

Flirds 진행 보고

Client-level In-Run Data Shapley for Federated LLM Fine-tuning

2026-06-12 · Yonghee Choi · 요약판

표기 규약

㉠ 구현+smoke (값 coarse) · ㉡ 실측 (설정 병기) · ㉢ 설계만, 미실행

기울임 회색 = 잔여 셀(device100 poison · $\alpha=0.5$ anchor · 7B) 확정 대기. 상세 근거는 상세판 데크 참조.

문제와 선행 연구의 빈 부분

- server가 보는 것은 $\Delta w_k, n_k$ 뿐 $\rightarrow$ post-hoc · 재학습 0 · 추가 통신 0으로 client 기여도 φ_k
- 용도: ① corrupt/free-rider 식별 ② selection(상위 client 재학습)

선행	한계
retrain Shapley (G&Z '19)	재학습 비용 — 126분 (1B N=5 fp32 ㉞), N=10 $\approx$ 2-5일 (추정, ㉟)
FL-SV 계열 ('20-'23)	coalition/MC 비용 · 전부 CNN
Influence Functions ('17)	iHVP($H^{-1}v$) 역산 — 불안정·고비용
IRDS	centralized · per-step · sample-level
Ripple (AAAI '26)	sample-level · CNN · 2차는 cross-round 전파(클라 상호작용 항 없음)
FedIF ('25)	순수 1차 · aggregation 변경
FedTSV (ECC '26)	0차 기하 · aggregation 물건

빈 교집합: client-level · in-run · closed-form 1+2차 · HVP 상호작용항 · 통신 0 · LoRA/LLM (서술적 서버이 근거)

알고리즘

$$\varphi_k = \sum_r p_k^r [\langle g^r, \Delta w_k \rangle + \frac{1}{2} \langle \Delta w_k, u^r \rangle], \quad u^r = H^r \Delta W^r$$

frozen FedAvg 궤적만 입력 · $g^r = \nabla \text{val-loss} \cdot \text{val-loss}$ 를 내리면 $\varphi < 0$

- **round당 HVP 1회** — forward $H \cdot v$, H^{-1} 불사용, true Hessian
- 비용 **N-독립** $\leftrightarrow$ in-run oracle $2^N \cdot R$ forward
- Flirds-1st(2차 off): 35s — coalition 계열($\sim 530s$) 대비 $\approx 15\times$
- **free-rider $\varphi = 0$ exact** (구조적; 실측 매 seed 0 ⑥)
- 2차의 근거: FL per-round Δw 큼 — CNN $0.962 > 0.924$ ⑥; momentum서 역전 $\rightarrow$ plain SGD 고정
- 제약: fp32 · eager attention · LoRA-subspace

실험 프레임 — 질문 → 실험 → 상태

질문	실험	상태
Shapley 계산이 옳은가	dual-oracle 삼중 비교	㉞ +1.000 (1B N=5 fp32 3-seed)
기존 방법 대비	같은 궤적 9-method (+FedIF)	㉞ 3-seed (FedIF 포함)
위협을 식별하나	2 regime × 4 threat + detector 4종	㉞ silo5·3B·device100 · <i>poison 2셀 잔여</i>
N=100서 성립하나	per-round exact 분해 + α -sweep	sweep 12셀 ㉞ · <i>anchor 3셀 잔여</i>
실용 가치	selection run	㉞ 3-seed
scale 유지	1B → 3B → 7B	1B ㉞ · 3B 4-threat ㉞(1-seed) · 7B ㉞
무변별 해소	N=10 retrain oracle	㉞ 연기 — 논의 ㉞

방법 검증

dual-oracle — 검증은 같은 게임(val-loss)으로

- retrain(val-loss) = in-run oracle = estimator — **Spearman +1.000** ⑥ (1B N=5 fp32 3-seed, lr 2종) · 3B(1-seed): estimator +1.000 유지, retrain↔in-run +0.900
- retrain-ROUGE는 발산(+0.4 / -0.9) = 다른 게임 → val-loss가 옳은 검증 지표

baseline 9종 — 같은 frozen 궤적

- noisy/FR: 전 방법 +1.000 동률 (N=5 near-additive) → "같은 랭킹을 더 싸게"
- runtime: 35s(1st·FedIF) · 107s(Flirds) · 164s(loss-heur) · ~530s(GTG·FedSV·Banzhaf·ShapleyFL·oracle) · ~4515s(Ripple, 별도 세션)
- free-rider $\varphi=0$ exact: Flirds·oracle·Banzhaf·loss-heur (GTG·FedSV는 $\neq 0$) · FedIF(정규화 1차): noisy/FR AUROC 1.0 ⑥(silo5 재실행 3-seed)

selection — 검출을 성능으로

- noisy+FR 정확히 드롭 ⑥ (3-seed, 양 lr 일관) · vs full 항상 우세 · vs random cross-seed 우세 (noisy AUROC lr 반전 있어도 결론 불변)

위협 매트릭스 — 2 regime × 4 threat

위협	정의	matched detector
noisy	answer_swap — 정직하지만 나쁜 데이터	FedDQC
free-rider (2모드)	zero: $\Delta w=0$ · random: benign-std	STD-DAGMM · FLTrust
poison	backdoor (trigger + γ -scaled replacement)	FLDetector · FLTrust

라벨은 AUROC 채점 key — method 입력 아님(순환 아님). 결과: silo5 3-seed 재실행본 ⑥ (FedIF 포함, 8d364cc)

- noisy / free-rider: **전 방법 AUROC 1.0** (Sp 예외: FedIF 0.90–0.93 · FedSV FR-random 0.933)
- **poison(ASR=1.00) = 동물 첫 붕괴 — raw 1차만 0.000 회피** · 2차 0.917 ± 0.118 · 정규화 1차(FedIF·FLTrust)·exact 계열 **1.0**
2차는 이전 동일 config run서 0.417 ± 0.425 (run간 분산, 원인 규명 중) · 3B(1-seed)는 1차·2차 모두 0.000 회피 · exact 계열 = oracle-loss-heur-Banzhaf-ShapleyFL
- detector: poison — FLDetector·FLTrust·FedDQC **1.0**, STD-DAGMM 0.75 · FR-zero STD-DAGMM 0.250 **실패** · noisy FedDQC 0.917

Flirds = noisy + free-rider는 잡는다. backdoor는 raw 1차 회피·2차 불안정 → 정규화 1차·secant·matched detector가 보완 (채택은 논의 ①)

scale-up

cross-device N=100

- per-round exact 분해 $\equiv 2^N$ ($\Delta\phi \approx 3e-16$ ㉞) · oracle ~11h/4-GPU → $\alpha=0.5$ anchor만, 나머지는 Flirds proxy-truth
- α -sweep 12셀 ㉞(3-seed): free-rider — Flirds 계열 전 α AUROC 1.000 · noisy — 0.57–0.77 약함 (matched FedDQC 0.96–1.0이 보완)
- anchor: Flirds vs oracle +1.000 ㉞ (1B, 1-seed smoke) · $\phi=0$ exact 유지 · *anchor 3셀 + poison 2셀 잔여*

model ladder

- 1B ㉞ → 3B 4-threat ㉞(1-seed): noisy/FR valuation 전부 1.0 (detector 예외: STD-DAGMM 0.25/0.00, FedDQC 0.75), **poison은 1차·2차 모두 0.000 회피** → 7B ㉟ · 전부 fp32

N=10 retrain oracle

- 재학습 $64\times \approx 2\text{--}5\text{일}/1\text{-GPU}$ (추정) → ㉟ 연기 — 투자 판단(논의 ㉠)

남은 문제

방법 내재

- Taylor 절단 — clean-preserving backdoor 회피(tangent 맹점)
- plain SGD 강제 — AdamW 비호환(최대 일반성 제약)
- fp32 강제 — 신호 < bf16 정밀도
- 적용 범위 — eager · LoRA-subspace · vanilla FedAvg 한정
- 단일 val-loss 게임 — val 오염 미고려 ©

증거력

- N=5 무변별 — 유일한 분리(poison)가 Flirds에 불리
- noisy AUROC lr 반전 — lr 미확정(논의 ③)
- N=100 noisy 약함 — 0.57–0.77 (FedDQC 보완)
- 1-seed 항목 — 3B tier · anchor 미실행
- proxy-truth 순환 — off-anchor truth = Flirds 자신
- poison 인위성 — 별도 config서만 ASR>0
- 최악 공격자만 — stealthy·DBA·advanced FR 제외
- detector 개조 confound — 원형 ablation 부재

① 진행 중 + main 트랙 보강

- real grid — 20/25셀 완료 (8d364cc) · 잔여: device100 poison 2 + $\alpha=0.5$ anchor 3 + 7B
- poison 2차 거동 규명 — 1B run 분산 + 3B 회피 · 기실행 궤적 재분석(비용 ~0) — **최우선**
- two-sided $|\varphi|$ 산출물화 · orientation·lr 양쪽 보고 규약
- 2차항 결정 실험 — PGD/direction-aligned poison (FedIF 공인 blind spot)
- advanced free-rider(Lin II/III) · **원형 ablation** + bootstrap CI
- N=10 retrain oracle — 투자 판단(논의 ②)

② 추가 실험 Track C/D — 표준 세팅 비교 (설계 확정 ㉟)

동기: main 실험은 선행과 직접 비교가 어렵다 → 선행 다수의 **일반 학습 세팅**으로 비교 트랙 추가 (선행 13편 프로토콜 조사 기반)

트랙	세팅	핵심
C1	CNN cross-silo, N=10 full	fidelity & cost — (a)+(b) 듀얼 oracle, GTG 5-시나리오, 9-method + Ripple
C2	CNN cross-device, N=100 (메인)	일반 성능 — 개입 3종 × 3 파티션 × 4 위험 개입: 가중집계(곱셈형 $w \propto n \cdot s$ 메인) · selection · bottom-q%
C3	(비용 0)	cross-seed 안정성 — Banzhaf-Volatility 처방 응답
D	LLM, Alpaca-GPT4 20k IID N=5	표준 세팅 — answer_swap 50% → 필터링 재학습 → MMLU (전부 API-free; 7B=Llama-2)

조사에서 본 공백: fidelity+학습개선 동시 커버 없음 · (a)+(b) 듀얼 oracle 없음 · LLM-scale FL valuation 직접 경쟁자 없음

결정이 필요한 항목

항목	선택지
① threat-matrix headline	"noisy+FR은 잡고 backdoor엔 회피(detector 보완)" 채택 여부
② N=10 retrain oracle	2-5일/1-GPU vs 샤딩 구축(11-22h) vs detection-only 차선
③ real grid lr	2e-5 vs 1e-3/3e-3 — noisy 결론이 갈림
④ Ripple 차별화 문구	"2차 없음" → "다른 종류의 2차"로 교체 승인