

Flirds 진행 보고

Client-level In-Run Data Shapley for Federated LLM Fine-tuning

2026-06-12 · Yonghee Choi

표기 규약 (자료 전체 공통)

㉠ 구현 완료 + smoke 통과 (값은 coarse) · ㉡ 실측 (설정 병기) · ㉢ 설계 확정, 미실행

모든 정량 주장에 설정(모델 / N / regime / seed / config)을 병기한다.

기울임 회색 = 잔여 셀 확정 대기(device100 poison 2셀 · $\alpha=0.5$ anchor 3셀 · 7B) — 확정 시 갱신.

문제 설정과 선행 연구의 빈 부분

- FedAvg에서 server가 보는 것은 round별 client update Δw_k 와 데이터 수 n_k 뿐 — raw data에는 접근할 수 없다.
- 목표: 학습 종료 후 post-hoc으로, 재학습 0 · 추가 통신 0으로 client별 기여도 ϕ_k 를 산출.
- 용도: ① value semantics — corrupt/free-rider client가 낮은 값을 받는가 ② selection — 상위 client만으로 재학습하면 성능이 좋아지는가.

선행 연구가 놓쳐온 부분

선행	남는 한계
retrain Shapley (Ghorbani & Zou 2019)	coalition마다 재학습. 실측 1B N=5 fp32 126분 ⑥; N=10은 $\approx$ 2-5일/1-GPU 추정(실행 ⑥) — LLM-FL에 비용 부적합
FL-SV 계열 (FedSV '20 · GTG '21 · ComFedSV '21 · ShapleyFL '23)	retrain-free지만 coalition 재구성/MC 비용. 실험은 전부 CNN
Influence Functions (Koh & Liang 2017)	iHVP($H^{-1}v$) 반복 역산 — 불안정·고비용(LLM 적용 한계 보고)
IRDS (In-Run Data Shapley)	in-run Shapley의 직접 조상이나 centralized · per-step · sample-level
Ripple Shapley (AAAI '26)	federated in-run 선점. sample-level · CNN; 2차는 local-data Hessian의 cross-round 전파 — within-round client 상호작용 항 없음
FedIF (2025)	client-level 순수 1차(TracIn). 2차 명시 회피, CNN, aggregation 변경
FedTSV (ECC '26)	0차 기하 근접 utility. aggregation 방법(평가 회계 아님), 서버 val-train 추가

비어 있는 교집합(6축): client-level · in-run · closed-form 1+2차 Taylor · HVP client-interaction 항 · 추가 통신 0 · LoRA/LLM (post-hoc/aggregation 무변경은 별도 축). 이 비점유 주장의 근거는 서술적 서베이이며 코드 수준 검증은 아니다.

알고리즘 — 수식·비용 / 성질·제약

- 입력: frozen FedAvg 궤적 $\text{logs} = [(\mathbf{w}_r, \text{deltas_map})]$ 만. estimator는 model-task를 직접 보지 않는다(loss_fn·pkeys 주입).

$$\varphi_k = \sum_r p_k^r [\langle \mathbf{g}^r, \Delta \mathbf{w}_k \rangle + \frac{1}{2} \langle \Delta \mathbf{w}_k, \mathbf{u}^r \rangle], \quad \mathbf{u}^r = \mathbf{H}^r \Delta \mathbf{W}^r$$

$\mathbf{g}^r = \nabla \text{val-loss}$, $p_k^r = n_k / \sum_{j \in P_r} n_j$. val-loss를 내리면 $\varphi_k < 0$ (더 가치 있음).

- **round당 HVP 정확히 1회** — 2차항이 $\mathbf{u}^r$ 하나와 $|P_r|$ 개 내적으로 붕괴. forward $\mathbf{H} \cdot \text{v}(\text{vp} \circ \text{grad})$ 만 사용, $\mathbf{H}^{-1}$ 불사용. true Hessian(GGN/Fisher는 CNN 시험 후 기각).
- 비용: estimator = R회 HVP + N·R 내적(N-독립) $\leftrightarrow$ in-run oracle = $2^N \cdot R \cdot \text{val forward}$.
- Flirds-1st(2차 off): ~35s — coalition 계열(~530s) 대비 $\approx 15\times$, Flirds(107s) 대비 $\sim 3\times$ 저렴.

구조적 성질

- **free-rider φ = 정확히 0** — $\Delta \mathbf{w}=0$ 이면 모든 내적이 0(구조적). 실측 매 seed exact 0 ⑥(1B N=5 3-seed).

2차항이 FL에서 의미를 갖는 이유

- IRDS는 centralized per-step(작은 η)에서 2차가 거의 무의미하다고 보고. FL의 per-round $\Delta \mathbf{w}$ 는 multi-step 누적이라 크다.
- CNN 실측 ⑥: plain SGD에서 1+2차 Spearman 0.962 > 1차 0.924; momentum=0.9에서는 역전(0.73 < 0.81) $\rightarrow$ 전 실험 plain SGD mom=0 고정.

운영 제약 (그대로 보고)

- fp32 필수 — utility(=loss 차) $\sim 1e-3 < \text{bf16}$ 정밀도 $\sim 8e-3$.
- eager attention 필수(forward-mode AD) · LoRA-subspace 한정 valuation.

실험 프레임 — 질문 → 실험 → 상태

7개 질문에 실험을 대응시켰다. 상세 결과는 다음 3장.

질문	실험	현재 상태
Shapley 계산이 옳은가	dual-oracle 삼중 비교 (retrain = in-run = estimator)	㉞ +1.000 (1B N=5 fp32 3-seed)
기존 방법 대비 무엇이 나은가	같은 frozen 궤적 위 9-method 비교 (+FedIF)	㉞ phase1 + silo5 재실행 3-seed (FedIF 포함)
위협을 식별하는가	2 regime × 4 threat + matched detector 4종	㉞ silo5·3B·device100 sweep · <i>poison 2셀 잔여</i>
N=100에서 성립하는가	per-round exact 분해 + α -sweep	sweep 12셀 ㉞ 3-seed · $\alpha=0.5$ <i>anchor 3셀 잔여</i>
실용 가치가 있는가	selection run (top-k 재학습)	㉞ 3-seed, 양 lr
scale에서 유지되는가	1B → 3B → 7B ladder	1B ㉞ · 3B 4-threat ㉞(1-seed) · 7B ㉞
N=5 near-additive 무변별 해소	N=10 retrain oracle	㉞ 연기(비용) — 논의 항목 ②

방법 검증 — dual-oracle · baseline 비교 · selection

dual-oracle 검증 — 왜 val-loss인가

- 검증은 **같은 게임(val-loss)**이어야 한다: estimator는 val-loss의 Taylor. ROUGE는 미분 불가(estimator-ROUGE 자체가 불가) + answer_swap의 도메인 포맷에 속는다 — retrain-ROUGE는 실제로 발산(+0.4 @1B / -0.9 @3B). retrain coalition val-loss 차(~0.005–0.02)는 bf16 정밀도(~0.009)에 묻혀 fp32 필수.
- 결과 ⑥: retrain(val-loss) = in-run oracle = estimator, **Spearman +1.000** (1B N=5 fp32 3-seed, lr 2종). 3B(1-seed): estimator +1.000 유지, retrain vs in-run +0.900(clean-client 1-swap ≈ 재학습 noise).

같은 궤적 위 baseline 비교 (9-method + FedIF)

- ⑥ phase1(1B N=5 silo5 3-seed, lr 1e-3·3e-3): noisy/free-rider에서 **전 방법 Spearman +1.000 동률**(N=5 near-additive) → 주장은 "더 정확"이 아니라 "**같은 랭킹을 더 싸게**". silo5 재실행본(3-seed, 8d364cc)도 동률 재확인.
- 런타임 ⑥: Flirds-1st 35s · FedIF 35s · Flirds 107s · loss-heur 164s · GTG/FedSV/Banzhaf/ShapleyFL/(b) oracle ~530s · Ripple ~4515s(별도 세션; eigsh flaky로 자동 비교에서 분리).
- free-rider φ exact-0: Flirds·oracle·Banzhaf·loss-heur. GTG·FedSV는 within-subset renorm으로 ≠0. FedIF(정규화 1차) ⑥: noisy/FR AUROC 1.0, Spearman 0.90–0.93(silo5 재실행 3-seed).

selection run — 검출을 성능으로

- ⑥(1B N=5 3-seed, 양 lr): noisy+free-rider를 정확히 드롭(keep {2,3,4} 전 seed·양 lr 일관). vs full 항상 우세; vs random은 cross-seed 우세(seed0은 random도 clean set 선택 → tie).
- nuance: noisy AUROC는 lr에 따라 반전(1e-3: 0.75/1.0 ↔ 3e-3: 1.0/0.75) — selection 결론은 양 lr 동일.

위협 매트릭스 — 2 regime × 4 threat + matched detector

– oracle 일치는 "Shapley 계산이 맞다"까지만 증명 — corrupt→low value(semantics)는 별도 검증 + 전용 detector 대비 경쟁 bar. **라벨은 AUROC 채점 key일 뿐 method 입력이 아니다 (순환 아님).**

위협	정의 (출처)	matched detector
noisy	answer_swap — 정직하지만 나쁜 데이터	FedDQC
free-rider	$\Delta w=0$ 또는 benign-std random (Lin 2019)	STD-DAGMM · FLTrust
poison	backdoor — Xu 2023 trigger + Bagdasaryan 2020 γ -scaled replacement	FLDetector · FLTrust

결과 — silo5 4-threat 3-seed 재실행본 ⑥ (FedIF 포함 · run-dir 영속화, 8d364cc)

- noisy / free-rider: valuation 전 방법 AUROC 1.0; Spearman 동률(예외: FedIF 0.90–0.93 · FedSV FR-random 0.933±0.047).
- **poison(ASR=1.00 전 seed, working-backdoor config) = 동률의 첫 붕괴 — raw 1차(Flirds-1st)만 AUROC 0.000 완전 회피.** Flirds-2차 0.917±0.118(seed별 0.75/1.0/1.0; 단 이전 동일 config run은 0.417±0.425 — run간 비결정성, 원인 규명 중). 정규화 1차(FedIF·FLTrust)와 exact 계열(oracle·loss-heur·Banzhaf·ShapleyFL)은 AUROC 1.0; Spearman은 GTG +0.867 · FedSV +0.367로 열화.
- detector: poison — FLDetector·FLTrust·FedDQC 1.0, STD-DAGMM 0.75±0.204 · noisy — FedDQC 0.917±0.118, FLDetector 0.75(off-threat), STD-DAGMM 0.417±0.312 · FR-zero — STD-DAGMM 0.250±0.204 **실패**(matched threat 실패, 진단 필요), FedDQC 0.75 · FR-random — STD-DAGMM·FLDetector 1.0.

현재 데이터 기준 정리: Flirds는 noisy + free-rider를 잡는다. clean-preserving backdoor는 raw 1차가 일관 회피하고, 2차는 1B서 0.917±0.118(run 분산)·3B(1-seed)서는 0.000 — 정규화 1차(FedIF·FLTrust)·loss-heur·FLDetector·FedDQC가 보완(전부 1.0). (headline 채택은 논의 항목 ①)

scale-up — cross-device $N=100 \cdot 1B \rightarrow 7B \cdot N=10$ 연기

cross-device $N=100$

- 설계: per-client Dirichlet(α) 도메인 혼합(Option B), $K=10/\text{round}$, $\alpha \in \{0, 0.01, 0.1, 0.5, 5.0\}$, $\text{per_client}=300$.
- oracle: per-round exact 분해 $\sum_r 2^{|\mathcal{P}_r|} \equiv 2^N$ ($\Delta\phi \approx 3e-16$ 검증 ㉞). 그래도 771ms/forward(fp32, B200) $\rightarrow \sim 11\text{h}/4\text{-GPU}$: in-run oracle은 $\alpha=0.5$ anchor 1점만, off-anchor는 Flirds proxy-truth(자기 오류는 검출 불가 — 한계로 명시).
- α -sweep 12셀 ㉞($\alpha \in \{0, 0.01, 0.1, 5.0\} \times \text{noisy/FR-zero/FR-random, 3-seed}$): free-rider — Flirds·Flirds-1st-loss-heur·FLTrust 전 α **AUROC 1.000**(FedIF 0.98–0.99) · noisy — cheap valuation 0.57–0.77로 약함, matched FedDQC 0.96–1.0이 보완 · 1차=2차=loss-heur 랭킹 동일(proxy-truth Sp 1.000) · ComFedSV 0.39–0.45 실패, STD-DAGMM 0.51–0.96 불안정.
- anchor: Flirds vs per-round oracle Spearman +1.000 ㉞(1B, 1-seed smoke) · free-rider $\phi=0$ exact 유지 · $\alpha=0.5$ anchor 3셀(*oracle 동반*) + *device100 poison 2셀 잔여*.

scale ladder

- 1B ㉞ 완료 · 3B 4-threat ㉞(1-seed, (b)oracle 동반): noisy/FR valuation 전 방법 AUROC 1.0(detector 예외: STD-DAGMM noisy 0.25·FR-zero 0.00·FR-random 1.0, FedDQC FR 0.75), Flirds vs (b) Sp +1.000(FedIF 0.600) — **poison(ASR=1.0)은 Flirds 1차·2차 모두 AUROC 0.000 회피**(loss-heur·FedIF·FLTrust·FLDetector·FedDQC는 1.0) · 7B ㉞(경로 구현됨, 미실행). 전부 fp32.

$N=10$ retrain oracle — 연기 사유

- ㉞ 재학습 코어리션-스텝 5120 vs $N=5$ 의 80(64 $\times$) + eval 32 $\times \approx 2\text{--}5\text{일}/1\text{-GPU}$ 추정 $\rightarrow$ multi-GPU coalition 사당 필요. $N=5$ near-additive 무변별을 직접 해소하는 유일한 증거라 투자 판단 필요(논의 항목 ㉞).

남은 문제 — 방법 내재 / 증거력

방법 내재

- **Taylor 절단** — clean-preserving backdoor의 γ -update가 clean val-loss를 내림 → tangent는 most-helpful로 오판, exact secant는 잡음. 2차 회복은 1B서 부분적(run 분산)·3B(1-seed)서는 부재. 전개반경 진단 코드 부재.
- **plain SGD mom=0 강제** — AdamW 실무와 비호환. momentum에서 2차 역효과 기관측. 가장 큰 일반성 제약.
- **fp32 강제** — 신호($\sim 1e-3$) < bf16 정밀도($\sim 8e-3$) 자체가 본질 제약. bf16 배포 궤적 valuation 불가.
- **적용 범위** — eager attention 필수 · LoRA-subspace 한정 · vanilla FedAvg 한정 (robust/secure aggregation 비호환) · 개별 Δw 노출 전제.
- **단일 server val-loss 게임** — val 오염·편향 미고려(민감도 실험 ©).

증거력

- **N=5 near-additive 무변별** — noisy/FR은 전 방법 동률. 유일한 분리는 poison인데 Flirds에 불리한 방향.
- **noisy AUROC lr 반전** — real grid lr 선택이 noisy 결론을 결정(미확정, 논의 ③).
- **N=100 noisy 약함** — cheap valuation 0.57–0.77(전 α , 3-seed); matched FedDQC 0.96–1.0이 보완.
- **1-seed 항목** — 3B(dual-oracle +0.900 · 4-threat tier); $\alpha=0.5$ anchor 미실행; FedDQC per-domain IRA 분석.
- **proxy-truth 순환** — α -sweep off-anchor의 truth가 Flirds 자신.
- **poison 인위성** — working-backdoor config(lr 2e-3 · batch 8 · epochs 5 · frac 0.8) 별도 invocation에서만 ASR>0; per_client 40→300은 공격 성립 위한 조정.
- **최악 공격자만** — stealthy 불가($\|\Delta\|=40\times$ benign), DBA 제외, free-rider easy 모드만.
- **detector 개조 confound** — FLTrust signed-cosine(강화) · STD-DAGMM hash+pooling(약화 가능) — 원형 ablation 부재.
- **문서 드리프트 전력** — 독립 검증 세션이 4건 교정. 본 자료는 교정값 채택.

① 진행 중 + main 트랙 보강

진행 중 — real grid (cost-tiered stage-gate)

- 완료: silo5 재실행 · device100 sweep 12셀 · 3B 4-threat (20/25셀, 8d364cc). 잔여: device100 poison 2셀 + $\alpha=0.5$ anchor 3셀 + 7B. poison은 working-backdoor config 별도 invocation.

무비용 분석 (기실행 데이터 재분석)

- **poison Flirds-2차 거동 규명** — 1B run간 분산($0.417 \leftrightarrow 0.917$) + 3B(1-seed) 완전 회피. per-round ϕ 분해 재분석(비용 ~ 0). 2차항 novelty의 사활처 — **최우선**.
- two-sided $|\phi|$ 점수 표준 산출물화(" ϕ -extreme, not ϕ -high") + orientation 사전고정 · lr 양쪽 보고 규약 명문화.

논문 전

- 2차항 결정 실험 — PGD/direction-aligned poison(FedIF가 논문에서 인정한 blind spot)에서 1차 vs 2차 분리; Ripple "2차 종류" 차별화와 결합.
- advanced free-rider(Lin Attack II/III) — val-loss를 내리는 적대 update의 free-rider 측 확인.
- 원형 ablation 3건(ReLU-FLTrust · per-round STD-DAGMM · Ripple 저자코드) + STD-DAGMM FR-zero 진단 + bootstrap CI.
- N=10 retrain oracle — 투자 판단(논의 항목 ②).

② 추가 실험 Track C/D — 표준 세팅 비교 (06-12 설계 확정 ©, 구현 착수)

- 동기: main 실험(LLM + 도메인 silo + detection)은 선행과 직접 비교가 어렵다 → 선행 다수가 쓰는 **일반 학습 세팅**(CNN · IID/label-skew · fidelity/수렴/정확도)의 비교 트랙 추가. 선행 13편의 실험 프로토콜 조사 기반 설계.

C1 — fidelity & cost (cross-silo CNN)

- MNIST+LeNet5 / CIFAR-10+FedSVCNN, N=10 full participation, GTG 5-시나리오(graded label-flip ladder 포함), GT = (a) 2^{10} retrain + (b) exact in-run 듀얼 oracle, Spearman/Kendall + GTG 거리 metric + wall-clock, 3-5 seed, 9-method + Ripple(eigsh guard).

C2 — 일반 성능 (cross-device CNN; 추가분의 메인)

- N=100, C=0.1, T=100-150 · 파티션 {IID, Dir(1), 2-shard} × 위협 {clean, label-flip(p, τ), free-rider, grad-noise} · **개입 3종**: 가중집계(곱셈형 $w \propto n \cdot s$ 메인[고유 규칙] + 대체형 [FedIF/ShapleyFL 관례] + additive $\lambda=0.5$ [Ripple 관례]) · selection(S-FedAvg식) · bottom-q% 제외(FedSV식) · 평가: AUROC + 최종 $\text{acc} \pm \text{seed}$ + acc-vs-round + rounds-to-target. C1→C2 stage-gate.

C3 — stability (보고 축, 비용 0)

- C1/C2 다시드에서 cross-seed Spearman + top/bottom-k% 일관성(Banzhaf 프로토콜 · Volatility 처방 응답).

D — LLM 표준 세팅 (전부 API-free)

- D-메인: Alpaca-GPT4 20k IID, N=5, answer_swap 50%(FedDQC convention) → AUROC/Spearman vs (b) + **ϕ -bottom 필터링 재학습** → MMLU(random-q% 대조). 옵션: FedDQC Table-1 미러(FiQA·AQUA) · FedHDS Dolly 미러(200 클라). 모델 1B/3B = Llama-3.2, 7B = Llama-2-7b(FL-LLM 문헌 표준).

조사에서 본 공백: fidelity+학습개선 동시 커버 논문 없음 · (a)+(b) 듀얼 oracle 없음 · LLM-scale FL valuation 직접 경쟁자 없음.

결정이 필요한 항목

항목	내용
① threat-matrix headline	"noisy+free-rider는 잡고, clean-preserving backdoor에는 회피됨(matched detector 보완)" — real config 재확인 후 채택 여부.
② N=10 retrain oracle 투자	2-5일/1-GPU vs multi-GPU 샤딩 구축(11-22h) vs 차선: cross-silo N=10 detection-only(retrain 불요 — 단 near-additive 직접 해소는 아님).
③ real grid lr	2e-5(plan, fine-tune scale) vs 1e-3/3e-3(비교 실험용). noisy AUROC 방향이 lr에 따라 갈림.
④ Ripple 차별화 문구	"2차 없음"(반박 위험) → "다른 종류의 2차: local-data Hessian의 cross-round 전파, within-round client-interaction 항 부재"로 교체 승인.