

EDGE AI LAB · 연구 진행 보고

Flirds: 재학습 없는 연합학습 데이터 기여도 평가

client-level Federated Learning In-Run Data Shapley
— validation loss의 1·2차 Taylor 근사로 라운드당 HVP 1회 —

최용희 · 연구실 세미나 · 2026-06

Llama-3.2 1B/3B (LoRA) · 5-domain instruction tuning · DGX B200×4

왜 연합학습에서 '데이터 기여도'인가

문제

의료기관

로컬 데이터 (비공개)

법률

로컬 데이터 (비공개)

금융

로컬 데이터 (비공개)

수학

로컬 데이터 (비공개)

일반

로컬 데이터 (비공개)

↓ 매 라운드, 모델 update Δw_k 만 서버로 ↓

서버 — 글로벌 LLM (FedAvg)

데이터는 못 보고, 클라이언트가 보낸 update만 받는다 → "누가 얼마나 기여했나? $\phi_k = ?$ "

- 보상·과금 — 기여한 만큼 나누려면 (data market, incentive) 기여도가 먼저 필요
- 품질 관리 — 나쁜 데이터 클라이언트를 걸러내면 글로벌 모델 성능이 좋아짐
- 위협 대응 — 무임승차(free-rider)·오염(poisoning) 클라이언트 식별

핵심 질문 — 서버가 어차피 받는 것(라운드별 update)만으로, 클라이언트별 기여도를 공정하게 계산할 수 있는가?

표준 답은 Shapley value — 그러나 비용 장벽

문제

- **Shapley value** = 협력 게임이론의 공정 배분 해 — 가능한 모든 부분집합(coalition)에 대해 "클라이언트 k가 들어갔을 때 성능이 얼마나 좋아지나"의 평균
 - 공정성 공리(효율·대칭·무기여자 0·가산성)를 만족하는 **유일한** 배분 — 데이터 가치평가의 표준
- 정의대로 계산하려면 **2^N 개 부분집합 각각으로 재학습** 후 평가해야 한다

N=5 (1B, fp32)

≈ **2시간**

재학습 oracle 실측 126분

N=10

2-5일 / GPU

재학습 64×, 평가 32×

N=100

불가능

2^{100} coalition

- 기존 FL-Shapley 근사(GTG, FedSV, ComFedSV ...)도 라운드마다 coalition을 평가 — 여전히 비싸고, **전부 CNN/소규모에서만 검증** (LLM-scale 검증 없음)

필요한 것 — LLM에서 돌고, Shapley 공리는 유지하면서, 재학습 없이 싼 방법


핵심 아이디어 — 학습 궤적 위에서 값을 매긴다 (in-run)

방법

- FedAvg는 어차피 라운드마다 (글로벌 모델 w_r , 클라이언트별 update Δw_k)를 서버에 남긴다
- 학습을 다시 하지 말고(IRDS의 통찰을 FL로), 이미 일어난 학습 궤적을 올려두고 그 위에서 가치를 매기자 — coalition별 validation-loss 변화를 **Taylor 전개**하면 Shapley 합이 닫힌 식으로 떨어진다

$$\phi_k = \sum_r p_k^r [\langle g^r, \Delta w_k \rangle + \frac{1}{2} \langle \Delta w_k, H^r \Delta w^r \rangle]$$

g^r = val-loss gradient · $H^r \Delta w^r$ = Hessian-vector product, 라운드당 단 1회 (클라이언트 수 N 과 무관)




재학습 0 · 추가 통신 0 · 학습 비개입(post-hoc) + 무임승차($\Delta w=0$)는 구조적으로 ϕ = 정확히 0

왜 2차(곡률) 항인가 — FL에서 비로소 의미가 생긴다

방법

- 원조 IRDS(centralized)는 **SGD 한 step**마다 전개 → step이 작아 2차가 거의 무의미했다
- FL은 다르다 — 클라이언트가 라운드당 **여러 step** 학습 → Δw 가 큼 → **곡률 보정이 필요해진다**
- 2차항의 정체 = $\frac{1}{2}\langle \Delta w_k, H_{val} \Delta w^r \rangle$
같은 라운드 참여자들의 update가 val-loss 곡률을 통해 **서로 상호작용**하는 항 (client-interaction)
- 증거
 - CNN: 1+2차 Spearman **0.96** > 1차 0.92 (plain SGD)
 - LLM backdoor: 1차 완전 회피 vs 2차 부분 회복 → **결과 ③**
- 경쟁자엔 없는 물건 — Ripple의 곡률은 로컬-Hessian의 **시간 전파** (라운드 내 상호작용 없음), FedIF는 **1차뿐**



가장 가까운 경쟁 연구와의 위치

방법


측	Ripple (AAAI'26)	FedIF ('25)	FedTSV (ECC'26)	Flirds (우리)
도메인	CNN	CNN	MLP/ResNet	LoRA-LLM 1B-7B
평가 단위	sample	client	client	client
Shapley 공리	✓	✗ (점수·EMA)	✓ (MC)	✓ (closed-form)
곡률(2차)	로컬-H 시간 전파	✗ 1차뿐	✗ 0차 기하	val-H client-interaction
학습 개입	없음	aggregation 변경	aggregation 변경	없음 (post-hoc)
추가 통신	0	0	서버 val-train/라운드	0

- 세 경쟁자 모두 CNN/이미지 — LLM·LoRA 측에서는 Flirds가 단독
- 노벨티 = "최초의 federated in-run"이 아니라(그건 Ripple), client-level × in-run × closed-form 1+2차 × post-hoc × LLM의 교집합
- 실측: Ripple을 LLM에 포팅하면 ~42× 느리고 탐지력 최약 (noisy AUROC 0.50±0.20) — 둘 다 우리 비교 suite에 포함

근사가 맞다는 걸 어떻게 믿나 — dual-oracle 검증

검증


- (a) **retrain oracle** — coalition마다 FedAvg를 재학습 (고전 Data Shapley의 정의; gold standard, N=5에서만 감당 가능)
- (b) **in-run oracle** — 같은 frozen 궤적에서 coalition별 val-loss 변화를 **exact 2^N 열거** (estimator가 근사하는 대상)
- **결과 — 삼중 일치 Spearman +1.000**
1B N=5, fp32, lr 2종 (3B에서도 estimator +1.000 유지)
- **방법론 통찰** — 검증은 **같은 게임(val-loss)**으로 해야 한다
 - retrain-ROUGE로 채점하면 발산(+0.4 / -0.9): 평가지표가 데이터 오염에 속는 사례 — val-loss는 안 속음



결과 ① — 같은 답을 5-15× 싸게 (비용-정확도)

결과

같은 frozen 궤적 위에서 **valuation 9종 + detector 4종** 공정 비교 (1B, N=5, 3-seed, real config) — noisy-free-rider에서 **모든 valuation 방법이 oracle과 같은 랭킹(Spearman +1.000)** → 남는 차이는 **비용**



* Ripple은 수치 불안정(eigsh)으로 별도 세션 측정. 비용 구조의 차이: **Flirds = 라운드당 HVP 1회** vs oracle·SV 계열 = 라운드당 2^N /MC coalition 평가.

결과 ② — 위협 탐지와 클라이언트 선별

결과

평가 설계: 2 regime (cross-silo N=5 / cross-device N=100) × 4 threat × 5-domain instruction 데이터 · 위협별 전용 detector 4종과 경쟁 (AUROC, 1B N=5 3-seed)


방법	noisy (라벨 오염)	free-rider (zero)	free-rider (random)
Flirds / Flirds-1st	1.000	1.000	1.000
FLTrust (≈ 정규화된 1차)	1.000	1.000	1.000
FedDQC (data-quality 전용)	0.917	0.750	0.750
STD-DAGMM (free-rider 전용)	0.417	0.250	1.000
FLDetector (poisoning 전용)	0.750	0.750	1.000

- 전용 detector는 위협이 바뀌면 무너진다 — Flirds는 가치평가를 하면서 noisy·free-rider 전부 1.0
- free-rider ϕ = 정확히 0 (수치 우연이 아니라 구조적: $\Delta w=0 \rightarrow$ 모든 내적 0)
- 선별 효과 — ϕ 하위 클라이언트 드롭 $\rightarrow$ 오염 2개(noisy+FR)만 정확히 제거, 전체 사용 대비 val loss 항상 개선, random 선택 대비 우위(seed 평균)

결과 ③ — backdoor가 드러낸 근사의 경계 (정직한 특성화)

결과

- 위협: instruction-trigger backdoor + γ -scaled 주입 (Xu'23 + Bagdasaryan'20), 배포 **ASR=1.00**인 실제 작동 공격
- 발견: 공격자가 clean val-loss를 오히려 낮춰줌 → 1차 Taylor에겐 "가장 도움되는 클라이언트"로 보임 → **Flirds-1st AUROC 0.000 (완전 회피, 재현 일관)**
- 2차항은 부분 회복 — 단 불안정 (동일 설정 재실행 간 $0.42 \pm 0.43 \leftrightarrow 0.92 \pm 0.12$) → 분산 원인 규명 진행 중. 2차가 1차를 이긴 첫 LLM-scale 신호
- 메커니즘: Taylor(접선)는 속고, exact 평가(secant)는 잡는다 (oracle·loss-heur 1.0) — 근사의 경계이지 프레임워크의 경계가 아님
- 처방: 전용 detector가 전부 1.0 → "Flirds(가치평가) + 전용 detector(보완)" 상보 구성. poison에서 방법 간 동률도 처음 깨짐 (FedSV Spearman +0.37로 추락)



결과 ④ — cross-device 스케일 (N=100)

결과

- N=100이면 2^{100} — oracle 자체가 불가능? → **per-round exact 분해**: 라운드 참여자(K=10)만의 $2^{|P_r|}$ 로 분해해도 수학적으로 동일 ($\Delta\phi \approx 3 \times 10^{-16}$ 검증)
- **anchor 검증 ($\alpha=0.5$)** — N=100에서 Flirds vs per-round exact oracle **Spearman +1.000** (oracle $\approx$ 11h/4-GPU vs Flirds 수 분 — oracle은 anchor 1점, 나머지 α 는 Flirds를 검증된 proxy로)
- **α -sweep** (Dirichlet 비IID 강도 {0, 0.01, 0.1, 0.5, 5}) **진행 중** — 잠정: free-rider는 N=100에서도 Flirds AUROC **1.000** ($\alpha=0.1$)

단계	내용	상태
tier 1 — cross-silo N=5	4 threat $\times$ 3-seed, 전 방법 + oracle	완료
tier 2 — cross-device N=100	α -sweep 12셀 + poison 2셀 (4-GPU 큐)	진행 중
tier 2 — $\alpha=0.5$ anchor	per-round oracle 동반 (비싼 셀, 마지막)	대기
tier 3 — 3B $\rightarrow$ 7B 스케일업	silo5 4 threat (oracle 포함)	대기

업데이트 예정 이 슬라이드의 sweep 결과는 실험 완료 시 갱신

한계와 열린 문제 — 정직하게

정리

- 2차항 가치의 입증에 아직 약하다 — noisy·FR에선 1차=2차(그리고 1차가 3× 싸다); 분리 신호는 poison뿐인데 불안정 → **분산 원인 규명이 현재 최우선 과제** (기존 궤적 재분석, 비용 ≈ 0)
- N=5는 near-additive — 방법 간 차이가 안 드러나는 regime; 분리력 입증은 N=10 oracle(2-5일) 또는 N=100 결과 필요
- 방법의 전제 조건 — plain SGD(momentum 0)·fp32·LoRA-subspace·vanilla FedAvg
 - momentum을 켜면 2차항이 역효과(실측) — Adam/bf16 일반화는 향후 과제
- poison 위협의 인위성 — backdoor가 설치되는 별도 config에서만 작동(설치 임계 존재); 더 정교한 공격(stealthy)은 이 설정에선 불가능했음
- advanced free-rider 미시험 — 이전 글로벌 update를 재활용하는 위장 모드가 Flirds에게 진짜 위험한 축; 뚫리면 경계 특성화, 막으면 robustness — 양쪽 다 논문 가치

현재 상태와 다음 단계

정리

완료 ✓

- 방법+코드 전체 (estimator, oracle 2종, baseline 9종, detector 4종, matrix 자동화)
- dual-oracle 삼중 일치 +1.000
- tier1 cross-silo 4-threat × 3-seed (결과 영속화 포함)

진행 중 ⦿

- tier2 cross-device α -sweep (4-GPU 큐 자동 실행)
- poison 2차항 분산 원인 규명 (라운드별 ϕ 분해 재분석)

예정 →

- $\alpha=0.5$ anchor(oracle 동반) → 3B → 7B
- N=10 retrain oracle (multi-GPU 샷딩)
- 2차항 결정 실험(PGD-poison) · advanced free-rider

논문 전 가장 가치 있는 한 수 — **poison에서 2차항 seed/run 분산의 원인 규명**: 이미 돌린 궤적의 재분석이라 비용이 거의 없고, 결과가 "2차항이 언제 필요한가"라는 중심 서사를 결정한다

업데이트 예정

실험 완료분 반영 시 이 슬라이드 갱신

- 1 Flirds — 재학습 0, 추가 통신 0, 라운드당 HVP 1회로 클라이언트 Shapley 기여도를 계산.**
LLM 연합학습에서 실용적으로 도는 첫 client-level 기여도 평가 (LoRA 1B-7B).
- 2 검증: retrain oracle = in-run oracle = estimator, 삼중 일치 +1.000 — 그리고 같은 랭킹을 5-15× 싸게.**
"같은 게임(val-loss)으로 검증한다"는 dual-oracle 방법론 자체가 기여.
- 3 탐지: noisy-free-rider 완벽 ($\phi=0$ 구조적), backdoor는 경계를 메커니즘까지 규명 + 보완 detector 제시.**
근사가 속는 지점(접선 vs secant)을 숨기지 않고 특성화 — 2차항이 1차를 이긴 첫 신호 확보.

다음 한 수 — 2차항 분산 규명 + α -sweep 완료 → 논문 중심 서사 확정

부록 A — LLM-scale에서 돌게 만든 엔지니어링

부록

- **fp32 필수** — 신호(coalition loss 차 $\sim 10^{-3}$)가 bf16 정밀도($\sim 8 \times 10^{-3}$)보다 작다 → bf16에선 Spearman 자체가 무의미 (oracle·estimator 모두 fp32 master)
- **forward HVP** (jvp◦grad) — $H \cdot v$ 한 번이면 되고 H^{-1} 은 절대 안 쓴다 → influence function의 iHVP 역산 비용·불안정성 회피
- **eager attention 강제** — SDPA/flash kernel은 forward-mode AD 미구현 → HVP가 예러
- **validation 도메인 청킹** — full-val gradient/HVP와 수학적으로 동일(선형)하면서 peak memory = 1청크 → OOM 회피
- **plain SGD (momentum=0) 강제** — per-round Taylor 전개 가정; momentum을 켜면 2차항이 역효과 (CNN 실측 $0.73 < 0.81$)
- **LoRA-subspace** — FL 상태는 named_parameters 키의 LoRA 가중치만 ($r=16$, 7개 projection)

부록 B — 데이터와 위협 정의

5-domain instruction 데이터

도메인	출처
의료	Medical Meadow flashcards
법률	QA legal dataset
금융	FiQA
수학	AQuA-RAT (풀이 포함)
일반	Dolly-15k

- 전 도메인 **free-form instruction→response** **균일 포맷** — 포맷이 다른 공유 val-loss Shapley가 불공정해짐
- train 12k/도메인 (크기 통제), val 200/도메인

위협 4종 (전부 논문 기반 정의)

- **noisy** = answer_swap — 클라이언트 내부에서 응답을 뒤섞음: "정직하지만 나쁜 데이터" (data-quality)
- **free-rider zero / random** — 가짜 update(0 또는 benign 통계 모사) (Lin et al. 2019 분류)
- **backdoor** — instruction trigger→목표 출력 (Xu 2023) + γ -scale 주입 (Bagdasaryan 2020); 설치 임계가 있어 별도 config에서만 ASR=1.0
- 검출 평가의 순환성 없음 — 주입 라벨은 채점 key(AUROC)일 뿐 방법의 입력이 아님

부록 C — 위협-매칭 detector suite

부록

detector	원 논문	타겟 위협	필요한 것	특징
FedDQC	'24	data-quality (noisy)	클라이언트 데이터+모델	instruction-response 정렬(IRA) 점수
STD-DAGMM	'19	free-rider	update만 (model-free)	AE+GMM 이상치 — gradient를 안 쓰는 독립 기준선
FLTrust	'21	free-rider·poison	val gradient	cosine 신뢰점수 $\approx$ 정규화된 Flirds-1차 (포섭 관계)
FLDetector	'22	poisoning	update만 (model-free)	시간 일관성 예측 잔차 — Flirds와 직교 신호

- 각 detector는 자기 위협에 맞춰 설계된 것 — 우리가 위협마다 가장 유리한 상대와 붙는 구도
- 전부 CV/소규모에서 온 방법: LLM-FL 클라이언트 레벨에서 검증된 기존 detector는 없음 → 포팅 자체도 기여
- 발견: gradient를 쓰는 검출(FLTrust $\approx$ Flirds-1차)은 free-rider에 강하고, model-free는 LoRA-scale에서 약함

부록 D — 핵심 수치 출처

부록

수치	설정	출처
삼중 일치 Spearman +1.000	1B N=5 fp32, lr 2종	retrain-oracle 검증 세션 (06-07)
3B: estimator +1.000 / retrain vs in-run +0.900	3B N=5 fp32 1-seed	scale 확인 세션 (06-08)
런타임 35 / 107 / ~530 / 4515s	1B N=5 R=10 3-seed	tier1 real grid (RESULTS.md)
noisy·FR AUROC 1.000, FR $\phi=0$	1B N=5 3-seed	tier1 real grid (RESULTS.md)
poison: 1차 0.000 / 2차 0.92 ± 0.12 (재실행) $\leftrightarrow$ 0.42 ± 0.43 (원실행)	1B N=5 3-seed, ASR=1.00	tier1 두 run 로그 대조 — run간 분산 자체가 보고 대상
N=100 anchor +1.000 ($\alpha=0.5$)	1B, K=10/round	cross-device 검증 (06-08)
CNN 2차 0.96 > 1차 0.92 (plain SGD)	CNN 시뮬레이터 3-seed	Phase 0.5 (06-03)

전체 근거 문서: [research-wiki/wiki/checkpoint-2026-06-10/](https://research-wiki.wiki/checkpoint-2026-06-10/) (00-07) · [runs/phase2_matrix/RESULTS.md](#)