
Flirds — 연합학습 클라이언트 기여도 측정

실험 결과 보고 (이미지 · 언어모델)

방법 : 검증손실의 1 차 +2 차 테일러 전개로 클라이언트 Shapley 추정 (라운드당 HVP 1 회)
client-level FL Shapley via 1st+2nd-order Taylor of validation loss

실험 개요 — 세 트랙, 모두 완료

트랙	도메인 / 모델	연합 셋업 (분할)	셀	seed	핵심 산출
Image (CNN)	MNIST+LeNet5 / CIFAR-10·FMNIST+CNN	N=10 fidelity · N=100 개입 (IID·Non-IID 다종)	150	3	fidelity(듀얼 오라클) · 개입 8arm
LLM robustness	Llama-3.2 1B · 3B (LoRA)	N=5 cross-silo(Non-IID) · N=100 cross-device(α)	25	1-3	4 threat × fidelity · 탐지 · 개입
LLM standard (clean·IID)	Llama-3.2 1B · 3B / OpenFedLLM	N=20 standard · N=5 reference (IID)	10	2-3	IID·clean fidelity · 성능 · 수렴

핵심 질문 위계 (모든 표 · 서술 순서에 적용):

- 1 차 — 기여도를 얼마나 정확히 측정하는가 (오라클 대비 fidelity: Spearman·Kendall· 값 - 거리)
- 2 차 — 측정한 기여도의 실효성 : ① 일반 성능 → ② 수렴 속도 → ③ 오염 클라 탐지 (이 순서)
- 비교 대상 11 종 + 탐지기 4 종 / 듀얼 오라클 : retrain oracle(부분집합 재학습→검증손실), in-run oracle(학습계적 exact 2^N 분해).
- 분할 (IID/Non-IID)· 명세 · 지표 범례는 각 결과 페이지의 표 옆 / 아래에 병기 (별도 명세 페이지 없음).

비교 방법 11 종과 오라클 정의 (공용)

방법	유형	핵심	라운드당 비용
Flirds (제안)	valuation	검증손실 1 차 +2 차 테일러	HVP 1 회
Flirds-1st	valuation	1 차항만 (곡률 제외)	grad 1 회
loss-heur	heuristic	클라별 손실차	fwd 1 회
GTG / FedSV	Shapley(MC)	truncated/permutation MC	수십-수백 평가
Banzhaf	exact	2^N Banzhaf	2^N 평가
ShapleyFL / ComFedSV	Shapley(변형)	uniform-util / 부분합	수십-수백
FedIF	influence	검증그래디언트 정렬	grad 1 회
Ripple	2nd-order	고유분해 기반 (이미지만)	eigsh (수십분)
탐지기 4 종	detector	FLDetector·STD-DAGMM·FLTrust·FedDQC	모델 -free/grad

오라클 (정답 기여도)

in-run oracle

학습 궤적을 라운드별 exact Shapley 로 분해 (2^N). 추정량이 재현해야 할 게임 . $N=5$ 에서 2^5 .

retrain oracle

부분집합 S 를 FedAvg 재학습 → 배포모델 검증손실 . ' 배포 가치 ' 게임 . 이미지 $N=10$ 에서 $2^{10}=1024$ 재학습 .

핵심 : Flirds 는 in-run oracle 게임의 추정량 .
retrain oracle 와의 일치 여부는 'in-run 게임 = 재학습 게임 ' 인지를 묻는 별개 질문 (이미지 fidelity· 한계 참조).

in-run oracle 대비 기여도 순위 — 비교 11 종 전체

시나리오 (CIFAR / MNIST)	Flirds	Flirds1st	Banzhaf	GTG	FedSV	ComFedSV	ShapleyFL	FedIF	loss-heur	Ripple
CIFAR·iid	0.95	0.54	0.98	0.21	0.22	0.12	0.18	0.45	0.69	0.31
CIFAR·label_skew	0.98	0.92	1.00	0.49	0.53	0.31	0.29	0.68	0.88	0.26
CIFAR·quantity_skew	0.99	0.96	1.00	0.78	0.56	0.67	0.44	-0.20	0.98	0.68
CIFAR·label_flip	1.00	0.95	1.00	0.64	0.54	0.31	0.37	0.74	0.95	0.32
CIFAR·feature_noise	1.00	0.89	1.00	0.59	0.40	0.19	0.20	0.62	0.90	-0.01
CIFAR 평균	0.98	0.85	1.00	0.54	0.45	0.32	0.30	0.46	0.88	0.31
MNIST·iid	0.81	0.78	0.98	0.47	0.04	0.10	0.47	0.73	0.84	0.18
MNIST·label_skew	0.71	0.61	0.98	0.33	-0.01	0.14	-0.02	0.41	0.63	0.06
MNIST·quantity_skew	0.96	0.98	1.00	0.78	0.63	0.49	0.52	-0.07	0.96	0.96
MNIST·label_flip	1.00	0.99	1.00	0.99	0.97	0.95	0.98	0.98	0.99	0.97
MNIST·feature_noise	0.79	0.70	0.95	0.41	0.13	0.21	0.48	0.57	0.78	0.00
MNIST 평균	0.85	0.81	0.98	0.60	0.35	0.38	0.49	0.52	0.84	0.44

명세

MNIST+LeNet5 / CIFAR-10+CNN · N=10 full · R=10 · SGD mom=0 lr0.01 · val=2000 · 3 seed · in-run oracle 2¹⁰

분할 : iid=IID · label_skew·quantity_skew=Non-IID · label_flip·feature_noise=IID 분할 + 손상

지표

Spearman ρ ↑ (오라클 ϕ 대비 순위). 평균 = 데이터셋 단순평균 .
Flirds·Banzhaf 순위 최상 ; MC 기반
GTG/FedSV/ShapleyFL·ComFedSV·Ripple 은 noisy.
2 차항 고유 기여는 순위 아닌 값 - 거리 (다음장 하단).

iid·feature_noise 는 in-run oracle 신호 약함 (클라 동질). 출처 : runs/track_c/c1/* 재집계 (11 종 전체). 내부코드 fidelity=C1.

retrain oracle (2¹⁰) 대비 순위 , 그리고 in-run 과의 괴리

시나리오	Flirds	Flirds1st	Banzhaf	GTG	FedSV	ComFedSV	ShapleyFL	FedIF	loss-heur	Ripple
CIFAR·iid	-0.23	-0.13	-0.21	-0.20	-0.18	0.30	0.00	0.07	-0.18	-0.20
CIFAR·label_skew	-0.18	-0.07	-0.12	0.44	0.40	0.28	0.12	0.19	0.14	-0.23
CIFAR·quantity_skew	0.57	0.56	0.57	0.70	0.70	0.72	0.81	-0.03	0.57	0.47
CIFAR·label_flip	0.52	0.59	0.51	0.46	0.41	0.32	0.29	0.36	0.58	0.01
CIFAR·feature_noise	0.63	0.50	0.62	0.44	0.18	0.39	0.28	0.40	0.56	-0.12
CIFAR 평균	0.26	0.29	0.27	0.37	0.30	0.40	0.30	0.20	0.34	-0.01
MNIST·iid	0.36	0.52	0.44	0.19	-0.11	-0.10	0.67	0.74	0.48	0.09
MNIST·label_skew	-0.28	-0.06	-0.20	-0.22	-0.14	-0.04	0.28	0.54	-0.16	0.28
MNIST·quantity_skew	0.85	0.77	0.74	0.56	0.69	0.65	0.51	-0.10	0.84	0.74
MNIST·label_flip	0.96	0.97	0.97	0.97	0.96	0.94	0.96	0.96	0.97	0.98
MNIST·feature_noise	0.33	0.44	0.23	0.40	-0.07	-0.07	0.60	0.67	0.44	0.12
MNIST 평균	0.44	0.53	0.44	0.38	0.27	0.27	0.60	0.56	0.51	0.44

핵심 — 게임 정의 차이 (label_skew)

Flirds 는 in-run oracle 은 거의 완벽 재현하나 (앞장), retrain oracle 와는 label_skew 서 갈림 :

CIFAR in-run 0.98 → retrain -0.18 · MNIST 0.71 → retrain -0.29

추정오차 아님 — 모든 in-run 방법 공유 (희귀라벨 클라는 라운드 한계기여 낮아도 최종 재학습 모델엔 필수).

지표 / 2 차항 효과

Spearman ρ ↑ (retrain oracle ϕ 대비). 평균 = 데이터셋 단순 .
2 차항 : euclid_d(값 - 거리) label_flip CIFAR 0.031 vs 1 차 0.046
(MNIST 0.207 vs 0.370) → 값 오차 1 차 대비 ~25-50% ↓.

표 =Spearman ρ ↑ (rho_a_mean, 3-seed). reference(N=5, LLM standard) 는 retrain oracle 와 1.000 일치 → 괴리는 이질성 구동 . 출처 : RESULTS.txt. 내부코드 retrain oracle=(a).

개입 — IID vs Non-IID 분할 대조 (clean, 3-seed)

CIFAR-10 (test acc ↑)

분할 \ arm	vanilla	flirds_mult	flirds_select	shapleyfl	fedif	sfedavg
iid (IID)	0.648	0.646	0.646	0.647	0.647	0.646
dir1 (Non-IID)	0.638	0.642	0.634	0.635	0.637	0.631
shard (Non-IID 강)	0.475	0.498	0.417	0.496	0.474	0.487

명세

- CIFAR-10/FMNIST + CNN · N=100, C=0.1(10/round) · R=120
- epochs=5 lr0.01 · 분할 iid(IID) · dir1(Dir α=1) · shard(2 클래스 / 클라)
- clean(위협 없음) = do-no-harm 검증 · 3 seed

지표

test acc ↑. 분할 난이도 : shard(극단 Non-IID) ≪ iid.

FMNIST (test acc ↑)

분할 \ arm	vanilla	flirds_mult	flirds_select	shapleyfl	fedif	sfedavg
iid (IID)	0.856	0.856	0.858	0.858	0.855	0.858
dir1 (Non-IID)	0.812	0.829	0.846	0.842	0.813	0.838
shard (Non-IID 강)	0.686	0.717	0.672	0.733	0.683	0.712

읽기

clean 에선 전 가중 **arm** ≈ **vanilla** — 분할 종류 무관 **do-no-harm**.
(CIFAR shard 만 flirds_select 가 vanilla 보다 ↓ = hard-drop 의 비 -IID 부작용)
분할 난이도가 절대 정확도를 지배 (shard= 극단 Non-IID):
CIFAR iid 0.65→shard 0.48 · FMNIST 0.86→shard 0.69.
→ **가중은 어느 분할에서도 clean 성능을 해치지 않음**.

iid/shard 는 6 arm(flirds_repl·add 제외), dir1 은 8 arm. 위협 하 결과는 다음 장 . 출처 : runs/track_c/RESULTS.txt. 내부코드 intervention=C2.

개입 — 위협 하 robustness (CIFAR-10, dir1=Non-IID, 8 arm)

arm	clean	grad_noise	label_flip	free_rider	위협평균 acc
vanilla	0.638 (-)	0.245 (-)	0.515 (-)	0.587 (-)	0.449
flirds_mult	0.642 (-)	0.433 (0.99)	0.585 (0.93)	0.597 (0.39)	0.538
flirds_repl	0.639 (-)	0.370 (0.99)	0.579 (0.95)	0.593 (0.41)	0.514
flirds_add	0.640 (-)	0.333 (0.98)	0.560 (0.97)	0.593 (0.48)	0.495
flirds_select	0.634 (-)	0.313 (0.99)	0.559 (0.91)	0.589 (0.48)	0.487
shapleyfl	0.635 (-)	0.550 (1.00)	0.568 (0.96)	0.560 (0.00)	0.559
fedif	0.637 (-)	0.527 (1.00)	0.567 (0.96)	0.611 (1.00)	0.568
sfedavg	0.631 (-)	0.243 (1.00)	0.521 (0.94)	0.587 (0.04)	0.450

명세

- CIFAR-10 + CNN · N=100, C=0.1 · R=120
- 분할 dir1 (Dirichlet $\alpha=1$, Non-IID)
- arm 8 종 : vanilla · flirds(mult/repl/add/select) · shapleyfl · fedif · sfedavg
- strength sweep: grad0.05 · flip0.6/0.8 별도

지표

값 = test acc ↑ · () = 탐지 AUROC ↑

clean = 위협 無 → (-) · 위협평균 = 오염 3 종 acc

읽기

위협 하 전 가중 arm > vanilla.

grad_noise: shapleyfl0.550 · fedif0.527 최고 > flirds_mult0.433 (vanilla 0.245).

label_flip: flirds_mult0.585 최고 .

free_rider: fedif AUROC0.996, flirds0.385(약).

→ soft(mult) > hard(select). robust+ 무해 , 정확도 최고는 위협별로 같림 .

탐지 · 기여도 · 런타임 (Non-IID 5 도메인)

방법	noisy ↑	fr-rand ↑	fr-zero ↑	poison ↑	평균 ↑	ρ noisy ↑	ρ poison ↑	런타임 ↓
in-run oracle	1.000	1.000	1.000	1.000	1.000	-	-	532s
Flirds	1.000	1.000	1.000	0.917	0.979	1.00	0.97	106s
Flirds1st	1.000	1.000	1.000	0.000	0.750	1.00	0.00	35s
FedIF	1.000	1.000	1.000	1.000	1.000	0.93	0.97	35s
GTG	1.000	1.000	1.000	1.000	1.000	1.00	0.87	538s
FedSV	1.000	1.000	1.000	1.000	1.000	1.00	0.37	533s
ShapleyFL	1.000	1.000	1.000	1.000	1.000	1.00	1.00	530s
Banzhaf	1.000	1.000	1.000	1.000	1.000	1.00	1.00	533s
loss-heur	1.000	1.000	1.000	1.000	1.000	1.00	1.00	164s
FLDetector	0.750	1.000	0.750	1.000	0.875	-	-	30s
STD-DAGMM	0.417	1.000	0.250	0.750	0.604	-	-	136s
FLTrust	1.000	1.000	1.000	1.000	1.000	-	-	36s
FedDQC	0.917	0.750	0.750	1.000	0.854	-	-	22s

명세

- Llama-3.2-1B(+3B) LoRA · N=5
- 1 도메인 / 클라 → Non-IID(도메인 분리)
- R=10 · val=100 · lr1e-3(poison 2e-3)
- fp32 · eager · 3 seed · in-run oracle 2⁵
- 위협 : noisy(품질)/fr(zero,random)/poison(백도어 스케일교체)

지표

AUROC ↑ · ρ ↑ (vs in-run oracle) · 런타임 ↓

평균 = 4 위협 AUROC 단순평균

읽기

noisy·fr: 전 valuation 1.000, AUROC 1.0
(N=5 near-additive 동률); 우위 = 비용 .

poison ASR≈1.0: 1 차 0.000 완전회피 → 2 차 0.917 회복 (불안정); FedSV ρ 0.37.

α -sweep 탐지 AUROC (α = 분할 이질성)

noisy 탐지 AUROC ↑ (α -sweep)

방법	$\alpha=0.0$	$\alpha=0.01$	$\alpha=0.1$	$\alpha=0.5$	$\alpha=5.0$	평균
Flirds	0.774	0.575	0.605	0.604	0.596	0.631
FedIF	0.973	0.568	0.693	0.830	0.973	0.807
STD-DAGMM	0.856	0.652	0.659	0.671	0.760	0.720
FLTrust	1.000	0.602	0.720	0.854	0.994	0.834
FedDQC	0.960	1.000	1.000	1.000	1.000	0.992
FLDetector	0.535	0.482	0.525	0.539	0.532	0.523
ComFedSV	0.442	0.419	0.432	0.371	0.396	0.412

명세

- Llama-3.2-1B LoRA · N=100, K=10/round · R=30 · 1-3 seed
- 분할 = per-client Dirichlet(α), $\alpha \in \{0, 0.01, 0.1, 0.5, 5.0\}$
- α = 분할 이질성 : $\alpha \rightarrow 0$ 도메인 분리 (극단 Non-IID), $\alpha \rightarrow \infty$ 균일혼합 (IID). $\alpha=5.0 \approx \text{near-IID}$.

poison 탐지 AUROC ↑

방법	$\alpha=0.0$	$\alpha=0.5$	평균
Flirds	1.000	1.000	1.000
Flirds1st	1.000	0.670	0.835
loss-heur	1.000	1.000	1.000
FLDetector	0.987	0.983	0.985
STD-DAGMM	1.000	0.983	0.992
FedDQC	1.000	1.000	1.000
FLTrust	0.650	0.498	0.574
FedIF	0.542	0.458	0.500

읽기

free-rider(random · zero, 전 α): Flirds · 1 차 · loss-heur · FLTrust = 1.000.
noisy: FedDQC 영역 (스케일 1.0), Flirds ~0.60; fidelity 는 1 차 · loss-heur p=1.000(전 α).
poison(install): Flirds 1.0(both α), 1 차도 $\alpha=0$ 서 1.0 — 1 차가 회피되지 않음 .

$\alpha=0.5$ anchor — 전체 11 종 + 탐지기 (스케일 fidelity, 1 seed)

방법	AUROC ↑	ρ vs in-run oracle ↑
in-run oracle	0.604	–
Flirds	0.604	1.000
Flirds1st	0.605	1.000
loss-heur	0.605	1.000
GTG	0.734	0.784
FedSV	0.708	0.752
ShapleyFL	0.762	0.582
ComFedSV	0.371	-0.023
FedIF	0.830	0.721
FLDetector	0.539	–
STD-DAGMM	0.671	–
FLTrust	0.854	–
FedDQC	1.000	–

명세

- N=100 cross-device, $\alpha=0.5$ (중간 이질성)
- in-run oracle = per-round exact 분해
- 1 seed (기준점) · R=30
- 왜 기준점만 : 비싼 method(GTG/FedSV/ShapleyFL/ComFedSV) 는 α -sweep 전체엔 비용상 미실행 → $\alpha=0.5$ 한 점에서만 전체 suite 비교

지표

AUROC ↑ (noisy 탐지) · ρ ↑ (in-run oracle 순위)

읽기

스케일 fidelity: Flirds·1 차·loss-heur $\rho=1.000$;
GTG 0.78·FedSV 0.75·ShapleyFL 0.58·ComFedSV -0.02
→ N=100 서 MC/ 변형 Shapley 순위 열화, Flirds 유지.
noisy AUROC 는 데이터품질 탐지라 FedDQC 1.0 영역.
free-rider($\alpha=0.5$): Flirds·GTG·FedSV·loss-heur AUROC 1.0,
 ρ Flirds 1.0·GTG 0.82·FedSV 0.80. poison: Flirds·
loss-heur·FedDQC 1.0, Flirds1st 0.67(부분회피).

Llama-3.2-3B — 탐지 · 기여도 · 런타임 (Non-IID 5 도메인)

방법	noisy ↑	fr-rand ↑	fr-zero ↑	poison ↑	평균 ↑	ρ noisy ↑	ρ poison ↑	런타임 ↓
in-run oracle	1.000	1.000	1.000	1.000	1.000	–	–	1240s
Flirds	1.000	1.000	1.000	0.000	0.750	1.00	0.00	251s
Flirds1st	1.000	1.000	1.000	0.000	0.750	1.00	0.00	82s
FedIF	1.000	1.000	1.000	1.000	1.000	0.60	0.60	82s
loss-heur	1.000	1.000	1.000	1.000	1.000	1.00	1.00	384s
FLDetector	1.000	1.000	1.000	1.000	1.000	–	–	250s
STD-DAGMM	0.250	1.000	0.000	0.750	0.500	–	–	530s
FLTrust	1.000	1.000	1.000	1.000	1.000	–	–	85s
FedDQC	1.000	0.750	0.750	1.000	0.875	–	–	49s

명세

- Llama-3.2-3B LoRA · cross-silo N=5
- Non-IID(도메인 분리) · R=10
- 나머지 1B 와 동일 · seed 1 개 → 잠정
- 비싼 method(Banzhaf/GTG/FedSV/ ShapleyFL) 는 3B 서 비용상 미실행

지표

AUROC ↑ · ρ ↑ (vs in-run oracle) · 런타임 ↓

평균 = 4 위협 AUROC 단순평균

읽기

noisy · fr: Flirds ρ =1.000 유지 (1B→3B),
251s vs in-run oracle 1240s (~5× ↓).

poison: Flirds · 1 차 모두 0.000 — 1B 의 2 차
회복이 3B(1seed) 선 안 나타남 (미확정).

FedIF ρ 0.600(1B 0.90 ↓). loss-heur · 탐지기 1.0.

기여도 fidelity — 듀얼 오라클 · 1B/3B (IID·clean)

standard 1B (N=20) — vs in-run oracle (3 seed)

방법	Spearman ↑	Kendall ↑	cosine_d ↓	euclid_d ↓	max_diff ↓
Flirds	1.000	1.000	3.5e-07	4.4e-05	2.1e-05
Flirds1st	0.999	0.996	4.4e-05	6.2e-04	2.3e-04
loss-heur	1.000	1.000	2.4e-06	1.3e-04	5.3e-05
GTG	0.975	0.916	7.1e-04	9.8e-04	4.7e-04
FedSV	0.910	0.786	5.7e-03	2.8e-03	1.7e-03
ComFedSV	0.093	0.060	8.4e-01	2.6e-02	9.8e-03
ShapleyFL	0.194	0.133	2.1e-01	2.7e+00	9.9e-01
FedIF	0.157	0.111	1.9e-01	2.6e+00	9.8e-01

reference 1B (N=5) — vs retrain oracle (3 seed)

방법	Spearman ↑	Kendall ↑	cosine_d ↓	euclid_d ↓	max_diff ↓
Flirds	1.000	1.000	2.3e-09	4.8e-05	2.4e-05
Flirds1st	1.000	1.000	2.0e-07	3.1e-04	1.6e-04
Banzhaf	1.000	1.000	3.9e-11	4.0e-06	1.9e-06
loss-heur	1.000	1.000	6.1e-08	2.4e-04	1.2e-04
GTG	1.000	1.000	3.2e-03	2.5e-03	1.8e-03
FedSV	0.700	0.600	5.5e-03	3.6e-03	2.6e-03
ShapleyFL	0.700	0.600	1.9e-01	1.2e+00	9.8e-01
ComFedSV	0.500	0.467	1.3e-01	1.9e-02	1.4e-02
FedIF	0.067	0.067	2.3e-01	1.3e+00	9.8e-01

standard 3B (N=20) — vs in-run oracle (2 seed)

방법	Flirds	Flirds1st	loss-heur	GTG	FedSV	ComFedSV	ShapleyFL	FedIF
Spearman ↑	1.000	1.000	1.000	0.992	0.944	-0.133	0.302	0.338
cosine_d ↓	8.0e-08	2.1e-05	1.8e-06	5.6e-04	3.1e-03	1.0e+00	1.9e-01	1.6e-01

읽기
Flirds: in-run p=1.000 · retrain p=1.000 —
IID·clean 서 두 오라클 일치 → 이미지 (S5)
괴리는 이질성 구동임을 확인 .
1B→3B Flirds p=1.000 유지 (GTG 0.99·FedSV 0.93).
2 차항 : cosine_d 3.5e-7 vs 1 차 4.4e-5(~125×).
ShapleyFL·FedIF·ComFedSV 는 스케일서 약함 .

개입 arm — MMLU · ROUGE-L · 수렴 (standard 1B N=20)

arm	MMLU (0-shot) ↑	ROUGE-L ↑	final val-loss ↓	rounds→target ↓
base	0.4822	0.2168	–	–
vanilla	0.4742	0.2841	1.2653	200
flirds_w	0.4745	0.2848	1.2653	199
flirds_sel	0.4739	0.2838	1.2654	199
shapleyfl_w	0.4742	0.2845	1.2653	199
fedif_w	0.4741	0.2847	1.2652	198

명세

- Llama-3.2-1B / alpaca-gpt4 20k (IID)
- standard N=20, 2/round · R=200
- 10 steps×batch16 · lr1e-3 · seq512
- 개입 arm 6 종 · 3 seed · clean·IID
- 3B 는 N=20 개입 미실행 (N=5 reference 만)

지표

MMLU(0-shot) ↑ · ROUGE-L ↑ 성능
final val-loss ↓ · rounds→target ↓ 수렴

읽기

base = 학습 전 . FL-SFT 후 ROUGE-L +0.067
(0.217→0.284), MMLU -0.008.
전 가중 arm ≈ vanilla (±0.001, ±1 라운드).
→ **clean·IID 서 do-no-harm parity 확인**
(고칠 오염 없을 때 성능 · 수렴 무해).

기여도 측정 정확성 — 트랙 횡단 요약

측면	결과	근거
순위 vs in-run oracle	Flirds $\rho \approx 1.000$ (전 트랙 · 1B→3B). Banzhaf·loss-heur 도 우수 ; MC-SV 는 noisy	cross-silo·standard 1.000 / 이미지 0.71–1.00
값 - 거리 vs in-run oracle	2 차항이 1 차 대비 값오차 $\sim 2\times$ 축소 ; loss-heur 은 순위만 비기고 크기는 빛나감	euclid_d: 이미지 $\sim 0.5\times$ · standard cosine 125 $\times$
순위 vs retrain oracle	IID·clean 은 1.000 일치 ; label_skew(이질성) 에서 in-run oracle 와 괴리 (–)	reference(N=5) 1.000 / 이미지 label_skew –0.18~–0.29
스케일 (N=100)	$\alpha=0.5$ 기준점서 Flirds·1 차 ·loss-heur $\rho=1.000$; GTG/FedSV/ShapleyFL 은 열화	GTG 0.78·FedSV 0.75·ShapleyFL 0.58·ComFedSV –0.02
비용	Flirds 1 HVP/round; in-run oracle exact 의 5–15 $\times$ 저렴 , 동일 순위	cross-silo 106s vs 530s · 3B 251s vs 1240s

한 줄 요약

Flirds 는 in-run oracle 게임을 순위 · 값 모두에서 충실히 , exact 대비 저비용으로 , 1B→3B·N=5→N=100 서 일관되게 재현한다 .
2 차항의 고유 기여는 순위가 아니라 값 - 크기 정밀도 . retrain oracle 게임과의 일치는 데이터 이질성에 의존 (동질↔ label_skew).

① 일반 성능 → ② 수렴 → ③ 탐지

질문	요약
① 일반 성능	오염 하 전 가중 arm > vanilla(이미지 , 전 분할). clean/IID 는 무해 parity(이미지 · LLM). 정확도 최고는 위협별로 갈림 — grad_noise 서 shapleyfl/fedif, label_flip 서 flirds. soft>hard. 분할 난이도 (shard<<iid) 가 절대성능을 지배 .
② 수렴	IID·clean(LLM standard) 서 전 arm 동일 수렴 (rounds→target ~199/200, parity). 고칠 오염 없을 때 가중이 수렴을 해치지 않음 .
③ 탐지	free-rider: LLM AUROC 1.0(전 α) 이나 N=100 CNN 서 0.4(상충 , 한계). noisy: FedDQC 영역 (1.0), Flirds ~0.6. poison: 1 차 회피→ 2 차 부분회복 (1B)· 실패 (3B); loss-heur· 전 탐지기 1.0.

탐지는 위계상 마지막 — 기여도 ≠ 탐지 . clean-val-loss 를 낮추는 공격자를 ϕ 가 ' 기여 높음 ' 으로 보는 것은 valuation 의 정직한 답이며 , 바로 그 지점 (clean-preserving poison) 이 valuation 접근의 경계다 (한계 페이지).

솔직한 항목 (같은 톤으로)

항목	상태	내용
오라클 게임 괴리 (retrain↔in-run)	㉞ 실측	label_skew(이질성) 서 in-run ϕ 가 재학습 가치와 역상관 . 모든 in-run 방법 공유 . 프레이밍 필요 .
free-rider 탐지 상충	㉞ 미해결	동일 zero-delta 가 LLM AUROC 1.0 vs N=100 CNN 0.4(IID 칸 포함). 버그 배제용 드릴다운 필요 .
poison 2 차 불안정	㉞ 잠정	1B 서 1 차 회피 (0.000)→2 차 부분회복하나 run 간 0.42↔0.92(동일 config·seed). 3B(1seed) 선 회복 실패 .
미실행 (deferred)	㉞ 미실행	LLM standard 7B · LLM N=10 retrain oracle · 7B robustness 전반 — 설계상 보류 (3B standard 는 완료).

다음 단계 (제안)

1 차 : 오라클 게임 괴리 (retrain↔in-run) 규명 (ϕ 직접 분석 , 희귀라벨 가설) — 핵심질문 위계상 우선 .
병행 : free-rider CNN-vs-LLM 상충 드릴다운 (버그 / 실재 판별) · poison 2 차 비결정성 재현 확인 .

㉞ 구현 ㉞실측 ㉞미실행 . 잠정 · 미해결치도 결과와 같은 비중으로 기재 .