
Flirds — 연합학습 클라이언트 기여도 측정

실험 결과 보고 — 검증 질문별 구성

방법 : 검증손실의 1 차 +2 차 테일러 전개로 클라이언트 Shapley 추정 (라운드당 HVP 1 회)
구성 : 1 차 Fidelity → 2 차 ① Performance ② Convergence ③ Detection (모델 무관, 질문별 묶음)

실험 개요 — 무엇을 검증했는가 (질문별 분류)

검증 질문	무엇을 확인하나	실험 (무대)
1 차 Fidelity	기여도 (Shapley) 를 오라클 대비 얼마나 정확히 추정하나	CNN C1 (듀얼 오라클 , N=10) · LLM standard (N=20/5) · LLM scale (silo · device · 3B)
2 차 -① Performance	측정한 기여도로 가중 / 선택 시 일반 성능이 오르나 · 무해한가	CNN intervention (N=100, IID · Non-IID) · LLM standard (N=20)
2 차 -② Convergence	수렴 속도 — 목표 도달 라운드 · 최종 손실	LLM standard (N=20)
2 차 -③ Detection	오염 클라이언트를 분리하나 (AUROC)	CNN intervention · LLM cross-silo · cross-device · 3B

핵심 질문 위계 (발표 순서 = 이 순서):

1 차가 가장 기본 — 기여도를 정확히 재는가 . 2 차는 그 기여도의 실효성 (성능 → 수렴 → 탐지 순).
듀얼 오라클 : in-run oracle(학습계적 exact 2ⁿ 분해) · retrain oracle(부분집합 재학습→검증손실). 비교 방법 11 종 + 탐지기 4 종 .
비교 방법이 실험마다 다른 이유 = 다음 장 '적용 범위' 표 (임의 결정 아님 , 실현성 · 비용 · 적용성 규칙).

비교 방법 (valuation) 과 오라클 정의

방법	유형	핵심	라운드당 비용
Flirds (제안)	valuation	검증손실 1 차 +2 차 테일러	HVP 1 회
Flirds-1st	valuation	1 차항만 (곡률 제외)	grad 1 회
loss-heur	heuristic	클라별 손실차	fwd 1 회
GTG / FedSV	Shapley(MC)	truncated/permutation MC	수십-수백 평가
Banzhaf	exact	2^N Banzhaf	2^N 평가
ShapleyFL / ComFedSV	Shapley(변형)	uniform-util / 부분참여	수십-수백
FedIF	influence	검증그래디언트 정렬	grad 1 회
Ripple	2nd-order	고유분해 기반 (이미지만)	eigsh (수십분)
탐지기 4 종	detector	FLDetector·STD-DAGMM·FLTrust·FedDQC	모델 -free/grad

오라클 (정답 기여도)

in-run oracle

학습 궤적을 라운드별 exact Shapley 로 분해 (2^N). 추정량이 재현해야 할 게임 . $N=5$ 에서 2^5 .

retrain oracle

부분집합 S 를 FedAvg 재학습 → 배포모델 검증손실 . ' 배포 가치 ' 게임 . 이미지 $N=10$ 에서 $2^{10}=1024$ 재학습 .

핵심 : Flirds 는 in-run oracle 게임의 추정량 .

retrain oracle 와의 일치는 별개 질문 (1 차 Fidelity).

intervention arm(가중 · 선택 전략) 정의는 2 차 섹션 첫 장 .

실험마다 baseline 이 다른 이유 — 적용 범위 (임의 결정 아님)

비교 방법	CNN-fid N=10	silos N=5	device N=100	3B N=5	std N=20	ref N=5	7B
in-run oracle	●	●	◐	●	●	●	©
retrain oracle	●	○	○	○	○	●	©
Flirds (제안)	●	●	●	●	●	●	©
Flirds-1st	●	●	●	●	●	●	©
loss-heur	●	●	●	●	●	●	©
FedIF	●	●	●	●	●	●	©
GTG (MC Shapley)	●	●	◐	○	●	●	©
FedSV (MC Shapley)	●	●	◐	○	●	●	©
ShapleyFL (MC)	●	●	◐	○	●	●	©
ComFedSV (부분참여)	●	○	●	○	●	●	©
Banzhaf (exact 2 ^N)	●	●	○	○	○	●	©
Ripple (고유분해)	●	○	○	○	○	○	·
탐지기 4 종	○	●	●	●	○	○	©

범례

● 실측 · ◐ $\alpha=0.5$ 기준점만 · ○ 설계상 제외 · © 미실행 (계획) · · 해당없음

가르는 규칙 (4 가지) — 그때그때 정한 게 아님 :

① exact 2^N(Banzhaf·in-run·retrain oracle) 는 N=5/10 만 (N=20/100 불가)

② MC Shapley(GTG/FedSV/ShapleyFL) 는 N=100·3B 서 비용 ↑ → 기준점 / 제외

③ 참여형태 : full(silo·ref)→exact+MC · partial(device·std)→ComFedSV(부분참여)

④ 적용성 : Ripple= 고유분해라 LLM 비용 · 불안정→제외 (이미지만) · 탐지기 = 오염 있는 실험만

in-run oracle 대비 기여도 순위 — 비교 방법 전체 (10 종)

시나리오 (CIFAR / MNIST)	Flirds	Flirds1st	Banzhaf	GTG	FedSV	ComFedSV	ShapleyFL	FedIF	loss-heur	Ripple
CIFAR·iid	0.95	0.54	0.98	0.21	0.22	0.12	0.18	0.45	0.69	0.31
CIFAR·label_skew	0.98	0.92	1.00	0.49	0.53	0.31	0.29	0.68	0.88	0.26
CIFAR·quantity_skew	0.99	0.96	1.00	0.78	0.56	0.67	0.44	-0.20	0.98	0.68
CIFAR·label_flip	1.00	0.95	1.00	0.64	0.54	0.31	0.37	0.74	0.95	0.32
CIFAR·feature_noise	1.00	0.89	1.00	0.59	0.40	0.19	0.20	0.62	0.90	-0.01
CIFAR 평균	0.98	0.85	1.00	0.54	0.45	0.32	0.30	0.46	0.88	0.31
MNIST·iid	0.81	0.78	0.98	0.47	0.04	0.10	0.47	0.73	0.84	0.18
MNIST·label_skew	0.71	0.61	0.98	0.33	-0.01	0.14	-0.02	0.41	0.63	0.06
MNIST·quantity_skew	0.96	0.98	1.00	0.78	0.63	0.49	0.52	-0.07	0.96	0.96
MNIST·label_flip	1.00	0.99	1.00	0.99	0.97	0.95	0.98	0.98	0.99	0.97
MNIST·feature_noise	0.79	0.70	0.95	0.41	0.13	0.21	0.48	0.57	0.78	0.00
MNIST 평균	0.85	0.81	0.98	0.60	0.35	0.38	0.49	0.52	0.84	0.44

명세

MNIST+LeNet5 / CIFAR-10+CNN · N=10 full · R=10 · SGD mom=0 lr0.01 · val=2000 · 3 seed · in-run oracle 2¹⁰

분할 : iid=IID · label_skew·quantity_skew=Non-IID · label_flip·feature_noise=IID 분할 + 손상

지표

Spearman ρ ↑ (오라클 ϕ 대비 순위). 평균 = 데이터셋 단순평균 .
Flirds·Banzhaf 순위 최상 ; MC 기반
GTG/FedSV/ShapleyFL·ComFedSV·Ripple 은 noisy.
2 차항 고유 기여는 순위 아닌 값 - 거리 (retrain 페이지 하단).

iid·feature_noise 는 in-run oracle 신호 약함 (클라 동질). 비교 방법 10 종 전체 (로스터 11 종 = 10 종 + in-run oracle 기준 =1.0). 출처 : runs/track_c/c1/* 재집계 .

retrain oracle (2¹⁰) 대비 순위 , 그리고 in-run 과의 괴리

시나리오	Flirds	Flirds1st	Banzhaf	GTG	FedSV	ComFedSV	ShapleyFL	FedIF	loss-heur	Ripple
CIFAR·iid	-0.23	-0.13	-0.21	-0.20	-0.18	0.30	0.00	0.07	-0.18	-0.20
CIFAR·label_skew	-0.18	-0.07	-0.12	0.44	0.40	0.28	0.12	0.19	0.14	-0.23
CIFAR·quantity_skew	0.57	0.56	0.57	0.70	0.70	0.72	0.81	-0.03	0.57	0.47
CIFAR·label_flip	0.52	0.59	0.51	0.46	0.41	0.32	0.29	0.36	0.58	0.01
CIFAR·feature_noise	0.63	0.50	0.62	0.44	0.18	0.39	0.28	0.40	0.56	-0.12
CIFAR 평균	0.26	0.29	0.27	0.37	0.30	0.40	0.30	0.20	0.34	-0.01
MNIST·iid	0.36	0.52	0.44	0.19	-0.11	-0.10	0.67	0.74	0.48	0.09
MNIST·label_skew	-0.28	-0.06	-0.20	-0.22	-0.14	-0.04	0.28	0.54	-0.16	0.28
MNIST·quantity_skew	0.85	0.77	0.74	0.56	0.69	0.65	0.51	-0.10	0.84	0.74
MNIST·label_flip	0.96	0.97	0.97	0.97	0.96	0.94	0.96	0.96	0.97	0.98
MNIST·feature_noise	0.33	0.44	0.23	0.40	-0.07	-0.07	0.60	0.67	0.44	0.12
MNIST 평균	0.44	0.53	0.44	0.38	0.27	0.27	0.60	0.56	0.51	0.44

핵심 — 게임 정의 차이 (label_skew)

Flirds 는 in-run oracle 은 거의 완벽 재현하나 (in-run 페이지), retrain oracle 와는 label_skew 서 갈림 :

CIFAR in-run 0.98 → retrain -0.18 · MNIST 0.71 → retrain -0.29

추정오차 아님 — 모든 in-run 방법 공유 (희귀라벨 클라는 라운드 한계기여 낮아도 최종 재학습 모델엔 필수).

지표 / 2 차항 효과

Spearman ρ ↑ (retrain oracle ϕ 대비). 평균 = 데이터셋 단순 .
2 차항 : euclid_d(값 - 거리) label_flip CIFAR 0.031 vs 1 차 0.046
(MNIST 0.207 vs 0.370) → 값 오차 1 차 대비 ~25-50% ↓.

기여도 fidelity — in-run oracle 대비 (1B · 3B)

1B (N=20) — 3 seed

방법	Spearman ↑	Kendall ↑	cosine_d ↓	euclid_d ↓	max_diff ↓
Flirds	1.000	1.000	3.5e-07	4.4e-05	2.1e-05
Flirds1st	0.999	0.996	4.4e-05	6.2e-04	2.3e-04
loss-heur	1.000	1.000	2.4e-06	1.3e-04	5.3e-05
GTG	0.975	0.916	7.1e-04	9.8e-04	4.7e-04
FedSV	0.910	0.786	5.7e-03	2.8e-03	1.7e-03
ComFedSV	0.093	0.060	8.4e-01	2.6e-02	9.8e-03
ShapleyFL	0.194	0.133	2.1e-01	2.7e+00	9.9e-01
FedIF	0.157	0.111	1.9e-01	2.6e+00	9.8e-01

명세

- Llama-3.2 1B·3B / alpaca-gpt4 20k (IID, clean)
- N=20, 라운드당 2 개 (partial) · R=200
- local 10 steps × batch16 · lr1e-3 · seq512
- SGD mom=0 · fp32 · eager · val=200
- in-run oracle = per-round exact 분해

3B (N=20) — 2 seed

방법	Spearman ↑	Kendall ↑	cosine_d ↓	euclid_d ↓	max_diff ↓
Flirds	1.000	1.000	8.0e-08	3.6e-05	1.4e-05
Flirds1st	1.000	1.000	2.1e-05	3.8e-04	1.5e-04
loss-heur	1.000	1.000	1.8e-06	7.8e-05	3.7e-05
GTG	0.992	0.958	5.6e-04	1.0e-03	5.3e-04
FedSV	0.944	0.837	3.1e-03	2.4e-03	1.5e-03
ComFedSV	-0.133	-0.105	1.0e+00	3.0e-02	1.1e-02
ShapleyFL	0.302	0.211	1.9e-01	2.8e+00	9.9e-01
FedIF	0.338	0.219	1.6e-01	2.6e+00	9.9e-01

지표 / 읽기

Spearman ρ ↑ · Kendall τ ↑ · cosine_d/euclid_d/max_diff ↓

Flirds: in-run $\rho=1.000$ (1B·3B 동일) — 스케일 불변.

2 차항 : cosine_d 3.5e-7 vs 1 차 4.4e-5 (~125× 타이트).

loss-heur 은 순위만 비기고 cosine 은 큼 . ShapleyFL·FedIF·ComFedSV 는 스케일서 fidelity 약함 .

기여도 fidelity — retrain oracle 대비 , 그리고 in-run 과의 일치

1B (N=5) — vs retrain oracle (3 seed)

방법	Spearman ↑	Kendall ↑	cosine_d ↓	euclid_d ↓	max_diff ↓
Flirds	1.000	1.000	2.3e-09	4.8e-05	2.4e-05
Flirds1st	1.000	1.000	2.0e-07	3.1e-04	1.6e-04
Banzhaf	1.000	1.000	3.9e-11	4.0e-06	1.9e-06
loss-heur	1.000	1.000	6.1e-08	2.4e-04	1.2e-04
GTG	1.000	1.000	3.2e-03	2.5e-03	1.8e-03
FedSV	0.700	0.600	5.5e-03	3.6e-03	2.6e-03
ShapleyFL	0.700	0.600	1.9e-01	1.2e+00	9.8e-01
ComFedSV	0.500	0.467	1.3e-01	1.9e-02	1.4e-02
FedIF	0.067	0.067	2.3e-01	1.3e+00	9.8e-01

명세

- Llama-3.2 1B · 3B / alpaca-gpt4 20k (IID, clean)
- N=5, full participation · R=30
- retrain oracle = 2⁵ 부분집합 FedAvg 재학습 → 검증손실
- in-run oracle 도 함께 산출 (듀얼 오라클)
- 1B 3 seed · 3B 2 seed · Banzhaf(2⁵) 실행

3B (N=5) — vs retrain oracle (2 seed)

방법	Spearman ↑	Kendall ↑	cosine_d ↓	euclid_d ↓	max_diff ↓
Flirds	0.950	0.900	3.4e-10	3.9e-05	1.9e-05
Flirds1st	1.000	1.000	6.2e-07	1.1e-04	7.2e-05
loss-heur	1.000	1.000	2.2e-07	8.3e-05	5.1e-05
GTG	1.000	1.000	1.7e-03	1.9e-03	1.5e-03
FedSV	0.700	0.600	4.0e-03	3.1e-03	2.0e-03
ShapleyFL	0.100	0.000	1.9e-01	1.4e+00	9.5e-01
ComFedSV	0.450	0.400	1.4e-01	2.0e-02	1.6e-02
FedIF	0.100	0.100	1.9e-01	1.4e+00	9.8e-01

읽기 — 듀얼 오라클 일치

Flirds: retrain $\rho=1.000$ · in-run $\rho=1.000$ →

IID · clean 서 두 오라클 게임이 일치 .

→ 이미지 label_skew 의 retrain ↔ in-run 괴리는 'Flirds 오차 ' 가 아니라 데이터 이질성 구동임을 확인 .

3B reference 도 Flirds $\rho=1.000$ 유지 (FedSV 0.7).

Shapley 순위 fidelity — N=5 silo · N=100 device · 3B (vs in-run oracle)

방법	silo N=5 ρ noisy $\uparrow$	silo N=5 ρ poison $\uparrow$	device N=100 ρ ($\alpha=0.5$) $\uparrow$	3B N=5 ρ noisy $\uparrow$
Flirds	1.000	0.967	1.000	1.000
Flirds1st	1.000	0.000	1.000	1.000
loss-heur	1.000	1.000	1.000	1.000
Banzhaf	1.000	1.000	-	-
GTG	1.000	0.867	0.784	-
FedSV	1.000	0.367	0.752	-
ShapleyFL	1.000	1.000	0.582	-
ComFedSV	-	-	-0.023	-
FedIF	0.933	0.967	0.721	0.600

명세

- 동일 robustness run 의 ρ 만 모음
(같은 run 의 탐지 AUROC $\rightarrow$ Detection 섹션)
- silo N=5: 1 도메인 / 클라 (Non-IID), 3 seed
- device N=100: Dir($\alpha=0.5$), per-round oracle, 1 seed
- 3B: silo N=5, 1 seed
- 빈칸 (-) = 그 스케일서 미실행 (적용범위 표 :
비싼 method 는 기준점 / 제외 = 비용 게이팅)

지표

Spearman ρ $\uparrow$ (in-run oracle ϕ 대비 순위)

읽기

N=5 서 near-additive $\rightarrow$ 전 방법 $\rho \approx 1.000$;
poison · 스케일에서 분화 :
poison: FedSV 0.367 · 1 차 0.000 (Flirds 0.967 유지)
N=100: GTG 0.78 · FedSV 0.75 · ShapleyFL 0.58 · ComFedSV -0.02
 $\rightarrow$ Flirds · loss-heur 는 전 스케일 $\rho=1.000$ 유지 ;
MC/ 변형 Shapley 는 N $\uparrow$ · poison 서 열화 .

기여도 측정 정확성 — 횡단 요약

측면	결과	근거
순위 vs in-run oracle	Flirds $\rho \approx 1.000$ (전 트랙 · 1B→3B). Banzhaf·loss-heur 도 우수 ; MC-SV 는 noisy	cross-silo·standard 1.000 / 이미지 0.71–1.00
값 - 거리 vs in-run oracle	2 차항이 1 차 대비 값오차 $\sim 2\times$ 축소 ; loss-heur 은 순위만 비기고 크기는 빗나감	euclid_d: 이미지 $\sim 0.5\times$ · standard cosine 125 $\times$
순위 vs retrain oracle	IID·clean 은 1.000 일치 ; label_skew(이질성) 에서 in-run oracle 와 괴리 (–)	reference(N=5) 1.000 / 이미지 label_skew –0.18~–0.29
스케일 (N=100)	$\alpha=0.5$ 기준점서 Flirds·1 차 ·loss-heur $\rho=1.000$; GTG/FedSV/ShapleyFL 은 열화	GTG 0.78·FedSV 0.75·ShapleyFL 0.58·ComFedSV –0.02
비용	Flirds 1 HVP/round; in-run oracle exact 의 5–15 $\times$ 저렴 , 동일 순위	cross-silo 106s vs 530s · 3B 251s vs 1240s

한 줄 요약

Flirds 는 in-run oracle 게임을 순위 · 값 모두에서 충실히 , exact 대비 저비용으로 , 1B→3B·N=5→N=100 서 일관되게 재현한다 .
2 차항의 고유 기여는 순위가 아니라 값 - 크기 정밀도 . retrain oracle 게임과의 일치는 데이터 이질성에 의존 (동질↔ label_skew).

intervention arm 정의 — 측정된 기여도를 집계에 어떻게 쓰나

arm	집계 가중 규칙	설명
vanilla	$w \propto n_c$	plain FedAvg (샘플 수만 가중 — baseline)
flirds_mult	$w \propto n_c \cdot s_c$	크기가중 $\times$ Flirds 점수 (soft, 기본형)
flirds_repl	$w \propto s_c$	크기 무시 , 점수로 대체
flirds_add	$w \propto \frac{1}{2} \cdot (s_c / \sum s) + \frac{1}{2} \cdot (n_c / \sum n)$	점수 - 비중과 크기 - 비중 5:5 혼합 ($\lambda=0.5$)
flirds_select	점수 softmax 로 코호트 선발 $\rightarrow$ 저기여 제외	hard selection (S-FedAvg 式)
shapleyfl / fedif	동일 기계 , 점수만 교체	ShapleyFL 라운드 exact Shapley / FedIF 영향함수
sfedavg	자체 점수 softmax 선택	S-FedAvg baseline

'arm' 이란
비교하는 하나의 조건 / 변형 (임상시험 treatment arm).
여기선 ' ϕ 를 어떻게 활용할지 ' 의 각 전략이 한 arm.

점수 s_c
Flirds 추정점수의 EMA ($\beta=0.5$, 높을수록 기여 큼).
clean 에션 점수 평탄 $\rightarrow$ vanilla 로 복귀 = do-no-harm.

LLM standard 표기
 $flirds_w = mult(\beta.5) \cdot flirds_sel = select \cdot$
 $shapleyfl_w \cdot fedif_w (\beta=0.7).$

출처 : codes/flirds/fl/intervene.py rule_weights. repl/add 는 dir1(크기 skew) 서만 mult 와 같림 $\rightarrow$ iid/shard 는 6 arm 공통 , dir1 만 8 arm.

intervention — IID vs Non-IID partition (clean, do-no-harm)

dataset · partition	vanilla	flirds_mult	flirds_select	shapleyfl	fedif	sfedavg
CIFAR-10·iid (IID)	0.648	0.646	0.646	0.647	0.647	0.646
CIFAR-10·dir1 (Non-IID)	0.638	0.642	0.634	0.635	0.637	0.631
CIFAR-10·shard (Non-IID 강)	0.475	0.498	0.417	0.496	0.474	0.487
FMNIST·iid (IID)	0.856	0.856	0.858	0.858	0.855	0.858
FMNIST·dir1 (Non-IID)	0.812	0.829	0.846	0.842	0.813	0.838
FMNIST·shard (Non-IID 강)	0.686	0.717	0.672	0.733	0.683	0.712

명세

- CIFAR-10 / FMNIST + CNN · N=100
- C=0.1 (라운드당 10) · R=120 · lr0.01
- partition iid(IID) · dir1(Dir $\alpha=1$) · shard(2 클래스 / 클라)
- clean = 위협 없음 → do-no-harm 검증 · 3 seed
- arm 6 종 = iid/shard 공통 (dir1 만 repl/add 추가)

지표

test acc ↑ (오염 없음 → 탐지 AUROC 없음)

비교 대상 = intervention arm(가중 · 선택 전략)

읽기

clean: 전 **weighting arm** $\approx$ **vanilla** → 분할 무관 무해 .
(CIFAR shard 만 flirds_select<vanilla = hard-drop 부작용)

분할 난이도가 절대 정확도를 지배 (shard= 극단 Non-IID):
CIFAR 0.65→0.48 · FMNIST 0.86→0.69.

→ **가중은 어느 분할에서도 clean 성능을 해치지 않음 .**

intervention — under threat (CIFAR-10, dir1=Non-IID, 8 arm)

arm	clean	grad_noise	label_flip	free_rider	위협평균 acc
vanilla	0.638 (-)	0.245 (-)	0.515 (-)	0.587 (-)	0.449
flirds_mult	0.642 (-)	0.433 (0.99)	0.585 (0.93)	0.597 (0.39)	0.538
flirds_repl	0.639 (-)	0.370 (0.99)	0.579 (0.95)	0.593 (0.41)	0.514
flirds_add	0.640 (-)	0.333 (0.98)	0.560 (0.97)	0.593 (0.48)	0.495
flirds_select	0.634 (-)	0.313 (0.99)	0.559 (0.91)	0.589 (0.48)	0.487
shapleyfl	0.635 (-)	0.550 (1.00)	0.568 (0.96)	0.560 (0.00)	0.559
fedif	0.637 (-)	0.527 (1.00)	0.567 (0.96)	0.611 (1.00)	0.568
sfedavg	0.631 (-)	0.243 (1.00)	0.521 (0.94)	0.587 (0.04)	0.450

명세

- CIFAR-10 + CNN · N=100, C=0.1 · R=120
- partition dir1 (Dirichlet $\alpha=1$, Non-IID)
- arm 8 종 (앞 장 정의)
- strength sweep: grad0.05 · flip0.6/0.8 별도

지표

값 = test acc ↑ · () = 탐지 AUROC ↑
clean = 위협 無 → (-) · 위협평균 = 오염 3 종 acc

읽기

under threat: 전 weighting arm > vanilla.
grad_noise: shapleyfl0.550 · fedif0.527 최고
> flirds_mult0.433 (vanilla 0.245).
label_flip: flirds_mult0.585 최고 .
free_rider: fedif AUROC0.996, flirds0.385(약).
→ **soft(mult) > hard(select). robust+ 무해 ,**
정확도 최고는 위협별로 갈림 .

intervention arm — MMLU · ROUGE-L · 수렴 (standard 1B N=20)

arm	MMLU (0-shot) ↑	ROUGE-L ↑	final val-loss ↓	rounds→target ↓
base	0.4822	0.2168	–	–
vanilla	0.4742	0.2841	1.2653	200
flirds_w	0.4745	0.2848	1.2653	199
flirds_sel	0.4739	0.2838	1.2654	199
shapleyfl_w	0.4742	0.2845	1.2653	199
fedif_w	0.4741	0.2847	1.2652	198

명세

- Llama-3.2-1B / alpaca-gpt4 20k (IID)
- standard N=20, 2/round · R=200
- 10 steps×batch16 · lr1e-3 · seq512
- arm 6 종 · 3 seed · clean·IID
- 3B 는 N=20 intervention 미실행 (N=5 reference 만)

지표

MMLU(0-shot) ↑ · ROUGE-L ↑ ① Performance
final val-loss ↓ · rounds→target ↓ ② Convergence

읽기

base = 학습 전 . FL-SFT 후 ROUGE-L +0.067
(0.217→0.284), MMLU -0.008.
전 weighting arm ≈ vanilla (±0.001, ±1 라운드).
→ clean·IID 서 do-no-harm parity 확인
(고칠 오염 없을 때 성능 · 수렴 무해).

오염 클라 탐지 AUROC (Non-IID 5 도메인)

방법	noisy ↑	fr-rand ↑	fr-zero ↑	poison ↑	평균 ↑	런타임 ↓
in-run oracle	1.000	1.000	1.000	1.000	1.000	532s
Flirds	1.000	1.000	1.000	0.917	0.979	106s
Flirds1st	1.000	1.000	1.000	0.000	0.750	35s
FedIF	1.000	1.000	1.000	1.000	1.000	35s
GTG	1.000	1.000	1.000	1.000	1.000	538s
FedSV	1.000	1.000	1.000	1.000	1.000	533s
ShapleyFL	1.000	1.000	1.000	1.000	1.000	530s
Banzhaf	1.000	1.000	1.000	1.000	1.000	533s
loss-heur	1.000	1.000	1.000	1.000	1.000	164s
FLDetector	0.750	1.000	0.750	1.000	0.875	30s
STD-DAGMM	0.417	1.000	0.250	0.750	0.604	136s
FLTrust	1.000	1.000	1.000	1.000	1.000	36s
FedDQC	0.917	0.750	0.750	1.000	0.854	22s

명세

- Llama-3.2-1B(+3B) LoRA · N=5
- 1 도메인 / 클라 → Non-IID
- R=10 · val=100 · lr1e-3(poison 2e-3)
- fp32 · eager · 3 seed
- 위협 : noisy(품질)/fr(zero,random)/poison(백도어 스케일교체)

지표

AUROC ↑ (오염 = 높은 의심점수 분리 , 1.0= 완전)

평균 = 4 위협 단순평균 · 런타임 ↓

fidelity(p) 는 1 차 Fidelity · LLM scale 페이지

읽기

noisy·free-rider: 전 valuation AUROC 1.0
(N=5 near-additive); 우위 = 비용 .

poison ASR≈1.0: Flirds-1st 0.000 완전회피 → 2 차 0.917 회복 (불안정). loss-heur· 전 탐지기 1.0.

α-sweep 탐지 AUROC (α = 분할 이질성)

noisy 탐지 AUROC ↑ (α-sweep)

방법	α=0.0	α=0.01	α=0.1	α=0.5	α=5.0	평균
Flirds	0.774	0.575	0.605	0.604	0.596	0.631
FedIF	0.973	0.568	0.693	0.830	0.973	0.807
STD-DAGMM	0.856	0.652	0.659	0.671	0.760	0.720
FLTrust	1.000	0.602	0.720	0.854	0.994	0.834
FedDQC	0.960	1.000	1.000	1.000	1.000	0.992
FLDetector	0.535	0.482	0.525	0.539	0.532	0.523
ComFedSV	0.442	0.419	0.432	0.371	0.396	0.412

명세

- Llama-3.2-1B LoRA · N=100, K=10/round · R=30 · 1~3 seed
- 분할 = per-client Dirichlet(α), α∈{0,0.01,0.1,0.5,5.0}
- α = 분할 이질성 : α→0 도메인 분리 (극단 Non-IID), α→∞ 균일혼합 (IID). α=5.0 ≈ near-IID.

poison 탐지 AUROC ↑

방법	α=0.0	α=0.5	평균
Flirds	1.000	1.000	1.000
Flirds1st	1.000	0.670	0.835
loss-heur	1.000	1.000	1.000
FLDetector	0.987	0.983	0.985
STD-DAGMM	1.000	0.983	0.992
FedDQC	1.000	1.000	1.000
FLTrust	0.650	0.498	0.574
FedIF	0.542	0.458	0.500

읽기

free-rider(random · zero, 전 α): Flirds · 1 차 · loss-heur · FLTrust = 1.000.
noisy: FedDQC 영역 (스케일 1.0), Flirds ~0.60.
poison(install): Flirds 1.0(both α), 1 차도 α=0 서 1.0 — 1 차가 회피되지 않음 .

Llama-3.2-3B 탐지 AUROC (Non-IID 5 도메인)

방법	noisy ↑	fr-rand ↑	fr-zero ↑	poison ↑	평균 ↑	런타임 ↓
in-run oracle	1.000	1.000	1.000	1.000	1.000	1240s
Flirds	1.000	1.000	1.000	0.000	0.750	251s
Flirds1st	1.000	1.000	1.000	0.000	0.750	82s
FedIF	1.000	1.000	1.000	1.000	1.000	82s
loss-heur	1.000	1.000	1.000	1.000	1.000	384s
FLDetector	1.000	1.000	1.000	1.000	1.000	250s
STD-DAGMM	0.250	1.000	0.000	0.750	0.500	530s
FLTrust	1.000	1.000	1.000	1.000	1.000	85s
FedDQC	1.000	0.750	0.750	1.000	0.875	49s

명세
· Llama-3.2-3B LoRA · cross-silo N=5
· Non-IID(도메인 분리) · R=10 · seed 1 개 (잠정)
· 비싼 method(Banzhaf/GTG/FedSV/ShapleyFL) 는 3B 서 비용상 미실행 (적용범위 표)

지표
AUROC ↑ · 평균 =4 위협 단순 · 런타임 ↓
fidelity(ρ) 는 1 차 Fidelity · LLM scale 페이지

읽기
noisy·fr: Flirds AUROC 1.0(1B→3B 유지),
251s vs in-run oracle 1240s (~5× ↓).
poison: Flirds·1 차 모두 0.000 — 1B 의 2 차
회복이 3B(1seed) 선 안 나타남 (미확정).
CNN 탐지 (N=100): intervention arm 의 누적 점수로
측정 (전용 탐지기 4 종 미사용) — under-threat 페이지 괄호값 .

① Performance → ② Convergence → ③ Detection

질문	요약
① Performance	under threat 전 weighting arm > vanilla(이미지 , 전 분할). clean/IID 는 무해 parity(이미지 · LLM). 정확도 최고는 위협별로 갈림 — grad_noise 서 shapleyfl/fedif, label_flip 서 flirds. soft>hard. 분할 난이도 (shard<<iid) 가 절대성능을 지배 .
② Convergence	IID·clean(LLM standard) 서 전 arm 동일 수렴 (rounds→target ~199/200, parity). 고칠 오염 없을 때 가중이 수렴을 해치지 않음 .
③ Detection	free-rider: LLM AUROC 1.0(전 α) 이나 N=100 CNN 서 0.4(상충 , 한계). noisy: FedDQC 영역 (1.0), Flirds ~0.6. poison: 1 차 회피→ 2 차 부분회복 (1B)· 실패 (3B); loss-heur· 전 탐지기 1.0.

Detection 은 위계상 마지막 — 기여도≠탐지 . clean-val-loss 를 낮추는 공격자를 ϕ 가 ' 기여 높음 ' 으로 보는 것은 valuation 의 정직한 답이며 , 바로 그 지점 (clean-preserving poison) 이 valuation 접근의 경계다 (한계 페이지).

솔직한 항목 (같은 톤으로)

항목	상태	내용
오라클 게임 괴리 (retrain↔in-run)	㉞ 실측	label_skew(이질성) 서 in-run ϕ 가 재학습 가치와 역상관 . 모든 in-run 방법 공유 . 프레이밍 필요 .
free-rider 탐지 상충	㉞ 미해결	동일 zero-delta 가 LLM AUROC 1.0 vs N=100 CNN 0.4(IID 칸 포함). 버그 배제용 드릴다운 필요 .
poison 2 차 불안정	㉞ 잠정	1B 서 1 차 회피 (0.000)→2 차 부분회복하나 run 간 0.42↔0.92(동일 config·seed). 3B(1seed) 선 회복 실패 .
미실행 (deferred)	㉞ 미실행	LLM standard 7B · LLM N=10 retrain oracle · 7B robustness 전반 — 설계상 보류 (3B standard 는 완료).

다음 단계 (제안)

- 1 차 : 오라클 게임 괴리 (retrain↔in-run) 규명 (ϕ 직접 분석 , 희귀라벨 가설) — 핵심질문 위계상 우선 .
- 병행 : free-rider CNN-vs-LLM 상충 드릴다운 (버그 / 실재 판별) · poison 2 차 비결정성 재현 확인 .

㉠ 구현 ㉞실측 ㉞미실행 . 잠정 · 미해결치도 결과와 같은 비중으로 기재 .