
Flirds — 연합학습 클라이언트 기여도 측정

실험 결과 보고 (이미지 · 언어모델)

방법 : 검증손실의 1 차 +2 차 테일러 전개로 클라이언트 Shapley 추정 (라운드당 HVP 1 회)
client-level FL Shapley via 1st+2nd-order Taylor of validation loss

실험 개요 — 세 트랙, 모두 완료

트랙	도메인 / 모델	연합 셋업	셀	seed	핵심 산출
Image (CNN)	MNIST+LeNet5 / CIFAR-10+CNN	N=10 (fidelity) · N=100 (intervention)	150	3	fidelity (retrain+in-run oracle) · 개입 8arm
LLM robustness	Llama-3.2 1B · 3B (LoRA)	N=5 cross-silo · N=100 cross-device(α)	25	1-3	4 threat × fidelity · 탐지 · 개입
LLM standard (clean · IID)	Llama-3.2-1B / OpenFedLLM	N=20 standard · N=5 reference	6	3	IID · clean fidelity · 성능 · 수렴

핵심 질문 위계 (모든 표 · 서술 순서에 적용):

- 1 차 — 기여도를 얼마나 정확히 측정하는가 (오라클 대비 fidelity: Spearman · Kendall · 값 - 거리)
- 2 차 — 측정한 기여도의 실효성 : ① 일반 성능 → ② 수렴 속도 → ③ 오염 클라 탐지 (이 순서)
- 비교 대상 11 종 + 탐지기 4 종 / 듀얼 오라클 : retrain oracle(부분집합 재학습 → 검증손실), in-run oracle(학습계적 exact 2^N 분해).
- 명세 · 지표 범례는 각 결과 페이지의 표 옆 / 아래에 병기 (별도 명세 페이지 없음).

비교 방법 11 종과 오라클 정의 (공용)

방법	유형	핵심	라운드당 비용
Flirds (제안)	valuation	검증손실 1 차 +2 차 테일러	HVP 1 회
Flirds-1st	valuation	1 차항만 (곡률 제외)	grad 1 회
loss-heur	heuristic	클라별 손실차	fwd 1 회
GTG / FedSV	Shapley(MC)	truncated/permutation MC	수십-수백 평가
Banzhaf	exact	2^N Banzhaf	2^N 평가
ShapleyFL / ComFedSV	Shapley(변형)	uniform-util / 부분합	수십-수백
FedIF	influence	검증그래디언트 정렬	grad 1 회
Ripple	2nd-order	고유분해 기반 (이미지만)	eigsh (수십분)
탐지기 4 종	detector	FLDetector·STD-DAGMM·FLTrust·FedDQC	모델 -free/grad

오라클 (정답 기여도)

in-run oracle

학습 궤적을 라운드별 exact Shapley 로 분해 (2^N). 추정량이 재현해야 할 게임 . $N=5$ 에서 2^5 .

retrain oracle

부분집합 S 를 FedAvg 재학습 → 배포모델 검증손실 . ' 배포 가치 ' 게임 . 이미지 $N=10$ 에서 $2^{10}=1024$ 재학습 .

핵심 : Flirds 는 in-run oracle 게임의 추정량 .

retrain oracle 와의 일치 여부는 'in-run 게임 = 재학습 게임 ' 인지를 묻는 별개 질문 (이미지 fidelity 페이지 · 한계 참조).

in-run oracle 대비 기여도 순위

시나리오 (CIFAR / MNIST)	Flirds	Flirds1st	Banzhaf	GTG	FedSV	loss-heur
CIFAR · iid	0.95	0.54	0.98	0.21	0.22	0.69
CIFAR · label_skew	0.98	0.92	1.00	0.49	0.53	0.88
CIFAR · quantity_skew	0.99	0.96	1.00	0.78	0.56	0.98
CIFAR · label_flip	1.00	0.95	1.00	0.64	0.54	0.95
CIFAR · feature_noise	1.00	0.89	1.00	0.59	0.40	0.90
CIFAR 평균	0.98	0.85	1.00	0.54	0.45	0.88
MNIST · iid	0.81	0.78	0.98	0.47	0.04	0.84
MNIST · label_skew	0.71	0.61	0.98	0.33	-0.01	0.63
MNIST · quantity_skew	0.96	0.98	1.00	0.78	0.63	0.96
MNIST · label_flip	1.00	0.99	1.00	0.99	0.97	0.99
MNIST · feature_noise	0.79	0.70	0.95	0.41	0.13	0.78
MNIST 평균	0.85	0.81	0.98	0.60	0.35	0.84

명세

- MNIST+LeNet5 / CIFAR-10+CNN
- N=10 full · R=10 · epochs=5
- SGD mom=0 lr0.01 b64 · val=2000
- 시나리오 5 종 · 3 seed
- in-run oracle = 궤적 exact 2¹⁰

지표

Spearman ρ ↑ 순위상관 (오라클 ϕ 대비)
euclid_d ↓ 값 - 크기 오차 (아래 수치)

읽기

2 차항 효과 — euclid_d (label_flip)
CIFAR 0.031 vs 1 차 0.046
MNIST 0.207 vs 1 차 0.370
→ 값 오차 1 차대비 ~25-50% ↓ (전 시나리오)
순위는 Flirds · Banzhaf · loss-heur 우수 ;
MC 기반 GTG/FedSV 는 noisy → Flirds 우위 = 비용 .

표 = Spearman ρ ↑ (3-seed). 평균 = 시나리오 단순평균 (iid · feature_noise 는 in-run oracle 신호 약함). 출처 : runs/track_c/c1/*. 내부코드 fidelity=C1.

retrain oracle 대비 , 그리고 in-run 과의 괴리

시나리오	Flirds in-run	Flirds retrain	1st retrain	GTG retrain	loss-h retrain
CIFAR · iid	0.95	-0.23	-0.13	-0.20	-0.18
CIFAR · label_skew	0.98	-0.18	-0.07	0.44	0.14
CIFAR · quantity_skew	0.99	0.57	0.56	0.70	0.57
CIFAR · label_flip	1.00	0.52	0.59	0.46	0.58
CIFAR · feature_noise	1.00	0.63	0.50	0.44	0.56
CIFAR 평균	0.98	0.26	0.29	0.37	0.34
MNIST · iid	0.81	0.36	0.52	0.19	0.48
MNIST · label_skew	0.71	-0.28	-0.06	-0.22	-0.16
MNIST · quantity_skew	0.96	0.85	0.77	0.56	0.84
MNIST · label_flip	1.00	0.96	0.97	0.97	0.97
MNIST · feature_noise	0.79	0.33	0.44	0.40	0.44
MNIST 평균	0.85	0.44	0.53	0.38	0.51

명세

- fidelity 셋업 동일 (N=10 · R=10)
- retrain oracle: 부분집합 S FedAvg 재학습 → 배포모델 검증손실 (2^{10})
- efficiency-gap $\leq 1e-15$ (전 셀)

지표

Spearman $\rho \uparrow$ (오라클 종류만 다름)
in-run = 궤적 분해 · retrain = 재학습 가치

읽기

핵심 — 게임 정의 차이

Flirds 는 in-run oracle 거의 완벽 재현 ;
label_skew 서 두 오라클이 같림 :

CIFAR in-run 0.98 → retrain -0.18
MNIST in-run 0.71 → retrain -0.29

추정오차 아님 — 모든 in-run 공유 한계
(회귀라벨 클라 : 라운드 한계기여 낮아도
최종 재학습 모델엔 필수).

표 = Spearman $\rho \uparrow$. retrain 열 = rho_a_mean(3-seed). reference(N=5, LLM standard) 는 retrain oracle 와 1.000 일치 → 괴리는 이질성 구동 . 내부코드 retrain oracle=(a).

개입 결과 (CIFAR-10, dir1)

arm	clean	grad_noise	label_flip	free_rider	위협평균 acc
vanilla	0.638 (-)	0.245 (-)	0.515 (-)	0.587 (-)	0.449
flirds_mult	0.642 (-)	0.433 (0.99)	0.585 (0.93)	0.597 (0.39)	0.538
flirds_select	0.634 (-)	0.313 (0.99)	0.559 (0.91)	0.589 (0.48)	0.487
shapleyfl	0.635 (-)	0.550 (1.00)	0.568 (0.96)	0.560 (0.00)	0.559
fedif	0.638 (-)	0.527 (1.00)	0.567 (0.96)	0.611 (1.00)	0.568

명세

- CIFAR-10/FMNIST + CNN
- N=100, C=0.1(10/round) · R=120
- epochs=5 lr0.01 · target acc=0.6
- partition×threat · 개입 arm 8 종 · 3 seed
- 표 = CIFAR-10 · dir1

지표

값 = test acc ↑
() = 탐지 AUROC ↑ (오염 분리도)
clean = 위협 無 → (-)
위협평균 = 오염 3 종 acc 평균

읽기

clean: 전 arm ≈ vanilla (무해 확인).
grad_noise: shapleyfl0.550 · fedif0.527
> flirds_mult0.433 (모두 >vanilla0.245).
label_flip: flirds_mult0.585 최고 .
free_rider: fedif AUROC0.996 vs flirds0.385.
→ **robust+** 무해하나 정확도 최고는 아님 ;
soft(mult) > hard(select).

탐지 · 기여도 · 런타임

방법	noisy ↑	fr-rand ↑	fr-zero ↑	poison ↑	평균 ↑	ρ noisy ↑	ρ poison ↑	런타임 ↓
in-run oracle	1.000	1.000	1.000	1.000	1.000	–	–	532s
Flirds	1.000	1.000	1.000	0.917	0.979	1.00	0.97	106s
Flirds1st	1.000	1.000	1.000	0.000	0.750	1.00	0.00	35s
FedIF	1.000	1.000	1.000	1.000	1.000	0.93	0.97	35s
GTG	1.000	1.000	1.000	1.000	1.000	1.00	0.87	538s
FedSV	1.000	1.000	1.000	1.000	1.000	1.00	0.37	533s
ShapleyFL	1.000	1.000	1.000	1.000	1.000	1.00	1.00	530s
Banzhaf	1.000	1.000	1.000	1.000	1.000	1.00	1.00	533s
loss-heur	1.000	1.000	1.000	1.000	1.000	1.00	1.00	164s
FLDetector	0.750	1.000	0.750	1.000	0.875	–	–	30s
STD-DAGMM	0.417	1.000	0.250	0.750	0.604	–	–	136s
FLTrust	1.000	1.000	1.000	1.000	1.000	–	–	36s
FedDQC	0.917	0.750	0.750	1.000	0.854	–	–	22s

명세

- Llama-3.2-1B(+3B) LoRA · N=5
- 1 도메인 / 클라 · R=10 · val=100
- SGD mom=0 lr1e-3 (poison 2e-3)
- fp32 · eager · 3 seed
- in-run oracle = 궤적 exact 2⁵
- 위험 : noisy(품질)/fr(zero,random)/
poison(백도어 스케일교체)

지표

AUROC ↑ · ρ ↑ (vs in-run oracle) · 런타임 ↓

평균 = 4 위험 AUROC 단순평균

읽기

noisy·fr: 전 valuation 1.000, AUROC 1.0
(N=5 near-additive 동률); 우위 = 비용 .

poison ASR≈1.0: 1 차 0.000 완전회피 →
2 차 0.917 회복 (불안정); FedSV ρ 0.37.

α -sweep 탐지 AUROC

noisy 탐지 AUROC ↑ (α -sweep)

방법	$\alpha=0.0$	$\alpha=0.01$	$\alpha=0.1$	$\alpha=0.5$	$\alpha=5.0$	평균
Flirds	0.774	0.575	0.605	0.604	0.596	0.631
FedIF	0.973	0.568	0.693	0.830	0.973	0.807
STD-DAGMM	0.856	0.652	0.659	0.671	0.760	0.720
FLTrust	1.000	0.602	0.720	0.854	0.994	0.834
FedDQC	0.960	1.000	1.000	1.000	1.000	0.992
FLDetector	0.535	0.482	0.525	0.539	0.532	0.523
ComFedSV	0.442	0.419	0.432	0.371	0.396	0.412

명세

- Llama-3.2-1B LoRA · N=100, K=10/round · R=30
- per-client $\text{Dir}(\alpha)$, $\alpha \in \{0, 0.01, 0.1, 0.5, 5.0\}$ · 1-3 seed
- in-run oracle per-round exact (기준점 $\alpha=0.5$)

지표

AUROC ↑ (α 별) · 평균 = α 점 단순평균

poison 탐지 AUROC ↑

방법	$\alpha=0.0$	$\alpha=0.5$	평균
Flirds	1.000	1.000	1.000
Flirds1st	1.000	0.670	0.835
loss-heur	1.000	1.000	1.000
FLDetector	0.987	0.983	0.985
STD-DAGMM	1.000	0.983	0.992
FedDQC	1.000	1.000	1.000
FLTrust	0.650	0.498	0.574
FedIF	0.542	0.458	0.500

읽기

free-rider(random · zero, 전 α): Flirds · 1 차 ·
loss-heur · FLTrust = 1.000.
noisy: FedDQC 영역 (스케일 1.0), Flirds ~0.60;
fidelity 는 1 차 · loss-heur p=1.000(전 α),
기준점 GTG0.78 · FedSV0.75 · ShapleyFL0.58 · FedIF0.72.
poison(install): Flirds 1.0(both α), 1 차도
 $\alpha=0$ 서 1.0 — 1 차가 회피되지 않음 .

Llama-3.2-3B — 탐지 · 기여도 · 런타임

방법	noisy ↑	fr-rand ↑	fr-zero ↑	poison ↑	평균 ↑	ρ noisy ↑	ρ poison ↑	런타임 ↓
in-run oracle	1.000	1.000	1.000	1.000	1.000	–	–	1240s
Flirds	1.000	1.000	1.000	0.000	0.750	1.00	0.00	251s
Flirds1st	1.000	1.000	1.000	0.000	0.750	1.00	0.00	82s
FedIF	1.000	1.000	1.000	1.000	1.000	0.60	0.60	82s
loss-heur	1.000	1.000	1.000	1.000	1.000	1.00	1.00	384s
FLDetector	1.000	1.000	1.000	1.000	1.000	–	–	250s
STD-DAGMM	0.250	1.000	0.000	0.750	0.500	–	–	530s
FLTrust	1.000	1.000	1.000	1.000	1.000	–	–	85s
FedDQC	1.000	0.750	0.750	1.000	0.875	–	–	49s

명세
· Llama-3.2-3B LoRA · cross-silo N=5
· R=10 · 나머지 1B 와 동일
· seed 1 개 → 잡정

지표
AUROC ↑ · ρ ↑ (vs in-run oracle) · 런타임 ↓
평균 = 4 위협 AUROC 단순평균

읽기
noisy·fr: Flirds ρ =1.000 유지 (1B→3B),
251s vs in-run oracle 1240s (~5× ↓).
poison: Flirds·1 차 모두 0.000 — 1B 의 2 차
회복이 3B(1seed) 선 안 나타남 (미확정).
FedIF ρ 0.600(1B 0.90 ↓). loss-heur· 탐지기 1.0.

기여도 fidelity — 듀얼 오라클 (3-seed 평균)

standard (N=20) — vs in-run oracle

방법	Spearman ↑	Kendall ↑	cosine_d ↓	euclid_d ↓	max_diff ↓
Flirds	1.000	1.000	3.5e-07	4.4e-05	2.1e-05
Flirds1st	0.999	0.996	4.4e-05	6.2e-04	2.3e-04
loss-heur	1.000	1.000	2.4e-06	1.3e-04	5.3e-05
GTG	0.975	0.916	7.1e-04	9.8e-04	4.7e-04
FedSV	0.910	0.786	5.7e-03	2.8e-03	1.7e-03
ComFedSV	0.093	0.060	8.4e-01	2.6e-02	9.8e-03
ShapleyFL	0.194	0.133	2.1e-01	2.7e+00	9.9e-01
FedIF	0.157	0.111	1.9e-01	2.6e+00	9.8e-01

명세

- Llama-3.2-1B / alpaca-gpt4 20k (IID) · 3 seed
- standard N=20(2/round) R=200 → in-run oracle
- reference N=5(full) R=30 → retrain oracle(2⁵)

지표

Spearman ρ ↑ · Kendall τ ↑ · cosine_d/euclid_d/max_diff ↓

reference (N=5) — vs retrain oracle

방법	Spearman ↑	Kendall ↑	cosine_d ↓	euclid_d ↓	max_diff ↓
Flirds	1.000	1.000	2.3e-09	4.8e-05	2.4e-05
Flirds1st	1.000	1.000	2.0e-07	3.1e-04	1.6e-04
Banzhaf	1.000	1.000	3.9e-11	4.0e-06	1.9e-06
loss-heur	1.000	1.000	6.1e-08	2.4e-04	1.2e-04
GTG	1.000	1.000	3.2e-03	2.5e-03	1.8e-03
FedSV	0.700	0.600	5.5e-03	3.6e-03	2.6e-03
ShapleyFL	0.700	0.600	1.9e-01	1.2e+00	9.8e-01
ComFedSV	0.500	0.467	1.3e-01	1.9e-02	1.4e-02
FedIF	0.067	0.067	2.3e-01	1.3e+00	9.8e-01

읽기

**Flirds: in-run ρ=1.000(cosine_d 3.5e-7) ·
retrain ρ=1.000 — IID·clean 서 두 오라클
게임 일치 → 이미지 괴리는 이질성 구동 .**

2 차항 : cosine_d 3.5e-7 vs 1 차 4.4e-5 (~125× ↓).
ShapleyFL·FedIF·ComFedSV 는 스케일서 fidelity 약함 .

개입 arm — MMLU · ROUGE-L · 수렴

arm	MMLU (0-shot) ↑	ROUGE-L ↑	final val-loss ↓	rounds→target ↓
base	0.4822	0.2168	–	–
vanilla	0.4742	0.2841	1.2653	200
flirds_w	0.4745	0.2848	1.2653	199
flirds_sel	0.4739	0.2838	1.2654	199
shapleyfl_w	0.4742	0.2845	1.2653	199
fedif_w	0.4741	0.2847	1.2652	198

명세

- Llama-3.2-1B / alpaca-gpt4 20k (IID)
- standard N=20, 2/round · R=200
- 10 steps×batch16 · lr1e-3 · seq512
- 개입 arm 6 종 · 3 seed · clean·IID

지표

MMLU(0-shot) ↑ · ROUGE-L ↑ 성능
final val-loss ↓ · rounds→target ↓ 수렴

읽기

base = 학습 전 . FL-SFT 후 ROUGE-L +0.067
(0.217→0.284), MMLU +0.008.
전 가중 arm ≈ vanilla (±0.001, ±1 라운드).
→ **clean·IID 서 do-no-harm parity 확인**
(**고칠 오염 없을 때 성능 · 수렴 무해**).

기여도 측정 정확성 — 트랙 횡단 요약

측면	결과	근거
순위 vs in-run oracle	Flirds $p \approx 1.000$ (전 트랙). Banzhaf·loss-heur 도 우수 ; MC-SV 는 noisy	cross-silo·standard 1.000 / 이미지 0.71–1.00
값 - 거리 vs in-run oracle	2 차항이 1 차 대비 값오차 $\sim 2\times$ 축소 ; loss-heur 은 순위만 비기고 크기는 빗나감	euclid_d: 이미지 $\sim 0.5\times$ · standard cosine 125 $\times$
순위 vs retrain oracle	IID·clean 은 1.000 일치 ; label_skew(이질성) 에서 in-run oracle 와 괴리 (-)	reference(N=5) 1.000 / 이미지 label_skew -0.18~-0.29
비용	Flirds 1 HVP/round; in-run oracle exact 의 5–15 $\times$ 저렴 , 동일 순위	cross-silo 106s vs 530s · 3B 251s vs 1240s

한 줄 요약

Flirds 는 in-run oracle 게임을 순위 · 값 모두에서 충실히 , exact 대비 저비용으로 재현한다 . 2 차항의 고유 기여는 순위가 아니라 값 - 크기 정밀도 . retrain oracle 게임과의 일치는 데이터 이질성에 의존 — 동질이면 일치 , label_skew 면 갈림 .

retrain oracle 괴리는 Flirds 특정 오차가 아니라 모든 in-run 방법 공유 . 상세 : 이미지 fidelity·LLM standard fidelity 페이지 .

① 일반 성능 → ② 수렴 → ③ 탐지

질문	요약
① 일반 성능	오염 하 전 가중 arm > vanilla(이미지). clean/IID 는 무해 parity(이미지 · LLM). 정확도 최고는 아님 — grad_noise 서 shapleyfl/fedif 우위 , label_flip 서 flirds 우위 . soft>hard.
② 수렴	IID · clean(LLM standard) 서 전 arm 동일 수렴 (rounds→target ~199/200, parity). 고칠 오염 없을 때 가중이 수렴을 해치지 않음 .
③ 탐지	free-rider: LLM AUROC 1.0(전 α) 이나 N=100 CNN 서 0.4(상충 , 한계). noisy: FedDQC 영역 (1.0), Flirds ~0.6. poison: 1 차 회피→ 2 차 부분회복 (1B) · 실패 (3B); loss-heur · 전 탐지기 1.0.

탐지는 위계상 마지막 — 기여도 ≠ 탐지 . clean-val-loss 를 낮추는 공격자를 ϕ 가 ' 기여 높음 ' 으로 보는 것은 valuation 의 정직한 답이며 , 바로 그 지점 (clean-preserving poison) 이 valuation 접근의 경계다 (한계 페이지).

솔직한 항목 (같은 톤으로)

항목	상태	내용
오라클 게임 괴리 (retrain↔in-run)	㉞ 실측	label_skew(이질성) 서 in-run ϕ 가 재학습 가치와 역상관 . 모든 in-run 방법 공유 . 프레이밍 필요 .
free-rider 탐지 상충	㉞ 미해결	동일 zero-delta 가 LLM AUROC 1.0 vs N=100 CNN 0.4(IID 칸 포함). 버그 배제용 드릴다운 필요 .
poison 2 차 불안정	㉞ 잠정	1B 서 1 차 회피 (0.000)→2 차 부분회복하나 run 간 0.42↔0.92(동일 config·seed). 3B(1seed) 선 회복 실패 .
미실행 (deferred)	㉞ 미실행	LLM standard 3B/7B · LLM N=10 retrain oracle · 7B 전반 — 설계상 보류 .

다음 단계 (제안)

1 차 : 오라클 게임 괴리 (retrain↔in-run) 규명 (ϕ 직접 분석 , 희귀라벨 가설) — 핵심질문 위계상 우선 .
병행 : free-rider CNN-vs-LLM 상충 드릴다운 (버그 / 실재 판별) · poison 2 차 비결정성 재현 확인 .

㉞ 구현 ㉞실측 ㉞미실행 . 잠정 · 미해결치도 결과와 같은 비중으로 기재 .