
Flirds — 연합학습 클라이언트 기여도 측정

실험 결과 보고 (이미지 · 언어모델)

방법 : 검증손실의 1 차 +2 차 테일러 전개로 클라이언트 Shapley 추정 (라운드당 HVP 1 회)
client-level FL Shapley via 1st+2nd-order Taylor of validation loss

실험 개요 — 세 트랙, 모두 완료

트랙	도메인 / 모델	연합 셋업	셀	seed	핵심 산출
Image (CNN)	MNIST+LeNet5 / CIFAR-10+CNN	N=10 (fidelity) · N=100 (intervention)	150	3	fidelity (retrain+in-run oracle) · 개입 8arm
LLM robustness	Llama-3.2 1B · 3B (LoRA)	N=5 cross-silo · N=100 cross-device(α)	25	1-3	4 threat × fidelity · 탐지 · 개입
LLM standard (clean · IID)	Llama-3.2-1B / OpenFedLLM	N=20 standard · N=5 reference	6	3	IID · clean fidelity · 성능 · 수렴

핵심 질문 위계 (모든 표 · 서술 순서에 적용):

- 1 차 — 기여도를 얼마나 정확히 측정하는가 (오라클 대비 fidelity: Spearman · Kendall · 값 - 거리)
- 2 차 — 측정한 기여도의 실효성 : ① 일반 성능 → ② 수렴 속도 → ③ 오염 클라 탐지 (이 순서)
- 비교 대상 11 종 + 탐지기 4 종 / 듀얼 오라클 : retrain oracle(부분집합 재학습→검증손실), in-run oracle(학습계적 exact 2^N 분해).

비교 방법 11 종과 오라클 정의

방법	유형	핵심	라운드당 비용
Flirds (제안)	valuation	검증손실 1 차 +2 차 테일러	HVP 1 회
Flirds-1st	valuation	1 차항만 (곡률 제외)	grad 1 회
loss-heur	heuristic	클라별 손실차	fwd 1 회
GTG / FedSV	Shapley(MC)	truncated/permutation MC	수십-수백 평가
Banzhaf	exact	2^N Banzhaf	2^N 평가
ShapleyFL / ComFedSV	Shapley(변형)	uniform-util / 부분합	수십-수백
FedIF	influence	검증그래디언트 정렬	grad 1 회
Ripple	2nd-order	고유분해 기반 (이미지만)	eigsh (수십분)
탐지기 4 종	detector	FLDetector·STD-DAGMM·FLTrust·FedDQC	모델 -free/grad

오라클 (정답 기여도)

in-run oracle

학습 궤적을 라운드별 exact Shapley 로 분해 (2^N). 추정량이 재현해야 할 게임 . $N=5$ 에서 2^5 .

retrain oracle

부분집합 S 를 FedAvg 재학습 → 배포모델 검증손실 . ' 배포 가치 ' 게임 . 이미지 $N=10$ 에서 $2^{10}=1024$ 재학습 .

핵심 : Flirds 는 in-run oracle 게임의 추정량 .

retrain oracle 와의 일치 여부는 'in-run 게임 = 재학습 게임 ' 인지를 묻는 별개 질문 (S8·S18 에서 다룸).

출처 : codes/core·oracle·baselines. 모든 valuation 은 동일 $\log s=[(w_r, \{client:(\Delta,n_c)\})]$ 위에서 계산 (모델 · 검증셋 비접근).

평가 지표

질문	지표	정의 / 방향
1 차 fidelity (순위)	Spearman ρ $\uparrow$ · Kendall τ $\uparrow$	오라클 ϕ 대비 순위 상관 ($\uparrow$ 좋음)
1 차 fidelity (값 - 거리)	cosine_d $\downarrow$ · euclid_d $\downarrow$ · max_diff $\downarrow$	오라클 ϕ 대비 값 - 크기 오차 ($\downarrow$ 좋음)
2 차 -① 일반 성능	test acc (이미지) $\uparrow$ · MMLU · ROUGE-L (LLM) $\uparrow$	개입 arm 최종 성능 ($\uparrow$ 좋음)
2 차 -② 수렴	rounds-to-target $\downarrow$ · final val-loss $\downarrow$	목표 도달 라운드 / 최종 검증손실
2 차 -③ 탐지	AUROC $\uparrow$	오염 클라 = 높은 의심점수 (1.0= 완전분리)

3-state 라벨

Ⓐ 구현 완료 · Ⓑ 실측 (이 데크의 모든 수치) · Ⓒ 미실행

위협 모델 (오염 종류)

noisy = answer_swap(데이터 품질) · free-rider = zero/random 업데이트 · poison = 백도어 (스케일 모델교체)

탐지에서 valuation 의 입장

방법은 라벨에 blind; 라벨은 평가 KEY(AUROC) 일 뿐 . 오염이 검증손실을 낮추면 ϕ 가 ' 기여 높음 ' 으로 나오는 것이 정직한 답 .

방향 규약 : $\uparrow$ 높을수록 좋음 / $\downarrow$ 낮을수록 좋음 . · 값 - 거리 지표는 순위가 포화 ($\rho=+1.000$) 된 구간에서 방법을 변별 — 특히 1 차 vs 2 차 테일러 비교에 사용 .

실험 명세 — fidelity / intervention

항목	fidelity	intervention (일반 성능 · 탐지)
데이터 · 모델	MNIST+LeNet5 / CIFAR-10+CNN	CIFAR-10 / FMNIST + CNN
클라이언트	N=10 (full 참여)	N=100, 라운드당 C=0.1 (10 개)
라운드 / local	R=10 / epochs=5	R=120 / epochs=5
옵티마이저	SGD mom=0, lr=0.01, batch=64	SGD mom=0, lr=0.01, batch=64
검증 / 테스트	val=2000 / test=8000	val=2000 / test=8000 (target acc=0.6)
시나리오 · 위협	iid · label_skew · quantity_skew · label_flip · feature_noise	partition{iid · dir1 · shard} × {clean · label_flip · grad_noise · free_rider}
오라클	in-run oracle (exact 2^{10}) + retrain oracle (2^{10})	— (개입 결과로 평가)
개입 arm	—	vanilla · flirds{mult · repl · add · select} · shapleyfl · fedif · sfedavg

fidelity — in-run oracle 대비 (순위 Spearman ↑ , 3-seed 평균)

시나리오 (CIFAR-10 / MNIST)	Flirds	Flirds1st	Banzhaf	GTG	FedSV	loss-heur
CIFAR·iid	+0.95	+0.54	+0.98	+0.21	+0.22	+0.69
CIFAR·label_skew	+0.98	+0.92	+1.00	+0.49	+0.53	+0.88
CIFAR·quantity_skew	+0.99	+0.96	+1.00	+0.78	+0.56	+0.98
CIFAR·label_flip	+1.00	+0.95	+1.00	+0.64	+0.54	+0.95
CIFAR·feature_noise	+1.00	+0.89	+1.00	+0.59	+0.40	+0.90
mnist·iid	+0.81	+0.78	+0.98	+0.47	+0.04	+0.84
mnist·label_skew	+0.71	+0.61	+0.98	+0.33	-0.01	+0.63
mnist·quantity_skew	+0.96	+0.98	+1.00	+0.78	+0.63	+0.96
mnist·label_flip	+1.00	+0.99	+1.00	+0.99	+0.97	+0.99
mnist·feature_noise	+0.79	+0.70	+0.95	+0.41	+0.13	+0.78

값 - 거리 (euclid_d, ↓ 좋음)

2 차항이 값 - 크기를 얼마나 줄히나 (label_flip):

CIFAR : Flirds 0.031 vs 1 차 0.046

MNIST : Flirds 0.207 vs 1 차 0.370

→ 2 차항이 값 오차를 1 차 대비 ~25-50% 축소
(전 시나리오 일관).

읽기

순위만 보면 Flirds·Banzhaf·loss-heur 모두 우수
(Banzhaf=exact 2¹⁰). MC 기반 GTG/FedSV 는 noisy.
Flirds 의 우위는 정확도가 아니라 비용 (HVP 1 회).

fidelity — retrain oracle (2^{10}) 대비 , 그리고 in-run oracle 와의 괴리

시나리오	Flirds (in-run)	Flirds (retrain)	Flirds1st (retrain)	GTG (retrain)	loss-heur (retrain)
CIFAR·iid	+0.95	-0.23	-0.13	-0.20	-0.18
CIFAR·label_skew	+0.98	-0.18	-0.07	+0.44	+0.14
CIFAR·quantity_skew	+0.99	+0.57	+0.56	+0.70	+0.57
CIFAR·label_flip	+1.00	+0.52	+0.59	+0.46	+0.58
CIFAR·feature_noise	+1.00	+0.63	+0.50	+0.44	+0.56
mnist·iid	+0.81	+0.36	+0.52	+0.19	+0.48
mnist·label_skew	+0.71	-0.28	-0.06	-0.22	-0.16
mnist·quantity_skew	+0.96	+0.85	+0.77	+0.56	+0.84
mnist·label_flip	+1.00	+0.96	+0.97	+0.97	+0.97
mnist·feature_noise	+0.79	+0.33	+0.44	+0.40	+0.44

핵심 — 게임 정의 차이

Flirds 는 in-run oracle 게임을 거의 완벽 재현하나 , label_skew 에서 in-run 과 retrain oracle 가 갈린다 :

CIFAR·label_skew : in-run +0.98 → retrain -0.18

MNIST·label_skew : in-run +0.71 → retrain -0.29

이는 Flirds 추정오차가 아니라 모든 in-run 방법이 공유하는 한계 . 희귀라벨 클라는 매 라운드 한계기여는 낮아도 최종 재학습 모델엔 필수 . (iid 음수는 retrain oracle 신호 자체가 미약 → 노이즈)

intervention — 개입 결과 (CIFAR-10, dir1, 3-seed 평균)

arm	clean	grad_noise	label_flip	free_rider
vanilla	0.638 (-)	0.245 (-)	0.515 (-)	0.587 (-)
flirds_mult	0.642 (-)	0.433 (0.99)	0.585 (0.93)	0.597 (0.39)
flirds_select	0.634 (-)	0.313 (0.99)	0.559 (0.91)	0.589 (0.48)
shapleyfl	0.635 (-)	0.550 (1.00)	0.568 (0.96)	0.560 (0.00)
fedif	0.638 (-)	0.527 (1.00)	0.567 (0.96)	0.611 (1.00)

셀당 = test acc ↑ (탐지 AUROC ↑). clean 은 위협 없음→ AUROC 없음 .

- clean: 전 arm ≈ vanilla → 무해 (do-no-harm) 확인 .
 - grad_noise: 전 arm > vanilla(0.245). 단 shapleyfl(0.550) · fedif(0.527) > flirds_mult(0.433).
 - label_flip: flirds_mult(0.585) 이 최고 . free_rider: fedif AUROC 0.996, flirds_mult 0.385 — 탐지 약함 (아래).
- Flirds 가중은 항상 robust+ 무해하나 정확도에서 shapleyfl/fedif 를 압도하진 않음 . soft(mult) > hard(select).

실험 명세

항목	cross-silo (N=5)	cross-device (N=100)
모델	Llama-3.2-1B-Instruct (+ 3B)	Llama-3.2-1B-Instruct
클라이언트	N=5 (1 도메인 / 클라)	N=100, 라운드당 K=10
분할	5- 도메인 cross-silo	per-client Dir(α), $\alpha \in \{0,0.01,0.1,0.5,5.0\}$
라운드	R=10	R=30
옵티마이저	SGD mom=0, lr=1e-3 (poison 2e-3)	동일
정밀도 · attn	fp32 master · eager attention	동일
검증	val=100 (5 도메인)	domain-pool val
오라클	in-run oracle (exact 2 ⁵)	in-run oracle (per-round exact, reference point $\alpha=0.5$)
위협	noisy · freerider{zero,random} · poison	동일 (poison: install config)

LoRA 어댑터 , attn=eager(전진모드 AD 위해). cross-silo/3B 3seed (3B 는 1seed). cross-device α 별 1-3seed. 기준점 외 α 는 Flirds proxy(reference point $\alpha=0.5$ 서 in-run oracle 와 +1.000 검증). · 내부코드 cross-silo=silo5·cross-device=device100

탐지 AUROC ↑ · fidelity Spearman ↑ vs in-run oracle · 런타임 ↓

방법	noisy ↑	fr-rand ↑	fr-zero ↑	poison ↑	p noisy ↑	p poison ↑	런타임 ↓
in-run oracle	1.000	1.000	1.000	1.000	-	-	532s
Flirds	1.000	1.000	1.000	0.917	+1.00	+0.97	106s
Flirds1st	1.000	1.000	1.000	0.000	+1.00	+0.00	35s
FedIF	1.000	1.000	1.000	1.000	+0.93	+0.97	35s
GTG	1.000	1.000	1.000	1.000	+1.00	+0.87	538s
FedSV	1.000	1.000	1.000	1.000	+1.00	+0.37	533s
ShapleyFL	1.000	1.000	1.000	1.000	+1.00	+1.00	530s
Banzhaf	1.000	1.000	1.000	1.000	+1.00	+1.00	533s
loss-heur	1.000	1.000	1.000	1.000	+1.00	+1.00	164s
FLDetector	0.750	1.000	0.750	1.000	-	-	30s
STD-DAGMM	0.417	1.000	0.250	0.750	-	-	136s
FLTrust	1.000	1.000	1.000	1.000	-	-	36s
FedDQC	0.917	0.750	0.750	1.000	-	-	22s

noisy·free-rider: 전 valuation +1.000, AUROC 1.0 — N=5 near-additive 로 모두 동률 . Flirds 우위 = 비용 (106s vs 530s).
poison(ASR≈1.00): Flirds-1st AUROC 0.000 완전회피 → 2 차항 추가 시 0.917 회복 (불안정 , 아래). FedSV p 0.367 로 동률 붕괴 .

α -sweep — 탐지 AUROC ↑

방법 (noisy AUROC ↑)	$\alpha=0.0$	$\alpha=0.01$	$\alpha=0.1$	$\alpha=0.5$	$\alpha=5.0$
Flirds	0.774	0.575	0.605	0.604	0.596
FedIF	0.973	0.568	0.693	0.830	0.973
STD-DAGMM	0.856	0.652	0.659	0.671	0.760
FLTrust	1.000	0.602	0.720	0.854	0.994
FedDQC	0.960	1.000	1.000	1.000	1.000
FLDetector	0.535	0.482	0.525	0.539	0.532
ComFedSV	0.442	0.419	0.432	0.371	0.396

방법 (poison AUROC ↑)	$\alpha=0.0$	$\alpha=0.5$
Flirds	1.000	1.000
Flirds1st	1.000	0.670
loss-heur	1.000	1.000
FLDetector	0.987	0.983
STD-DAGMM	1.000	0.983
FedDQC	1.000	1.000
FLTrust	0.650	0.498
FedIF	0.542	0.458

free-rider (random · zero, 전 α): Flirds · Flirds1st · loss-heur · FLTrust = AUROC 1.000. FedDQC 0.14–0.57(off-threat) · ComFedSV ~0.40.

noisy: 데이터품질 탐지는 FedDQC 영역 (스케일에서 1.0). Flirds ~0.60. fidelity 는 Flirds1st · loss-heur $\rho=+1.000$ (전 α);

reference point $\alpha=0.5$ 서 GTG +0.78 · FedSV +0.75 · ShapleyFL +0.58 · FedIF +0.72 (vs in-run oracle per-round exact).

poison(install config): Flirds AUROC 1.0(both α), 1 차도 $\alpha=0$ 서 1.0 — cross-silo 와 달리 cross-device 예선 1 차가 회피되지 않음 .

Llama-3.2-3B — 탐지 AUROC ↑ · ρ vs in-run oracle ↑ · 런타임 ↓ (seed 0)

방법	noisy ↑	fr-rand ↑	fr-zero ↑	poison ↑	ρ noisy ↑	ρ poison ↑	런타임 ↓
in-run oracle	1.000	1.000	1.000	1.000	–	–	1240s
Flirds	1.000	1.000	1.000	0.000	+1.00	+0.00	251s
Flirds1st	1.000	1.000	1.000	0.000	+1.00	+0.00	82s
FedIF	1.000	1.000	1.000	1.000	+0.60	+0.60	82s
loss-heur	1.000	1.000	1.000	1.000	+1.00	+1.00	384s
FLDetector	1.000	1.000	1.000	1.000	–	–	250s
STD-DAGMM	0.250	1.000	0.000	0.750	–	–	530s
FLTrust	1.000	1.000	1.000	1.000	–	–	85s
FedDQC	1.000	0.750	0.750	1.000	–	–	49s

noisy · free-rider: Flirds ρ=+1.000 유지 (1B→3B), 런타임 251s vs in-run oracle 1240s (~5× 저렴).

poison: Flirds · Flirds-1st 모두 AUROC 0.000 — 1B 서 보인 2 차 회복이 3B(seed 1 개) 에선 안 나타남 → 경계의 스케일 취약성 (미확정).

FedIF ρ 는 3B 서 +0.600 으로 하락 (1B +0.90). loss-heur · FLDetector · FedDQC · FLTrust 는 poison 1.0 유지 .

실험 명세 — 오염축 제거 , OpenFedLLM 표준 셋업

항목	standard (N=20, 주 무대)	reference (N=5, 듀얼 오라클)
모델 · 데이터	Llama-3.2-1B / alpaca-gpt4 20k (IID)	동일
클라이언트	N=20, 라운드당 2 개	N=5 (full)
라운드 / local	R=200 / 10 steps × batch16	R=30 / 동일
옵티마이저	SGD mom=0, lr=1e-3, seq=512	동일
검증 / 테스트	val=200 / test=1000	동일
오라클	in-run oracle (per-round exact)	retrain oracle (2 ⁵) + in-run oracle + Banzhaf
개입 arm	base · vanilla · flirds_w (× β.5) · flirds_sel · shapleyfl_w · fedif_w	base · vanilla · flirds_w · shapleyfl_w · fedif_w
성능 지표	MMLU(full 0-shot) · Alpaca-test ROUGE-L · 수렴	동일

무대 =OpenFedLLM run_sft.sh verbatim(deviation: SGD mom=0/lr1e-3 상수 /r16/fp32). clean · IID → 개입은 do-no-harm parity 가 기대값 . 3 seed. · 내부코드
standard=std20 · reference=anchor5 · in-run oracle=(b) · retrain oracle=(a)

standard (N=20) vs in-run oracle · reference (N=5) vs retrain oracle (3-seed 평균)

standard (N=20) vs in-run oracle	Spearman ↑	Kendall ↑	cosine_d ↓	euclid_d ↓	max_diff ↓
Flirds	+1.000	+1.000	3.5e-07	4.4e-05	2.1e-05
Flirds1st	+0.999	+0.996	4.4e-05	6.2e-04	2.3e-04
loss-heur	+1.000	+1.000	2.4e-06	1.3e-04	5.3e-05
GTG	+0.975	+0.916	7.1e-04	9.8e-04	4.7e-04
FedSV	+0.910	+0.786	5.7e-03	2.8e-03	1.7e-03
ComFedSV	+0.093	+0.060	8.4e-01	2.6e-02	9.8e-03
ShapleyFL	+0.194	+0.133	2.1e-01	2.7e+00	9.9e-01
FedIF	+0.157	+0.111	1.9e-01	2.6e+00	9.8e-01

reference (N=5) vs retrain oracle	Spearman ↑	Kendall ↑	cosine_d ↓	euclid_d ↓	max_diff ↓
Flirds	+1.000	+1.000	2.3e-09	4.8e-05	2.4e-05
Flirds1st	+1.000	+1.000	2.0e-07	3.1e-04	1.6e-04
Banzhaf	+1.000	+1.000	3.9e-11	4.0e-06	1.9e-06
loss-heur	+1.000	+1.000	6.1e-08	2.4e-04	1.2e-04
GTG	+1.000	+1.000	3.2e-03	2.5e-03	1.8e-03
FedSV	+0.700	+0.600	5.5e-03	3.6e-03	2.6e-03
ShapleyFL	+0.700	+0.600	1.9e-01	1.2e+00	9.8e-01
ComFedSV	+0.500	+0.467	1.3e-01	1.9e-02	1.4e-02
FedIF	+0.067	+0.067	2.3e-01	1.3e+00	9.8e-01

Flirds: in-run oracle p=+1.000(cosine_d 3.5e-7) · retrain oracle p=+1.000 — IID·clean 에선 두 오라클 게임이 일치 → S7 의 괴리는 이질성 구동임을 확인 .

2 차항 효과 : cosine_d Flirds 3.5e-7 vs Flirds-1st 4.4e-5 (~125× 타이트). ShapleyFL·FedIF·ComFedSV 는 스케일서 fidelity 약함 .

개입 arm — MMLU · ROUGE-L · 수렴 (standard N=20, 3-seed 평균)

arm	MMLU (0-shot) ↑	ROUGE-L ↑	final val-loss ↓	rounds→target ↓
base	0.4822	0.2168	–	–
vanilla	0.4742	0.2841	1.2653	200
flirds_w	0.4745	0.2848	1.2653	199
flirds_sel	0.4739	0.2838	1.2654	199
shapleyfl_w	0.4742	0.2845	1.2653	199
fedif_w	0.4741	0.2847	1.2652	198

base= 학습 전 . FL-SFT 후 ROUGE-L +0.067(0.217→0.284), MMLU -0.008 — 과제 적합 향상 , 일반지식 미세 하락 .
전 가중 arm(flirds_w·flirds_sel·shapleyfl_w·fedif_w) ≈ vanilla (MMLU ±0.0006·ROUGE ±0.001·수렴 ±1 라운드).
→ IID·clean 에서 do-no-harm parity 확인 — 고칠 오염이 없을 때 가중이 성능 · 수렴을 해치지 않음 (설계 기대값 충족).

rounds-to-target= 검증손실 목표 도달 라운드 (전 arm ~199/200). reference (N=5) 도 동일 parity. 출처 : 재집계 .

기여도 측정 정확성 — 트랙 횡단 요약

측면	결과	근거
순위 vs in-run oracle	Flirds $p \approx +1.000$ (전 트랙). Banzhaf·loss-heur 도 우수 ; MC-SV 는 noisy	cross-silo·standard +1.000 / 이미지 +0.71~1.00
값 - 거리 vs in-run oracle	2 차항이 1 차 대비 값오차 $\sim 2\times$ 축소 ; loss-heur 은 순위만 비기고 크기는 빛나감	euclid_d: 이미지 $\sim 0.5\times$ · standard cosine 125 $\times$
순위 vs retrain oracle	IID·clean 은 +1.000 일치 ; label_skew(이질성) 에서 in-run oracle 와 괴리 (-)	reference (N=5) +1.000 / 이미지 label_skew -0.18~-0.29
비용	Flirds 1 HVP/round; in-run oracle exact 의 5~15 $\times$ 저렴 , 동일 순위	cross-silo 106s vs 530s · 3B 251s vs 1240s

한 줄 요약

Flirds 는 in-run oracle 게임을 순위 · 값 모두에서 충실히 , exact 대비 저비용으로 재현한다 . 2 차항의 고유 기여는 순위가 아니라 값 - 크기 정밀도 . retrain oracle 게임과의 일치는 데이터 이질성에 의존 — 동질이면 일치 , label_skew 면 갈림 .

retrain oracle 괴리는 Flirds 특정 오차가 아니라 모든 in-run 방법 공유 . 상세 S6·S7·S14.

① 일반 성능 → ② 수렴 → ③ 탐지

질문	요약
① 일반 성능	오염 하 전 가중 arm > vanilla(이미지). clean/IID 는 무해 parity(이미지 · LLM). 정확도 최고는 아님 — grad_noise 서 shapleyfl/fedif 우위 , label_flip 서 flirds 우위 . soft>hard.
② 수렴	IID · clean(LLM standard) 서 전 arm 동일 수렴 (rounds→target ~199/200, parity). 고칠 오염 없을 때 가중이 수렴을 해치지 않음 .
③ 탐지	free-rider: LLM AUROC 1.0(전 α) 이나 N=100 CNN 서 0.4(상충 , S18). noisy: FedDQC 영역 (1.0), Flirds ~0.6. poison: 1 차 회피→ 2 차 부분회복 (1B) · 실패 (3B); loss-heur · 전 탐지기 1.0.

탐지는 위계상 마지막 — 기여도 ≠ 탐지 . clean-val-loss 를 낮추는 공격자를 ϕ 가 ' 기여 높음 ' 으로 보는 것은 valuation 의 정직한 답이며 , 바로 그 지점 (clean-preserving poison) 이 valuation 접근의 경계다 (S18).

솔직한 항목 (같은 톤으로)

항목	상태	내용
오라클 게임 괴리 (retrain↔in-run)	㉞ 실측	label_skew(이질성) 서 in-run ϕ 가 재학습 가치와 역상관 . 모든 in-run 방법 공유 . 프레이밍 필요 .
free-rider 탐지 상충	㉞ 미해결	동일 zero-delta 가 LLM AUROC 1.0 vs N=100 CNN 0.4(IID 칸 포함). 버그 배제용 드릴다운 필요 .
poison 2 차 불안정	㉞ 잠정	1B 서 1 차 회피 (0.000)→2 차 부분회복하나 run 간 0.42↔0.92(동일 config·seed). 3B(1seed) 선 회복 실패 .
미실행 (deferred)	㉞ 미실행	LLM standard 3B/7B · LLM N=10 retrain oracle · 7B 전반 — 설계상 보류 .

다음 단계 (제안)

1 차 : 오라클 게임 괴리 (retrain↔in-run) 규명 (ϕ 직접 분석 , 희귀라벨 가설) — 핵심질문 위계상 우선 .
병행 : free-rider CNN-vs-LLM 상충 드릴다운 (버그 / 실재 판별) · poison 2 차 비결정성 재현 확인 .

㉠ 구현 ㉞실측 ㉞미실행 . 잠정 · 미해결치도 결과와 같은 비중으로 기재 .