

연구 진행 보고 · 2026-06-04

Flirds

Federated Learning + In-Run Data Shapley

Vanilla FedAvg 가 이미 받는 클라이언트 업데이트 Δw_k 만으로 , 라운드별 검증손실 변화의 1 차 +2 차 Taylor 전개로 client-level Shapley 를 닫힌형 계산 — 통신 추가비용 0, 역해시안 없음 .

한눈에 보기

- **무엇**: FL 에서 client 별 데이터 기여도 ϕ_k 를 측정 . IRDS(In-Run Data Shapley) 를 FL + LoRA(PEFT) 로 확장 .
- **어떻게**: 라운드별 검증손실 변화의 1 차 +2 차 Taylor 닫힌형 Δw_k 만 사용 → 통신 추가비용 0.
- **강점**: 역해시안 없이 forward HVP($H \cdot \Delta w$). LLM 에서 IF 가 무너지는 원인 (iHVP collapse) 을 구조적으로 회피 .
- **novelty**: client-level + in-run + 1·2 차 Taylor + HVP 상호작용 + zero-comm + LoRA/LLM 교집합이 prior art 에 비어 있음 .

현재 위치

완료

Phase 0 — CNN baseline 4 종 재현

완료

Phase 0.5 — estimator + dual oracle · 전 게이트 green

진행

Phase 1 — LLM 1B · 5 단계 빌드 + 검증 · SMOKE green

예정

Phase 2 / 3 — full baseline · 실험 매트릭스 실행

다음 액션

1B FULL clean run 실행 (MINI de-risk 먼저 , ~5-7h) → 이후 SV baselines LLM 이식 → Phase 2/3

문제 정의 — FL 에서 누구의 데이터가 기여했는가

학습된 FL 모델에 대해 각 client(데이터 보유자) 에게 기여도 ϕ_k 를 부여한다 . 용도 : 데이터 가치평가 · 저품질 /free-rider 탐지 · 공정 보상 · 데이터 선택 .

기존 방법의 벽

Retraining 기반 Shapley

U(S) 평가에 2^N 재학습 필요 → LLM 스케일에서 불가능 .

통신 / 계산 오버헤드

FedSV 는 $O(Tm^2)$ 서버 평가 , ComFedSV 는 추가 all-client 라운드 .

Gradient / IF 방법

heterogeneous FL 서 취약 (DataInf 가 Fed-WildChat 서 실패) · LLM 서 iHVP collapse.

Flirds 의 접근

- vanilla FedAvg 위에 post-hoc 로 동작 — 학습 알고리즘 변경 없음 .
- 서버가 이미 받는 Δw_k (LoRA) 만 사용 → 통신 · 계산 추가비용 0.
- forward HVP($H \cdot \Delta w$) 만 — H^{-1} 없음 → LLM-IF 의 실패 원인 회피 .

방법 — 라운드별 손실변화의 1·2 차 Taylor

$$\phi_k^{(r)} \approx -\nabla \ell(w_r, z_{\text{val}}) \cdot \Delta w_k + \frac{1}{2} \Delta w_k^\top H^{(\text{val})}(w_r) \Delta W^{(r)}$$

$$\Delta W^{(r)} = \sum_j \Delta w_j \text{ (참여 client 합)} \quad \phi_k = \sum_r \phi_k^{(r)} \text{ (라운드 합)}$$

- **비용** : 라운드당 비용 : HVP 1 회로 $u := H \cdot \Delta W^{(r)}$ 계산 후 N 개 내적 $\Delta w_k \cdot u$ — LoRA 차원이라 저렴 .
- **2 차항** : 1 차항 = 정렬 (alignment), 2 차항 = client 간 상호작용 (곡률). 비 -IID FL 에서 2 차항이 본질적 .
- **안정성** : forward HVP($H \cdot \Delta w$) 만 — H^{-1} 절대 계산 안 함 → IF 의 iHVP collapse 원인 회피 .

확정 : 곡률 = 참 Hessian (GGN/Fisher 변형 검증 후 기각) · 최적화 = plain SGD(momentum 0) — 이때 비로소 2 차항이 1 차항을 이김 .

무엇이 새로운가 — 비어 있는 교집합

방법	단위	통신 오버헤드	in-run	비고
FedSV (2020)	client	0 (단 $O(Tm^2)$ 평가)	per-round 대리	federated Shapley 원조
Ripple (2026)	sample	0	yes (Jacobian)	최근접 경쟁자
FedIF (2025)	client	0	yes (1 차 TracIn)	CNN 한정 · aggregation-side
FedTSV (2026)	client	+ val pass	yes	aggregation (가치평가 아님)
Flirds (본 연구)	client	0	yes (1·2 차 Taylor)	LoRA + 2 차항 + zero-comm

novelty

- 교집합 (client-level + in-run + 1·2 차 Taylor + HVP 상호작용 + zero-comm + LoRA/LLM) 을 점유한 단일 논문 없음 — 2026-06-03 재조사 (내부 4 + 외부 survey 교차검증) 로 확인 .
- cross-domain valuation-fairness: 공유 val-loss Shapley 의 도메인 간 공정성은 prior art 서 under-addressed → 추가 novelty hook (모든 도메인 free-form 통일로 대응).
- FedIF/FedTSV 는 aggregation-side(가중치 변경), Flirds 는 valuation-side(post-hoc 가치) — 같은 입력 , 다른 출력 .

이론 — 중앙집중 등가 + drift residual

- ① **등가**: 1-step SGD 에서 한 client 에 속한 data-level Shapley 의 합 = client-level Shapley (1·2 차항 모두). → 중앙집중 1-step 에서 granularity 선택은 grouping-invariant.
- ② **FL 편차**: FL 멀티스텝: Δw_k 는 E-step 궤적의 끝점 → Taylor 전개 시 '중앙집중 등가항' + 'client drift residual' $O(\eta E \cdot |H| \cdot \text{궤적길이})$ 로 분해.

Proposition 1

Flirds client-level SV = (중앙집중 data-level SV 를 client 로 합산) + drift residual. → FL 의 중앙집중 IRDS 로부터의 이탈을 정량화.

Proposition 2

drift residual 은 라운드별 local 궤적 반경의 3 차식으로 bound. E=1 서 소멸, non-IID· 큰 local epoch 서 증가.

핵심 함의

IRDS 는 "2 차항이 marginal" 이라 보고 — 그러나 이는 centralized per-step(미소 η) 의 산물. FL 의 per-round 멀티스텝이 바로 2 차항이 본질적으로 작동하는 무대 (실험으로 검증).

확정된 핵심 설계 결정

항목	결정
단위 (granularity)	client-level
서버 입력	Δw_k (LoRA) 만 — 추가 통계 / 통신 0
근사 차수	1 차 + 2 차 Taylor, 항상 둘 다
곡률	참 Hessian (GGN 기각)
최적화	plain SGD (momentum 0)
검증셋	server-side held-out · 도메인당 $200 \times 5 = 1000$ stratified
PEFT / 정규화	LoRA / participation 정규화 없음 (기본)
모델	1B Llama-3.2 · 3B Llama-3.2 · 7B Llama-2

Dual Oracle (ground truth)

(a) Exact retrain SV

$U(S)=S$ 만으로 FL 학습 (데이터가치 표준). 1B $N \in \{5,10\}$ · 3B $N=5$ · 7B ✗ (compute).

(b) IRDS- 定 in-run SV

Flirds-correct oracle. cross-silo $N=10$ exact enum(1024 subset) · cross-device $N=100$ MC. 비용 $2^N \cdot R \cdot |val| \cdot seq \rightarrow N5 \leftrightarrow N10 = 32 \times \cdot fp32$ 필수 .

원본 lock (conv4) + $N1-N4 / Q1-Q3 / \textcircled{4}\textcircled{5}$ 까지 설계 전부 동결 — 구현 중 새 정보 없는 한 재론 안 함 .

진행 현황 ① — Phase 0 / 0.5 완료 (CNN)

완료

Phase 0 — FL-Shapley baseline 4 종 self-build 재현

GTG-Shapley	FedSV	ComFedSV	Ripple
recon cosine 0.99	perm-MC 0.998	Spearman {1.0,.96,.85,.84}	noisy-AUROC 1.0

Ripple 속도이득 62× vs AFedSV+ / 49× vs FedSV (ground-truth-SV 지표 없음 → task-driven 검증).

완료

Phase 0.5 — Flirds estimator + dual oracle · 전 sanity gate green

- estimator $\approx$ (b) in-run oracle: Spearman 1.0 (3-seed 1+2 차 0.96 > 1 차 0.92).
- noisy-client AUROC 1.0 · (b) Shapley efficiency = 0, symmetry = 0 (exact).
- HVP jvp-vs-double-backward 9.8e-6 · N=2 singleton 3e-3 · 재현성 bitwise-0.

결정 (데이터로 확인)

2 차항 = 참 Hessian · momentum 제거 (plain SGD) 시 2 차항이 1 차항을 이김 → "FL per-round 가 2 차항의 무대" 라는 가설을 CNN 에서 실증.

진행 현황 ② — Phase 1 (LLM 1B) 거의 완료

estimator/oracle 무변경 . 5 단계 모두 빌드 + 검증 (real Llama-3.2-1B 궤적).

- | | | |
|---|--|---------------------------------|
| 1 | backend-agnostic estimator/oracle + partial-participation + per-layer ϕ | CNN bit-identical 회귀 |
| 2 | LLM backend + FL loop (TRL SFTTrainer + forced SGD) | 1B est $\approx$ oracle 1.70e-6 |
| 3 | 5-domain free-form data layer + val micro-batching + per-domain norm | chunked==single 3.8e-8 |
| 4 | ② corruptor: answer_swap(noisy) + free_rider(zero/random) | free-rider ϕ = 정확히 0 |
| 5 | #7 first-clean-run 인프라 (eval · run_logger · orchestrator) | SMOKE 1.6e-7 · AUROC 1.0 |

3 LLM musts (CNN 엔 없던 것)

eager attention(forward-AD) · FL state = named_parameters key · embedding require-gra hook clear (functorch $\leftrightarrow$ HF).

남은 1 액션

FULL scale run 실행 — N=5, R $\approx$ 30, 3 seed, ORACLE_B(N=5), ~5-7h (MINI de-risk 먼저).

데이터셋 & 평가 프로토콜

Cross-silo 5-domain — 전부 free-form instruction→response (공유 val-loss Shapley 공정성)

domain	medical	legal	finance	math	general
dataset	med flashcards	ibunesco QA	FiQA	AQUA-RAT	Dolly

- 크기 : 도메인당 train 12k / val 200 / test 2k (상호 disjoint) · cross-device: Fed-WildChat + FedHDS (N=100, K=10).

평가 — utility ≠ downstream 분리

- utility = val-loss (estimator/oracle 가 소비) ≠ downstream = per-domain ROUGE-L + math(AQUA) EM.
- selection-convergence: $\phi \rightarrow \text{top-K} \rightarrow \text{retrain}$ vs full/random (MATES 템플릿). caveat: heterogeneous FL 서 selection 이 random 에 질 수 있음 — 넘어야 할 bar.

보고 엄밀성 (Protocol)

- 수치 : bf16 train / fp32 eval + fp32 내적 · ≥ 3 seed mean $\pm$ std · 95% bootstrap CI.
- sanity gate: $E=1 \Rightarrow \text{residual} \approx 0$ · $N=2 \Rightarrow \text{singleton SV} = \phi_k$ · 재현성 bitwise.
- 추적 : local run-dir (config + git SHA + env hash + per-round ϕ parquet), W&B 미사용 .

실험 계획 — Section 3 (18 항목)

★★★ Spine

baseline 10 종 + detection 2(FLDetector·STD-DAGMM) · dual oracle (a)/(b) · Ripple head-to-head + 이론적 reduction 시도 .

★★ 특성화 / ablation

α -sweep $\times$ E-sweep drift 매트릭스 (16 셀) · Q2 variants(3×3) · ②③ 특성화 · 적대적 stress · non-IID valuation bias.

★ Scale

7B instruction-tuning bench (LESS · FedDQC 직접 비교).

◆ 차별화 실험 (flagship 후보)

PGD / direction-aligned poison: 1 차항으로 못 잡는 공격을 2 차 (곡률) 항이 분리하는가? — FedIF 의 blind spot, Flirds-1st-only 와 대조하여 "2 차 > 1 차" 를 직접 입증 .

매트릭스 : 1B / 3B / 7B 전 셀 (3 seed mean $\pm$ std + 95% CI). est-vs-oracle fidelity 는 비용 때문에 N 으로 capped ($N5 \leftrightarrow N10 = 32 \times$, fp32).

다음 단계 & 한계

다음 단계

즉시

1B FULL clean run (N=5, $R \approx 30$, 3 seed, ~5-7h) — MINI de-risk 먼저

이후

SV baselines LLM 이식 (GTG/FedSV/ComFedSV/Ripple)

Phase 2

full baseline + Data Banzhaf + ShapleyFL + detection + 3B/7B

Phase 3

실험 매트릭스 실행 + Ripple 이론 reduction → 논문

한계 (정직하게 보고)

Privacy

서버가 개별 Δw_k 를 봐야 함 → secure aggregation 과 비호환 . client-level 가치평가의 본질적 한계 (고칠 결함 아님).

noise vs OOD-good

signed value 안에서 분리하는 FL 방법은 없음 (detector 들 non-IID 서 붕괴)
→ characterized limitation 으로 보류 .

non-IID bias

FL-Shapley 가 maverick/ 희귀도메인 client 를 과소평가 → α -sweep 필수 측정 의무 .