

Flirds 진행 보고

Client-level In-Run Data Shapley for Federated LLM Fine-tuning

2026-06-12 · Yonghee Choi

표기 규약

㉠ 구현+smoke (값 coarse) · ㉡ 실측 (설정 병기) · ㉢ 설계만, 미실행
기울임 회색 = 잔여 셀(device100 poison · $\alpha=0.5$ anchor · 7B) 확정 대기.

문제 정의와 알고리즘

- **문제**: FedAvg 연합학습에서 server가 보는 것은 client별 update Δw_k 와 데이터 수 n_k 뿐(raw data 접근 불가). 이 정보만으로 각 client의 데이터 기여도 ϕ_k 를 매기는 data valuation 문제 — 대상은 LoRA-LLM fine-tuning(1B–7B; CNN은 검증·표준비교 트랙).
- **요건**: 학습 종료 후 post-hoc · 재학습 0 · 추가 통신 0. 용도 = corrupt/free-rider 식별 + selection(상위 client 재학습).

$$\phi_k = \sum_r p_k^r [\langle g^r, \Delta w_k \rangle + \frac{1}{2} \langle \Delta w_k, u^r \rangle], \quad u^r = H^r \Delta W^r$$

frozen FedAvg 궤적만 입력 · $g^r = \nabla \text{val-loss} \cdot \text{val-loss}$ 를 내리면 $\phi < 0$ (더 가치 있음)

- server-side validation loss의 **1차+2차 Taylor**로 in-run Shapley를 closed-form 근사 — **round당 HVP 1회**(forward H·v, true Hessian), 비용 N-독립 ↔ exact oracle은 $2^N \cdot R$ forward.
- **free-rider $\phi = 0$ exact**(구조적: $\Delta w=0 \rightarrow$ 전 내적 0) · Flirds-1st(2차 off, ~35s) = 자체 ablation.
- 제약: fp32 · eager attention · plain SGD mom=0 · LoRA-subspace.

선행 연구 — 계열별 경향과 비교 baseline

계열	대표	경향과 남는 한계
retrain 기반 semivalue	Ghorbani & Zou '19 · Data Banzhaf '23	coalition 재학습으로 utility 정의 — 정석이나 LLM-FL서 비용 불가(1B N=5 fp32 실측 126분 ㉞, N=10 ≈2-5일 추정)
FL-SV (게임이론적 FL 평가)	FedSV '20 · GTG '21 · ComFedSV '21 · ShapleyFL '23	retrain-free(로그로 coalition 재구성)지만 MC/열거 비용이 크고, 실험은 전부 소규모 비전 벤치마크(비-LLM)
gradient/influence 기반	IF (Koh & Liang '17) · Tracln → FedIF '25	미분 신호로 저렴하게 점수화 — IF는 iHVP 역산 불안정, FedIF는 순수 1차 + aggregation 변경, CNN
single-run / in-run	IRDS '24 · Ripple (AAAI '26)	한 궤적 안에서 재학습 없이 valuation — IRDS는 centralized-per-step-sample-level, Ripple은 sample-level-CNN이며 2차가 local-Hessian 시간 전파(within-round client 상호작용 항 없음)
aggregation 개입형	FedTSV (ECC '26) 등	점수로 다음 라운드 가중치를 조정 — 평가 회계가 아닌 학습 개입, 서버 추가 연산

비교 baseline	client-level	in-run (재학습 0)	closed-form (비 MC/열거)	명시적 2차 항 (client-interaction)	추가 통신 0	LLM-LoRA 실험
GTG / FedSV / ComFedSV / ShapleyFL	✓	✓	X MC-열거	X	✓	X
Data Banzhaf (원논문)	X sample	X 재학습	X MSR	X	—	X
Ripple	X sample	✓	X 저랭크 재귀	△ 시간 전파만	✓	X
FedIF	✓	✓	✓ 1차 내적	X	✓	X
Flirds	✓	✓	✓ 1+2차 Taylor	✓ HVP	✓	✓ 1B-3B (7B 예정)

비교는 전부 같은 frozen 궤적 위 from-logs 포팅(공정비교; loss-heur는 자작 floor baseline으로 별도) — 표는 원논문 기준 속성, 비점유 주장 근거는 서술적 서베이. X(2차)는 명시적 항의 부재 — 열거/MC 계열은 상호작용을 비용으로 암묵 포착. ComFedSV는 round-0 전원 참여 가정(Assumption 1).

실험 구조와 현재 상태

실험	구성	상태
dual-oracle 검증	retrain(val-loss) = in-run oracle = estimator 삼중 비교 — 같은 게임(val-loss)으로 방법 자체를 검증	㉞ 완료 — +1.000 (1B N=5 fp32 3-seed, lr 2중) · 3B(1-seed) est +1.000, retrain↔in-run +0.900
matrix ① cross-silo	silo5(N=5, 도메인당 1 client) × 4 threat × 3 seed — 9 valuation + FedIF + 4 detector + (b)oracle, 같은 frozen 궤적	㉞ 완료 (재실행본·영속화 8d364cc) → 결과 4장
matrix ② cross-device sweep	device100(N=100, Dir(α) 혼합, K=10/round) × $\alpha\{0, 0.01, 0.1, 5.0\}$ × 3 threat × 3 seed — cheap suite + proxy-truth	㉞ 완료 → 결과 5장
matrix ③ anchor / poison	$\alpha=0.5$ anchor 3셀((b) per-round exact 동반) · device100 poison 2셀(working-backdoor config)	㉞ 잔여 5셀 — 실행 대기(가장 비쌈)
scale ladder	1B → 3B → 7B (전부 fp32; 3B는 (b)oracle 동반 4-threat)	1B·3B ㉞ 완료 (3B 1-seed) · 7B ㉞
selection	φ 하위 드롭 후 재학습 — full / flirds-topk / random 3-arm	㉞ 완료 — corrupt 드롭 일관, vs full 우세, vs random cross-seed 우세 (1B N=5 3-seed, 양 lr)
N=10 retrain oracle	N=5 near-additive 무변별 해소용 직접 증거	㉞ 연기 ($\approx 2\text{--}5$ 일/1-GPU 추정)
Track C1 — CNN fidelity	MNIST/CIFAR, N=10, (a)+(b) 듀얼 oracle, GTG 5-시나리오, 9-method+Ripple	㉞ 설계 확정 · 구현 착수
Track C2 — CNN 일반 성능	N=100, 개입 3중(가중집계 $w \propto n \cdot s$ · selection · bottom-q%) × 3 파티션 × 4 위협	㉞ " (C1→C2 stage-gate)
Track C3 — 안정성	cross-seed Spearman + top/bottom-k% 일관성 (비용 0)	㉞ "
Track D — LLM 표준 세팅	Alpaca-GPT4 20k IID N=5, answer_swap 50% → 필터링 재학습 → MMLU (API-free)	㉞ "

결과 ① — cross-silo (1B N=5, 4 threat × 3 seed, 재실행본 ㉞)

AUROC ↑ 높을수록 좋음	noisy	freerider-zero	freerider-random	poison (ASR=1.00)	runtime/seed ↓ 낮을수록 좋음
(b) in-run oracle	1.0	1.0	1.0	1.0	~532s
Flirds (1+2차)	1.0	1.0	1.0	0.92±0.12	107s
Flirds-1st (1차만)	1.0	1.0	1.0	0.000	35s
FedIF (정규화 1차)	1.0	1.0	1.0	1.0	35s
GTG / FedSV / ShapleyFL / Banzhaf	1.0	1.0	1.0	1.0	530–538s
loss-heur (secant floor)	1.0	1.0	1.0	1.0	164s
FLDetector	0.75	0.75	1.0	1.0	~30s
STD-DAGMM	0.42±0.31	0.25±0.20	1.0	0.75±0.20	~136s
FLTrust	1.0	1.0	1.0	1.0	~36s
FedDQC	0.92±0.12	0.75	0.75	1.0	~22s

- Spearman vs (b) ↑ +1 = oracle과 동일 랭킹: noisy/FR 전 방법 +1.000(예외 FedIF 0.90–0.93 · FedSV FR-random 0.933) — N=5 near-additive → 주장은 "같은 랭킹을 더 싸게". poison: ShapleyFL·Banzhaf·loss-heur +1.000 · Flirds·FedIF +0.967 · GTG +0.867 · **FedSV +0.367** · Flirds-1st 0.000.
- **poison = 동물의 첫 붕괴**: raw 1차만 완전 회피(0.000), 정규화 1차·exact 계열은 잡음. Flirds-2차는 이전 동일 config run서 0.417±0.425 — run간 분산, 원인 규명 중(단정하지 않음).

결과 ② — cross-device sweep (N=100, 3-seed ㉠) · 3B (1-seed ㉠)

AUROC ↑	noisy $\alpha=0$	noisy $\alpha=0.01$	noisy $\alpha=0.1$	noisy $\alpha=5.0$	free-rider 전 α 양 모드
Flirds / 1st / loss-heur	0.77	0.57	0.60–0.61	0.60	1.00
FLTrust	1.00	0.60	0.72	0.99	1.00
FedIF	0.97	0.57	0.69	0.97	0.98–0.99
FedDQC (matched)	0.96	1.00	1.00	1.00	0.14–0.55
STD-DAGMM	0.86	0.65	0.66	0.76	0.51–0.96
FLDetector	0.53	0.48	0.53	0.53	0.51–0.61
ComFedSV	0.44	0.42	0.43	0.40	0.39–0.45

free-rider는 Flirds 계열·FLTrust가 전 α 에서 1.000. noisy는 cheap valuation이 0.57–0.77로 약함 — matched FedDQC가 보완. 1차=2차=loss-heur 랭킹 동일(proxy-truth Sp 1.000).

표 값은 seed 평균($\pm$ std 생략; 원본 = runs/phase2_matrix/rundirs/*/metrics.json). N=100 $\alpha=0.5$ anchor smoke에서 Flirds vs per-round exact oracle +1.000 ㉠(1-seed) · free-rider $\varphi=0$ 은 N=100서도 exact. $\alpha=0.5$ anchor 3셀 · device100 poison 2셀 · 7B 잔여.

AUROC (3B) ↑	noisy	FR-zero	FR-rand	poison
(b) oracle	1.0	1.0	1.0	1.0
Flirds	1.0	1.0	1.0	0.000
Flirds-1st	1.0	1.0	1.0	0.000
FedIF	1.0	1.0	1.0	1.0
loss-heur	1.0	1.0	1.0	1.0
FLDetector / FLTrust	1.0	1.0	1.0	1.0
FedDQC	1.0	0.75	0.75	1.0
STD-DAGMM	0.25	0.00	1.0	0.75

3B poison(ASR=1.0)서는 Flirds 1차·2차 모두 회피(1B의 2차 부분 회복이 사라짐; 1-seed). Flirds vs (b) Spearman: noisy/FR +1.000(FedIF 0.600).

고려 중인 사항 (novelty 방향)

항목	내용
① 탐지된 client의 처리	noisy-free-rider-backdoor로 탐지된 client를 어떻게 처리할지. 현재 구현: post-hoc selection(ϕ 하위 드롭 후 재학습) ㉞ 실측 완료 · Track C2의 개입 3종(가중집계 $w \propto n \cdot s$ / selection / bottom-q% 제외) ㉟ 설계 확정.구현 착수.
② 탐지 전용 데이터 분리	validation data와 구별되는 탐지 전용 데이터(추가 정보원)를 따로 두는 설계 검토.
③ validation data 약점 개선	단일 server val-loss 게임이 갖는 약점 — 공정성(도메인 편향), OOD, 오염 민감도 — 의 개선.
④ utility 함수 교체	val-loss 외의 utility로 게임 정의를 바꿔 사용해볼 여지.

앞으로의 계획

- ① **baseline 연구 심층 탐구** — 비교 baseline 원논문들의 메커니즘·실험 프로토콜 정밀 대조(특히 최근접 경쟁 Ripple-FedIF).
- ② **ablation study 실험 설계** — 주요 설계 선택에 대한 ablation 설계.
- ③ **novelty를 추가할 만한 요소 탐색** — 앞 장 '고려 중인 사항'과 연결해 구체화.