

0 Flirds 체크포인트 00 — 전체 그림 한 장

코드·raw 로그·PDF를 직접 읽고 대조한 연구자용 재오리엔테이션 문서. 추측 없음, 모든 정량주장에 파일경로 근거.

00 · 전체 그림 한 장

이 폴더는 외부 발표용이 아니라 연구자(Yonghee) 본인이 전체 그림을 다시 잡기 위한 체크포인트다. 모든 주장은 실제 코드(`codes/`), raw 로그(`research-wiki/raw/`), 논문 PDF를 직접 읽어 grounding했다. 3-state 규율을 전 문서에 적용: (a) = 코드 구현 + smoke green(값은 coarse) / (b) = 실제 실험결과 확보(seed·N·model 명시) / (c) = 설계 락됐으나 미실행.

0.1 한 줄 정의


Flirds = client-level **F**ederated **L**earning **I**n-**R**un **D**ata **S**hapley. FedAvg 학습 궤적(trajecory)을 열린 뒤, **server-side validation loss**의 1차+2차 Taylor 전개로 각 client의 in-run Shapley value ϕ_k 를 round당 HVP 1회로 추정한다. 재학습(retraining) 없음, 추가 통신 0.

핵심 수식(`codes/flirds/core/flirds_estimator.py:13`):

$$\phi_k = \sum_r p_k^r [\langle g^r, \Delta w_k \rangle + \frac{1}{2} \langle \Delta w_k, u^r \rangle], \quad u^r = H^r \Delta W^r$$

- $g^r = \nabla \text{val-loss at } w^r$, $H^r = \text{true Hessian}$ (IRDS와 동일; GGN/Fisher는 테스트 후 기각)
- $\Delta W^r = \sum_{j \in P_r} p_j^r \Delta w_j$ (round aggregate), $p_k^r = n_k / \sum_{j \in P_r} n_j$ (FedAvg participant weight)
- sign: client가 val-loss를 내리면 $\phi_k < 0$ (= 더 가치있음)
- `second_order=False` → 1차만 = **Flirds-1st** ($\approx 15 \times$ 더 싼)

0.2 End-to-end 파이프라인



평가 — eval/metrics.py · eval/generate.py
Spearman(vs oracle) · AUROC(vs 주입라벨) · ROUGE-L · ASR



selection / filtering — select_topk → arms {full / flirds_topk / random_k}
(detection→성능: noisy+free-rider 드롭 → val_loss ↓)

데이터 흐름의 불변식(durable):

- 모든 컴포넌트는 `logs = [(w_r, deltas_map)]` 만 본다 (backend-agnostic). estimator/oracle는 model-val-task를 직접 보지 않고 `loss_fn(params, buffers) + pkeys` 주입으로만 동작 (`codes/flirds/core/flirds_estimator.py:6-8`).
- backend는 `backends/{cnn,llm}.py` 의 `make_*_loss` 가 담당 → CNN/LLM 동일 인터페이스.

0.3 구성요소 지도

Estimator (우리 방법) — 2종

이름	코드	설명	상태
Flirds	<code>core/flirds_estimator.py</code> <code>second_order=True</code>	1차+2차 Taylor, round당 HVP 1회	(b) (1B N5 3-seed)
Flirds-1st	같은 함수 <code>second_order=False</code>	1차만 (= IRDS-1st self-ablation; FLTrust cosine 과 사실상 동일 신호)	(b) (1B N5 3-seed)

Oracle (ground truth) — 2종 (절대 평균내지 않고 별도 보고; 코드 공유 금지 — `flirds-protocol.md:84-86`)

이름	코드	utility	비용	상태
(b) in-run oracle	<code>oracle/in_run_sv.py</code>	얼린 궤적에서 coalition별 val-loss 변화의 exact 2^N Shapley (재학습 X)	$2^N \cdot R \cdot \text{val-seq}$ (FLOP-bound)	(b) (silo5 N5; device100 N100 1-seed)
(a) retrain oracle	<code>oracle/exact_sv_llm.py</code>	coalition S로 FedAvg 재학습 → 배포 모델 점수 (val-loss & ROUGE)	N5=126min(1B fp32)	(b) (1B N5; 3B N5 1-seed)

(a) vs (b) 핵심: 둘은 다른 게임. (b)=궤적-앵커 in-run(우리 방법이 근사하는 대상), (a)=재학습(고전 Data Shapley). 방법 검증은 (a)-val-loss = (b) = estimator 가 같은 게임이라 +1.000으로 일치((b)). (a)-ROUGE는 다른 게임이라 발산(+0.4@1B) — 미분불가라 estimator-ROUGE도 불가능 → 검증엔 반드시 val-loss.

Valuation baselines (성능비교 경쟁) — 7종

GTG-Shapley · FedSV · Ripple · Data Banzhaf · ShapleyFL · ComFedSV · loss-heuristic. 코드: `codes/flirds/baselines/` . 모두 같은 얼린 궤적 위에서 돈다(공정비교). 상세·PDF대조 → [03-baselines-and-prior-work](#).

Detectors (검출 경쟁 bar) — 4종 (위협-매칭, threat-matched)

detector	코드	타겟 위협	모델 필요?	상태
FLDetect or	<code>baselines/fldetector.py</code>	poisoning (시간 일관성)	model-free	(b)
STD-DAGMM	<code>baselines/std_dagmm.py</code>	free-rider (독립 baseline)	model-free	(b) (N100 1-seed)
FLTrust	<code>baselines/fltrust.py</code>	free-rider+poison (val-grad cosine = Flirds-1st와 동일신호)	val-grad 필요	(b) (N100 1-seed)
FedDQC	<code>baselines/feddqc.py</code>	noisy/data-quality (IRA)	client 데이터 +model 필요	(b) (1-seed smoke)

9-method 합계

"valuation method 9종" = Flirds, Flirds-1st, GTG, FedSV, Banzhaf, ShapleyFL, loss-heur, (그리고 regime별) Banzhaf/ComFedSV, + (b)oracle. `phase1_baseline_compare.py` 가 silo5에서 9-method를 한 궤적 위에서 비교(Ripple은 RIPPLE=0로 분리; eigsh flaky).

2 regime × 4 threat 매트릭스

	noisy (answer_swap)	freerider_z ero	freerider_ran dom	poison (backdoor)
silo5 (N=5, full participation, 1 domain/client)	✓	✓	✓	✓ (D2b config)
device100 (N=100, Dirichlet-α partial, domain-mix)	✓	✓	✓	✓ (per_client=300)

오케스트레이터: `codes/experiments/phase2_matrix.py` — env-parameterized [REGIME × THREAT × ALPHA × SEED], regime별 method-set 게이팅 + 4 detector 매 threat. 상세 → [02-experimental-setup](#).

0.4 핵심 용어집

용어	뜻
Flirds / Flirds-1st	우리 estimator(1차+2차 / 1차만). <code>core/flirds_estimator.py</code>
(a) oracle	재학습 기반 exact Shapley (Ghorbani-Zou 계열). coalition마다 FedAvg 재학습. <code>oracle/exact_sv_llm.py</code>
(b) oracle	in-run exact 2^N Shapley. 열린 궤적에서 coalition별 val-loss 변화 함. 재학습 X. <code>oracle/in_run_sv.py</code>
in-run	"한 번의 학습 궤적 안에서" 값을 매김 (재학습 없이). IRDS(In-Run Data Shapley)에서 차용한 핵심 idea
ComFedSV	FedSV + low-rank matrix completion (partial participation 보정). device100 전용 baseline. <code>baselines/comfedsv.py</code>

용어	뜻
D1 / D2 / D2b	backdoor 단계 진단 smoke. D1=no-FL install isolation / D2=FL model-replacement 전파 / D2b=working backdoor에 detector 반응. <code>phase2_backdoor*_smoke.py</code>
§ 3.9	plan의 "검출 baseline + 위협 매트릭스" 섹션(<code>flirds-implementation-plan.md:312</code>). poison-vs-Flirds framing 논쟁의 진원지
silos / device100	cross-silo N=5(full participation, 도메인당 1 client) / cross-device N=100(Dirichlet- α partial participation, per-client 도메인 혼합)
answer_swap	noisy 위협 = client 내부에서 completion을 셔플 → 정직하지만 나쁜 데이터(data-quality). <code>corruptors.py:28</code>
free_rider (zero/random)	가짜 update(0 또는 benign-std 매칭 random). Lin 2019 taxonomy. <code>corruptors.py:70</code>
backdoor	Xu 2023 instruction-trigger("tq")→target + Bagdasaryan γ -scaled model-replacement. <code>corruptors.py:47</code> + <code>llm_server.py:57</code>
poison_frac	backdoor에서 poison되는 sample 비율 = clean-preservation knob . 0.5-0.8=clean 보존+install, 1.0=clean 파괴
D2b config	backdoor가 전파되는 설정: <code>LR=2e-3 BATCH=8 EPOCHS=5 POISON_FRAC=0.8</code> (matrix 기본 <code>lr1e-3/batch16</code> 은 ASR=0)
proxy-truth	device100 off-anchor에서 (b) oracle이 너무 비싸 못 돌릴 때 Flirds를 검증된 대리 진실로 사용
HVP	Hessian-vector product. forward-over-reverse(<code>jvp◦grad</code>), $\mathbf{H} \cdot \mathbf{v}$ (forward; $\mathbf{H}^{-1}$ 절대 안 씀) → eager attention 필수

0.5 한 페이지 상태표 (3-state)

요지: 코드와 `phase1(silos N5)` 결과는 단단하다. **real grid**(매트릭스 전체)는 아직 한 번도 안 돌아갔다. `runs/phase2_matrix/` 는 빈 폴더(0 files); matrix는 stdout/ `/tmp` 에만 출력. (`phase2_matrix.py:122` , find 결과)

항목	상태	근거
Estimator + (a)/(b) oracle + LLM backend + FL 루프 + 5-domain 데이터	구현완료	<code>codes/flirds/</code> 전체; smoke green
Phase1 1B N=5 cross-silo, 3-seed (lr 1e-3 & 3e-3) — 9-method Spearman, AUROC, #7 selection	② 실제결과	<code>codes/runs/full_lr{1e-3,3e-3}/flirds-1b-N5-seed{0,1,2}/metrics.json</code>
task6 (a)-oracle 1B N=5 (fp32): (a)valloss= (b)=estimator +1.000	② 실제결과	<code>raw/.../2026-06-07-phase2-task6-a-retrain-oracle.md</code>
task6 3B N=5 (a)valloss vs (b) +0.900, estimator +1.000	② 1-seed	<code>raw/.../2026-06-08-phase2-task7-crossdevice-detection-redesign.md</code>

항목	상태	근거
task7 cross-device N=100 $\alpha=0.5$: Flirds vs (b)-perround +1.000; oracle 771ms/fwd	(b) 1-seed smoke	raw/.../2026-06-08-...redesign.md
task7e detectors N=100: STD-DAGMM FR 0.628 / FLTrust FR 1.0	(b) 1-seed	raw/.../2026-06-08-phase2-task7e-detector-suite-steps1-3.md
backdoor D1/D2/D2b 특성화 (install·전파·검출)	(b) 1-seed smoke	raw/.../2026-06-09-phase2-task7e-backdoor-install-fedddqc.md
step5 matrix orchestrator + task8 scale 코드	(a) 구현 +smoke	phase2_matrix.py ; 5 code paths green (tiny config)
device100 poison 해결 (per_client 40→300, ASR 0→0.75)	(b) 1-seed 탐색	raw/.../2026-06-09-phase2-step5-matrix-orchestrator-task8.md
real grid (silo5 N5 → device100 α -sweep → 3B → 7B, 3-seed 전체)	(c) 미실행	runs/phase2_matrix/ 빈 폴더
N=10 (a)-oracle (LLM)	(c) 연기	비용 2-5일/1-GPU → multi-GPU sharding 필요
7B (b)-oracle	(c) 미실행	matrix MODEL_CFG 경로에 있으나 미실행

문서 과장 교정(검증값 채택): ① poison detector STD-DAGMM·FLTrust = **0.75**(1.0 아님) ② "all methods +1.000"의 FedSV는 tiny-config서 **+0.900** (단 phase1 real은 +1.000) ③ STD-DAGMM runtime ~**360s**(~100s 아님) ④ D2b "evades-Flirds REFUTED" → matrix가 맞음: 표준 orientation서 **Flirds AUROC=0.0(EVADED)**. 상세 → [05-open-issues-and-next](#). 근거: [memory/phase2-step5-verification.md](#).

0.6 추천 읽기 순서

1. 이 문서(00) — 전체 지도
2. [01-research-value](#) — 알고리즘이 코드상 정확히 어떻게 도는가 + 노벨티
3. [02-experimental-setup](#) — 최종 실험 세팅(모델/regime/threat/하이퍼)
4. [03-baselines-and-prior-work](#) — baseline + 선행연구(PDF 1:1 대조) (가장 무거움)
5. [04-plan-vs-implementation-divergences](#) — plan 대비 달라진 점 11건
6. [05-open-issues-and-next](#) — 미해결 + 다음 단계(real grid)