

Flirds 체크포인트 01 — 알고리즘 + 노벨티

01 · 알고리즘 + 노벨티

코드(`codes/flirds/core/flirds_estimator.py`)를 직접 읽고 검증한 알고리즘 정확본 + 노벨티 주장(각 근거 첨부).
태그: **CODE** = 코드로 확인 / **DOC** = 문서(`plan/flirds.md`)에만 서술 / **PDF** = 원문 대조.

1.1 우리 알고리즘이 코드상 정확히 어떻게 도는가

입력

estimator는 `model·val·task`를 전혀 보지 않는다. 입력은 오직 (`flirds_estimator.py:6-8, :65-66`):

- `logs = [(w_r, deltas_map)]` — 열린 FedAvg 궤적. `deltas_map[c] = (Δw_c, n_c)` [CODE :87-89]
- `loss_fn(params, buffers) → scalar` — backend가 만든 val-loss closure (`backends/{cnn,llm}.py`)
- `pkeys` — 학습가능 param 이름들 (각 `w_r`를 `params=Taylor 변수` / `buffers=고정`으로 분리) [CODE :101-102]

핵심 계산 (round 루프, `flirds_estimator.py:97-131`)

각 round (`w_r, dm`)에 대해:

1. 참여 cohort `players = dm.keys()`, per-round FedAvg weight $pr[k] = n_k / \sum_{j \in \text{players}} n_j$ [CODE :98-100]
2. round aggregate $\Delta W^r = \sum_{k \in \text{players}} pr[k] \cdot \Delta w_k$ [CODE :109]
3. 1 HVP: $g, u = \text{jvp}(\text{grad}(\text{vloss}), (\text{params},), (dW,)) \rightarrow g^r = \nabla \text{val-loss}, u^r = H^r \Delta W^r$ [CODE :111]
4. 각 client: $\phi_k \leftarrow pr[k] \cdot \langle g^r, \Delta w_k \rangle + \frac{1}{2} \cdot pr[k] \cdot \langle \Delta w_k, u^r \rangle$ [CODE :128-131]

결과: $\phi_k = \sum_r pr[k] \cdot \langle g^r, \Delta w_k \rangle + \frac{1}{2} \langle \Delta w_k, u^r \rangle$ (docstring :13). [CODE 전체 검증]

비-자명한 설계 포인트 (모두 CODE)

- **round당 정확히 1 HVP**. 2차 quadratic-Shapley가 $u^r = H^r \Delta W^r$ 하나 + $|P_r|$ 개 내적으로 붕괴 (:26-28). 이게 비용의 핵심 — (b) oracle은 round당 2^N forward.
- **forward HVP H·v만 사용, H⁻¹ 절대 안 씀**. `jvp(grad(·))` = forward-over-reverse AD (`torch.func, :39, :55, :111`). → influence-function의 iHVP-inversion 비용/불안정성 회피.
- **true Hessian** (GGN/Fisher 아님). `jvp*grad`는 진짜 Hessian-vector product. GGN은 테스트 후 기각 [DOC `flirds.md:34`; raw 2026-06-03-phase05-estimator.md:48].
- **per-round participant weight** → partial participation(cross-device)서 정확, full participation(cross-silo)서 고정 $global\ n_k / \sum n$ 으로 환원 (:19-24).
- **participation normalization 없음** (locked): 값이 참여횟수에 비례 → tier 내 rank로 품질 회수 (:22-24).
- **sign**: client가 val-loss를 내리면 $\phi_k < 0$ (:28). selection은 가장 낮은 ϕ 를 keep (`phase1_clean_run.py:88-90`).
- **free-rider ϕ = 정확히 0**: $\Delta w_k=0 \rightarrow$ 모든 내적 0 → $\phi_k=0$ [CODE; 실측 `metrics.json` client 1 = 0.0 매 seed].
- **LLM val 청킹** (`loss_chunks`): val을 도메인별 청크로 쪼개 weighted-sum → full-val grad/HVP와 정확히 동일(선형), peak memory=1 청크. eager-attention HVP가 val=1000서 OOM 안 나게 (`flirds_estimator.py:42-62, backends/llm.py:35-51`).
- **fp32** (protocol 1): utility=loss차 $\sim 1e-3 < bf16$ 정밀도 $\sim 8e-3 \rightarrow bf16$ 불가 (`flirds_estimator.py:34, backends/llm.py:12-15`).

LLM backend의 3 musts (비-자명; CNN은 안 걸림) [CODE `backends/llm.py:14-68`]

1. `attn_implementation="eager"` — SDPA/flash는 forward-mode AD 미구현 → `jvp*grad` HVP 에러 (:14-20).

2. FL state를 `named_parameters()` 키로 (`...lora_A.default.weight`), `get_peft_model_state_dict` 아님; `load_state_dict(strict=False)` 동기화 (:4-6,:69).
3. `get_input_embeddings()._forward_hooks.clear() + use_cache=False` — SFTTrainer의 grad-checkpoint hook 이 functorch transform 안에서 금지 (:56-68).

(a)/(b) oracle와의 관계

- **(b) in-run oracle** (`oracle/in_run_sv.py`): estimator가 근사하는 대상. coalition별 $U_{(b)}(S) = \sum_r [\ell(w^r + \sum_{k \in S \cap P_r} p_k^r \Delta w_k) - \ell(w^r)]$ 를 exact 2^N enumeration으로 Shapley화 (`in_run_sv.py`:3-6,:71-122). estimator는 이걸 Taylor로 1 HVP 근사. cross-device는 `in_run_shapley_perround = round별 2^{|P_r|}` 분해 = 2^N 과 수학적 동일($\Delta \phi \approx 3e-16$, smoke phase2_crossdevice_oracle_smoke.py로 증명) [CODE](#).
- **(a) retrain oracle** (`oracle/exact_sv_llm.py`): coalition마다 FedAvg 재학습 → 배포모델 점수. utility=ROUGE-L(주) + -val-loss(검증용) :42-44,:85-89. 다른 게임. → [03](#) + [02](#).

1.2 기존 연구의 한계 → 우리 차별점 → 노벨티

우리가 직접 마주하는 한계들 (각 PDF/소스 근거)

선행 한계	근거	Flirds의 응답
재학습은 LLM-FL서 불가능 (Data Shapley는 CIFAR도 MC 필요)	Ghorbani-Zou 1904.02868v2.pdf PDF ; (a) $N=10=2^5$ 일/1-GPU	in-run(재학습 0): (b)/estimator는 round당 forward만
IRDS는 centralized-per-step-data-point	IRDS extract Data Shapley in One Training Run.md PDF	FL per-round client LoRA로 lift
IF는 iHVP collapse + 비수렴 → LLM서 약함	"Do IF Work on LLMs?" 2409.19998; Basu fragile 2006.14651 [DOC flirds.md:248]	forward HVP $H \cdot \Delta w$ (H^{-1} 안 씀) + in-run → 두 원인 모두 회피
FL-Shapley는 통신/서버연산 큼	GTG sub-model 재구성, FedSV O(Tm^2) util, ComFedSV "Everyone-Being-Heard" 라운드	통신 0 (vanilla FedAvg의 <code>deltas_map</code> 만 사용) [CODE estimator 입력=log스뿐]
FL-Shapley는 non-IID서 무너지고 rare("maverick") client를 과소평가	mavericks 2106.10734, volatility 2405.08044 DOC	(b) exact oracle로 안정화; 한계는 측정(검출 AUROC)
검출기는 noise/OOD/malicious를 다 "anomaly→discard"로 뭉갠	threads/noise-ood-malicious-client-separation DOC	signed value로 분리 시도; 못 푸는 부분은 특성화된 한계로 보고

차별점 / 노벨티 주장 (각 grounding)

1. 노벨티는 "최초 federated in-run"이 아니라 교집합 [DOC [flirds.md:241-243](#)]. Ripple Shapley(AAAI'26)가 이미 federated in-run을 점유. 주장하는 비점유 교집합 = client-level + in-run + closed-form 1st/2nd Taylor + HVP 상호작용항 + zero-extra-comm + LoRA/LLM. 근거=내부 4-agent + 외부 GPT 서베이(서술적; 코드 검증 아님).
2. Ripple 대비: Ripple=sample-level Jacobian propagation(eigsh, 재귀 chain) → 우리는 client-level closed-form Taylor, LoRA 명시, 2차 client-interaction항 명시 [DOC [flirds.md:235-239](#)]. 실측: Ripple ~4515s = Flirds(107s)의 ~42x, 검출도 가장 약함(noisy AUROC 0.50 ± 0.20) [[raw/.../2026-06-06-sv-baseline-port-and-results.md](#)].
3. FedIF 대비: FedIF(2025)=1st-order TraIn on Δw , CNN-only, aggregation 변경 → 우리는 2차 추가, LLM/LoRA, vanilla FedAvg 위 post-hoc valuation [DOC [flirds.md:245](#)].
4. 2차항이 FL에서 비로소 의미 [DOC](#): IRDS Appx E.2.2는 centralized per-step(작은 n)서 2차가 거의 무의미하다 함. FL per-round multi-step Δw 는 크므로 2차가 non-trivial. CNN 실측이 뒷받침: plain SGD서 1st+2nd Spearman $0.962 > 1st\ 0.924$; momentum 켜면 역전($1st\ 0.81 > 1st+2nd\ 0.73$) → 그래서 plain SGD 고정 [[raw 2026-06-03-phase05-estimator.md:75-80](#); [codes/CLAUDE.md §5](#)].

5. **속도/정확도 프론티어 지배** ⑥: N=5 near-additive → Shapley linearity로 (b)-utility 쓰는 모든 방법이 같은 ranking(+1.000) → Flirds가 5-15x 더 싸게 같은 답 (Flirds-1st 35s vs GTG/FedSV/oracle ~530s). 단 이걸 N=5 near-additive의 결과 — 큰 N·강한 상호작용서 분리력은 real grid로 확인 필요(©).
6. **free-rider ϕ 정확히 0** [CODE+⑥]: Flirds/(b)/Banzhaf/loss-heur는 정확 0; GTG/FedSV는 within-subset renorm 희석으로 $\neq 0$ → 우리 utility 정의의 깔끔함 입증.
7. **cross-domain valuation fairness hook** [CODE [backends/llm.py:83-88](#)]: per-domain macro-norm 옵션 (token-norm vs domain-macro). LESS/FedDQC 등은 magnitude만 부분완화, cross-domain 비교가능성은 미해결이라는 주장 [DOC](#).

솔직한 경계: 위 노벨티 중 1·2·3·7의 "비점유/미해결" 주장은 서술적 서베이 근거(코드로 증명 불가). 4·5·6은 실측 grounding 있음(단 5·6은 N=5 near-additive 한정 — 큰 N 분리력은 ©).

→ 알고리즘이 baseline들과 수식 차원에서 어떻게 다른지는 [03-baselines-and-prior-work](#).