

2 Flirds 체크포인트 02 — 최종 실험 세팅

02 · 최종 실험 세팅 (세부)

결정된 값 + 그 결정의 이유/흔적. 코드 우선(plan 서술과 같리면 코드가 정답). 태그 [CODE](#) / [DOC](#) / [b 실측](#).

2.1 모델 · regime · seed

축	값	근거
모델	1B = <code>meta-llama/Llama-3.2-1B-Instruct</code> (16L) · 3B = Llama-3.2-3B-Instruct (28L) · 7B = Llama-2-7B	[DOC <code>flirds.md:69</code>]; [CODE <code>phase2_matrix.py:80</code>]
regime	silos = cross-silo N=5 (full participation, 도메인당 1 client) · device100 = cross-device N=100 (Dirichlet- α partial, per-client 도메인 혼합, K=10/round)	[CODE <code>phase2_matrix.py:103,109</code> ; <code>llm.py:167</code>]
seed	3개 <code>[0,1,2]</code> (protocol 기본 <code>[42,123,2024]</code> 과 다름 — 코드가 <code>seeds=[0,1,2]</code>)	[CODE <code>phase1_clean_run.py:59</code> ; <code>phase2_matrix.py:375</code>]
α -sweep (device100)	<code>{0, 0.01, 0.1, 0.5, 5.0}</code> ; in-run oracle은 $\alpha=0.5$ 앵커 1점만	[DOC plan § 3.9]; [CODE <code>phase2_matrix.py:86</code> ALPHA env]
scale-up scale 메모리	1B batch16/val_chunk10 · 3B batch8/val_chunk5 · 7B batch4/val_chunk2, 전부 fp32 (7B도 bf16 안 씀 — bf16은 연기된 retrain oracle용)	[CODE <code>phase2_matrix.py:97-100</code>]

est-vs-oracle 비교 매트릭스 (LOCKED 2026-06-04) [DOC](#) : CNN retrain & in-run oracle $N \in \{5,10\}$. LLM 1B retrain & in-run oracle $N=5$ now / $N=10$ 연기. LLM 3B $N=5$ 만. LLM 7B in-run oracle $N=5$, retrain oracle X. estimator METHOD(noisy-AUROC-selection, oracle 불필요)는 $N=10$ 서도 가능.

2.2 데이터 레이어 (5-domain cross-silo)

`data/llm.py` — `build(n_clients, per_domain_train, per_domain_val, per_domain_test, seed, noisy=, backdoor=)` → `(clients, val_records, test_records)` . $N \in \{5,10\}$ `assert ( llm.py:167 )` . $N=5$ → 도메인당 1 client; $N=10$ → 도메인당 2 client(disjoint 절반).

도메인	HF dataset	val 출처	근거
medical	<code>medalpaca/medical_meadow_medical_flashcards</code>	train-carve	[CODE <code>llm.py:69-80</code>]
legal	<code>ibunesco/qa_legal_dataset_train</code>	train-carve	//

도메인	HF dataset	val 출처	근거
finance	LLukas22/fiqa	native test	//
math	deepmind/aqua_rat (config raw, rationale)	native validation	//
general	databricks/databricks-dolly-15k	train-carve	//

- 크기: per-domain train=12,000 / val=200(총 1,000) / test=2,000, 상호 disjoint [CODE phase1_clean_run.py:58-59]. val=1,000 ≠ 1,024(=2^10 coalition) 의도적 분리 [DOC plan § 3.4].
- 5 도메인 모두 free-form instruction→response (cross-domain 포맷 균일성 = 노벨티 hook; 이질 포맷이면 shared-val-loss Shapley가 불공정) [DOC threads/dataset-format-uniformity].
- equalized train = size CONTROL 변수 (B1) **DOC**.
- per-domain normalization 옵션 (backends/llm.py:80-88): token-norm n_c/N_{tot} (기본) vs domain-macro $n_c/(D \cdot n_d)$ (ablation arm). domain-norm은 ϕ 순서를 눈에 띄게 바꿈 **CODE**.

device100: build_crossdevice(n_clients, alpha, per_client, per_domain_pool, ...) via fl.partition.client_dirichlet_partition (per-CLIENT Dir(α) 도메인-혼합 = **Option B**; 고정크기·전부 non-empty- $\alpha=0$ =도메인 disjoint) [CODE partition.py:49-82]. per_client = 300 (40→300 변경; 04 참조) [CODE phase2_matrix.py:109].

2.3 LoRA · 학습 하이퍼 · fp32 이유

[CODE phase1_clean_run.py:124-125, :44, :58; llm_server.py:46,52-53]

```
LoraConfig(r=16, lora_alpha=32,
           target_modules=["q_proj", "k_proj", "v_proj", "o_proj", "gate_proj", "up_proj", "down_proj"],
           lora_dropout=0.0, task_type="CAUSAL_LM")
# 학습: SGD momentum=0 (forced), constant lr, completion_only_loss=True; bf16=False, fp16=False
```

- phase1 FULL: rounds=50, max_steps=10, lr=2e-5, batch=16, maxlen=768, val_maxlen=384, val_chunk=10 [CODE phase1_clean_run.py:58].
- phase2 matrix 기본(smoke): silo5 lr=1e-3, rounds=10, max_steps=10, batch=16, val=20; device100 rounds=30, max_steps=5, val=10 — coarse smoke값 [CODE phase2_matrix.py:103,109].
- SGD momentum=0 강제 [CODE llm_server.py:52-53; codes/CLAUDE.md § 5]: IRDS/Ripple per-step 가정; momentum 켜면 2차 Taylor 열화.
- fp32 master, 왜 bf16 불가: utility=coalition val-loss 차 ~0.005-0.02 < bf16 정밀도 ~0.009 → bf16서 Spearman 무의미. fp32서 +1.000 [CODE oracle/exact_sv_llm.py:62-63; ② raw 2026-06-07-phase2-task6-a-retrain-oracle.md]. eval forward도 fp32(HVP 수치 안정).
- attn_implementation="eager" [CODE phase1_clean_run.py:123]: forward-mode AD HVP가 SDPA/flash서 NotImplementedError.

△ **plan-vs-code divergence**: plan § 3.3은 phase1 lr=2e-5(fine-tune scale), matrix는 비교실험용 lr=1e-3/2e-3(빠른 수렴). matrix smoke는 final 값이 아님 — real grid는 config 재고 필요. 04 참조.

2.4 위험 4종 정의 — 어떤 논문 근거로 왜 그렇게 정의했나

data/corruptors.py + fl/llm_server.py. 상세 PDF 대조 → 03.

noisy (data-quality) — answer_swap [CODE corruptors.py:28-39]

- 무엇: client 내부에서 completion 컬럼을 permute → 각 prompt가 다른 행의 answer와 짝. prompt 불변.

- 왜 이렇게: "정직하지만 나쁜 데이터" = data-quality 위험 (악의 아님). FedDQC의 IRA가 정확히 이걸 잡도록 설계 — 매칭 detector = FedDQC [DOC [threads/data-quality-vs-data-value](#)].

free-rider — `free_rider(ref, mode)` [CODE [corruptors.py:70-93](#)]

- **zero:** $\Delta w=0 \rightarrow \phi$ 정확히 0 (자명검출). **random:** $\Delta w \sim U(-scale, scale)$, benign-std 매칭(`scale=benign_std *  $\sqrt{3}$` , `phase2_matrix.py:219-220`) $\rightarrow \phi \approx 0$.
- 왜 이렇게: Lin et al. 2019 (STD-DAGMM 원논문, [1911.12560](#)) free-rider attack taxonomy의 easy 쪽 [PDF](#) . 어려운 delta/advanced-delta는 advanced free-rider로 연기 (이전 global model을 FL 루프에 threading 필요).

poison (malicious) — `backdoor()` + `scaled_attackers` [CODE [corruptors.py:47-63](#) + [llm_server.py:57-58](#)]

- 무엇: Xu 2023 instruction-trigger "`tq`" $\rightarrow$ target string, `poison_frac` 만큼 poison (clean-preservation knob) [PDF web-extract [2305.14710](#)]. + Bagdasaryan 2020 plain-scaled model-replacement `delta  $\times$  attack_scale` (γ =cohort size= n/η) [PDF web-extract [1807.00459](#)].
- 왜 이렇게: backdoor는 새 위협(원 plan에 없던). Xu=instruction-tuning backdoor 표준, Bagdasaryan=FL 전파 메커니즘. DBA(Xie2020, 다중공모)는 제외. 우리는 stealthy constrain-and-scale 안 함 — plain-scaled만(attacker $\parallel \Delta \parallel = 40 \times$ benign $\rightarrow$ norm-bound가 backdoor 죽임 $\rightarrow$ stealthy arm 불가).
- working-backdoor config 필요: 전파엔 `LR=2e-3 BATCH=8 EPOCHS=5 POISON_FRAC=0.8` [CODE [phase2_matrix.py:40-44](#)]; matrix 기본 lr1e-3/batch16은 ASR=0(batch16이 attacker install step 절반).

왜 검출을 하나 (우리가 라벨을 주입하는데): method는 라벨에 **blind**; 라벨은 평가 KEY(AUROC)지 method 입력이 아님 $\rightarrow$ 순환 아님. 두 목적: (1) value SEMANTICS 검증(corrupt $\rightarrow$ low value; oracle은 "Shapley 계산 일치"만 증명) (2) 전용 detector 대비 경쟁 bar [DOC [MEMORY.md](#) detector 섹션].

2.5 in-run oracle 비용 공식

$U_{(b)}(S) = \sum_r [\ell(w^r + \sum_{k \in S \cap P_r} p_k^r \Delta w_k) - \ell(w^r)]$, exact 2^N enumeration [CODE [in_run_sv.py:3-6, :71-104](#)].

- 비용 = $2^N \cdot R \cdot val \cdot seq$, FLOP-bound [DOC [flirds-protocol.md:90](#) ; CODE [phase1_clean_run.py:52-54](#)]. N5 $\leftrightarrow$ N10 = 32 $\times$.
- 실측 cross-device: oracle **771ms/fwd** (fp32-B200, no-tensor-core) $\rightarrow$ R=200이면 $\sim 44h/1-GPU \rightarrow \sim 11h/4-GPU \rightarrow \alpha$ 1-2점만 [[b](#) raw [2026-06-08-...redesign.md](#)].
- cross-device는 `in_run_shapley_perround` = round별 $2^{|P_r|}$ 분해 (2^N 과 동일, $\Delta \phi \approx 3e-16$) $\rightarrow$ N=100서 2^{100} 대신 200×1024 [CODE [in_run_sv.py:126-165](#)].

2.6 검출 정보를 성능 향상에 쓰는 법 (selection/filtering)

[CODE [phase1_clean_run.py:88-90, :157-158](#)]

```
def select_topk(phi, k): # 가장 낮은  $\phi$  k개 = 가장 가치있는 client (val-loss 최대 감소)
    return sorted(range(len(phi)), key=lambda i: phi[i])[:k]
arms = {"full": all_idx, "flirds_topk": keep, "random_k": rand} # K=3 (N=5서 2개=noisy+FR 드롭)
```

성공기준: `flirds_topk val_loss  $\leq$  random_k and ROUGE-L  $\geq$  random_k` [CODE [read_runs.py:53](#)].

selection run 실측 결과 [b](#) 1B N=5 cross-silo, 3-seed, lr 1e-3 & 3e-3

직접 `codes/runs/full_lr{1e-3,3e-3}/.../metrics.json` 6개 파일 대조:

	lr=1e-3 (seed 0/1/2)	lr=3e-3 (seed 0/1/2)
flirds_keep (set)	<code>{2,3,4}</code> 모두 동일	<code>{2,3,4}</code> 모두 동일

	lr=1e-3 (seed 0/1/2)	lr=3e-3 (seed 0/1/2)
client1 (free-rider) ϕ	0.0 exact 매 seed	0.0 exact 매 seed
AUROC noisy / FR	0.75 / 1.0 (3 seed 동일)	1.0 / 0.75 (3 seed 동일)
flirds_topk vs full	항상 이김 (예 s0 2.40398<2.41421)	항상 이김 (단 margin 작음, s0 2.39724<2.39759)
flirds_topk vs random_k	s0 tie(random도 {2,3,4}), s1·s2 이김	s0 tie, s1·s2 이김

확인된 것: Flirds가 noisy(c0)+free-rider(c1)를 정확히 드롭하고 clean {2,3,4}만 keep — 양 lr-전 seed 일관. free-rider ϕ =0 exact.

정직한 nuance 2개 (직접 metrics.json 대조로 발견):

1. **seed0**은 **random**이 우연히 같은 **clean set {2,3,4}**를 골라 **tie** (val_loss curve 동일). "beats random" 근거는 seed1/2 (random이 corrupted 포함 시: s1 random={1,2,3} FR포함→짐, s2 random={0,1,2} noisy+FR포함→짐). → "beats random"은 **cross-seed 평균** 주장이지 매-seed 아님.
2. **AUROC가 lr로 뒤집힘**: lr1e-3 noisy 0.75/FR 1.0 ↔ lr3e-3 noisy 1.0/FR 0.75. noisy client(c0) ϕ 부호가 lr 의존(lr1e-3서 -0.0084, lr3e-3서 +0.0096). MEMORY는 lr1e-3(0.75/1.0)만 기재 → **lr3e-3 반전은 실제 run 파일에만 있는 caveat**. selection(flirds_keep)은 양 lr 동일하므로 결론 불변.

신호는 작지만 일관 — "random은 어려운 bar(FedDQC/DsDm)" caveat는 (corrupted를 random이 포함하는 seed서) 통과.