

4 Flirds 체크포인트 04 — plan 대비 구현 분기

04 · plan 대비 달라진 점 (+ 왜)

처음 plan과 실제 구현이 갈라진 지점 전부 + 각 근거(raw 대화/코드). 시간순. 분기는 실패가 아니라 대부분 Yonghee의 설계결정 (explanation→decision→execution).

#	분기	날짜	근거(raw)
1	curvature GGN/Fisher → true Hessian	06-03	2026-06-03-phase05-estimator.md
2	momentum=0.9 → plain SGD mom=0 (전 FL run)	06-03	"
3	dataset PubMedQA/CaseHOLD → MedAlpaca/QA-Legal (free-form)	06-04	2026-06-04-phase1-data-layer.md
4	retrain oracle 주 metric ROUGE → val-loss	06-07	2026-06-07-phase2-task6-a-retrain-oracle.md
5	oracle 정밀 bf16 → fp32	06-07	"
6	detector threat-matched 재설계 (+FedDQC, +poison 위협)	06-08	2026-06-08-phase2-task7-crossdevice-detection-redesign.md
7	partition per-class Dir → per-client Dir (Option B)	06-08	"
8	Ripple를 비교서 분리 (RIPPLE=0 , eigsh flaky)	06-06~07	2026-06-06-sv-baseline-port-and-results.md
9	N=10 retrain oracle 연기 (2~5일)	06-07	2026-06-07-phase2-task6-...md
10	device100 per_client 40 → 300 (poison install)	06-09	2026-06-09-phase2-step5-matrix-orchestrator-task8.md
11	matrix = 신규 파일 <code>phase2_matrix.py</code> (comparator 확장 아님)	06-09	"

1. curvature: GGN/Fisher → true Hessian (06-03)

- 원: IRDS 프레이밍 따라 Gauss-Newton/Fisher(PSD) 곡률.
- 변경/왜: CNN Phase0.5서 GGN을 테스트 → 진짜(indefinite) Hessian보다 일반적으로 나쁨(relL2 8/9 config서 열등). Yonghee 결정. [2026-06-03-phase05-estimator.md ; flirds.md:34]. 지금 `jvpograd=true` HVP.

2. momentum=0.9 → plain SGD mom=0 (06-03)

- 원: `local_train` 기본 momentum=0.9.
- 변경/왜: code-review가 Ripple drop항·IRDS가 plain SGD 가정임을 지적. 즉시 보상: plain SGD서 3-seed Spearman가 "1st 0.81 > 1st+2nd 0.73(2차 해로움)" → "1st+2nd 0.96 > 1st 0.92(2차 도움)"로 역전. 이제 보편 규약 [codes/CLAUDE.md §5 ; llm_server.py:52-53]. → 2차항 노벨티의 실증 기반(07).

3. dataset 교체 → free-form (06-04)

- 원(D3, 06-02 lock): PubMedQA + CaseHOLD + FiQA + AQUA + Dolly.
- 변경/왜: PubMedQA/CaseHOLD는 classification 포맷(closed/yes-no) → "free-form instruction→response 균일성" 결정과 충돌(이질 포맷이면 shared val-loss Shapley 불공정). medical→ `medical_meadow_flashcards`, legal→ `ibunescu/qa_legal`. FedDQC 도메인 겹침 3/5→2/5(허용; FedDQC 비교는 IRA-baseline만). [`2026-06-04-phase1-data-layer.md`].

4. retrain oracle 주 metric: ROUGE → val-loss (06-07) — 방법론적으로 가장 중요

- 원: retrain oracle을 ROUGE-L(CNN test-acc 유추)로 프레임.
- 변경/왜: Yonghee 교정 — 우리 method(estimator/in-run oracle)가 Shapley를 *옳게 계산*하는지 검증하려면 retrain oracle가 **같은 게임(val-loss)** 풀어야. ROUGE는 다른 게임(불일치가 metric 탓일 수 있음). estimator는 val-loss의 Taylor → apples-to-apples 필수. ROUGE는 미분불가→estimator-ROUGE 불가능, in-run ROUGE도 infeasible. 실측이 정당화: retrain val-loss=in-run oracle=estimator +1.000 vs retrain ROUGE 발산(1B +0.4, 3B -0.9, answer_swap의 도메인-포맷 학습에 속음). [`2026-06-07-phase2-task6-...md`].

5. oracle 정밀: bf16 → fp32 (06-07)

- 변경/왜: bf16 절대정밀도 ~0.009 > coalition val-loss 차 ~0.005-0.02 → bf16서 Spearman 무의미. fp32서 양 lr +1.000. [`2026-06-07-phase2-task6-...md` ; `oracle/exact_sv_llm.py:62-63`]. "fp32 master"는 비협상 규약.

6. detector threat-matched 재설계 (06-08) — 검출 baseline 전면 개편

- 원(06-07 lock): FLDetector→cross-silo noisy / STD-DAGMM→cross-device free-rider (regime로 분리).
- 변경/왜: Yonghee 탐문이 **위협 불일치** 발견 — FLDetector는 crafted-update 검출기지 정직한 answer_swap 검출기 아님 → 0.50 noisy AUROC는 off-threat(non-IID erosion 아님). answer_swap엔 매칭 detector 없음 → **FedDQC 신규 추가**. 재설계: data-quality→FedDQC / free-rider→STD-DAGMM+FLTrust / poisoning→FLDetector+FLTrust, **양 detector 양 regime**. 동시에 **poison/backdoor** 신규 위협(Xu+Bagdasaryan) 도입 — 원 Phase2 plan에 없던 것. [`2026-06-08-...redesign.md:64-76`].

7. partition: per-class → per-client Dirichlet (06-08)

- 원: 기존 `dirichlet_partition` (per-class-over-clients, Hsu 2019).
- 변경/왜: 5 도메인→100 client서 degenerate($\alpha=0 \rightarrow 5$ non-empty만; $\alpha=0.01 \rightarrow 44$; 크기 0-12k). 신규 `client_dirichlet_partition` (Option B: per-client Dir(α) 도메인혼합) = 전부 non-empty-고정크기(B1 size-control 보존)- $\alpha=0$ =도메인 disjoint. [`2026-06-08-...redesign.md:12-23` ; `partition.py:49-82`].

8. Ripple 비교서 분리 (RIPPLE=0) (06-06~07)

- 원: Ripple를 모든 비교표의 head-to-head baseline.
- 변경/왜: eigsh CPU-spinning stall(알려진 수렴 flaky) → 자동 배치서 불안정. `phase1_baseline_compare.py` 는 RIPPLE=0; Ripple 값은 06-06 단일 세션 것 사용. [`2026-06-06-...md` ; `2026-06-07-phase2-banzhaf-...md`]. 이후 CNN `ripple.py` 에 eigsh guard 구현(maxiter=1000 상한-고정 v0-ncv 확대 1회 재시도:partial-수렴 fallback; tol=0 유지) → **Track C1 CNN fidelity 비교에는 Ripple 포함** (a) (plan §3.11 결정 ⑥); C2 개입 arm 제외(비인과)-LLM 비교 분리는 유지.

9. N=10 retrain oracle 연기 (06-07)

- 원(매트릭스 06-04 lock): LLM 1B retrain oracle N=5 and N=10.
- 변경/왜: retrain-oracle validation 비용 추정 — N=10 재학습 $64 \times (\Sigma(10,s)-s=5120 \text{ vs } 80) + \text{eval } 32 \times \rightarrow 2\text{-}5\text{일}/1\text{-GPU}$. multi-GPU coalition sharding 미구축. N=5 fp32 검증(+1.000)으로 method 검증 충분. [`2026-06-07-phase2-task6-...md:85-94`]. LLM N=10 연기는 유지; 대신 **Track C1(CNN)에서 N=10 full 2¹⁰ 듀얼 oracle((a) retrain val-loss fp32 + (b) exact in-run) 설계-구현 완료** (a) (plan §3.11; 예상 비용 (a) ~11h(MNIST)/~9h(CIFAR) per config, 실측 run은 본 실험 세션).

10. device100 per_client 40 → 300 (06-09)

- 원: cross-device `per_client=40` (free-rider/noisy와 일관).
- 변경/왜: backdoor install엔 attacker당 ~200 poisoned 필요(backdoor install test). `per_client=40-frac0.5→75` poisoned<threshold→ASR=0(전파/코드 버그 아님; silo5 동일코드=ASR 1.0). 4-GPU sweep(single-shot R10/30/60, multi-round y4/10, multi-attacker 5%/10% **전부 ASR=0** — attacker 늘려도 install은 client별 local이라 무용) + A'(per_client=300/frac0.8→240 poisoned/EPOCHS5/R60→**ASR=0.75**). noisy/free-rider는 size-무관 → 300이 regime 통일. 탐색코드(poison_multiround 등) revert. [`2026-06-09-...task8.md:135-152` ; `phase2_matrix.py:105-109`].

11. matrix = 신규 파일 (06-09)

- 원: `phase1_baseline_compare.py` 확장 가능성.
- 변경/왜: Yonghee fork 결정 — 검증된 N=5 +1.000 comparator 보존 위해 신규 `phase2_matrix.py` (bit-identical call pattern만 재사용). 유일 코드변경 → baselines 무변경 → CNN bit-identical guard green. [`phase2_matrix.py` ; `2026-06-09-...task8.md`].

추가 관찰(plan vs code, 분기는 아니나 주의):

- phase1 $lr=2e-5$ (§3.3) vs matrix smoke $lr=1e-3/2e-3$ — matrix는 비교실험용 빠른수렴 config, final 아님. real grid는 06-10 착수·실행됨 — 22/25 셀 `runs/phase2_matrix/rundirs/*/metrics.json` 영속화 완료(커밋 8d364cc 20셀 + b9113c4 poison 2셀; 남은 3셀 =dev_a0.5 anchor {noisy, frrand, frzero}).
- plan §3.5 cross-device R=200 vs matrix smoke R=30 — smoke 기본 coarse, real은 env override.
- seed `[0,1,2]` (코드) vs protocol `[42,123,2024]` — 코드가 실제값.