

5 Flirds 체크포인트 05 — 이해결 + 다음 단계

05 · 이해결 이슈 + 다음 단계

판단 대기 / 알려진 caveat / 즉시 다음 단계. 근거: 코드·raw 로그: `memory/phase2-step5-verification.md`.

5.1 판단 대기 — poison vs Flirds framing (verification-item #1)

기술적 사실은 ruling 났으나, 논문 headline framing + real-config 재확인은 미결.

- 충돌: backdoor detection test smoke(`phase2_backdoor_d2b_smoke.py`)는 "clean-preserving backdoor가 Flirds를 evade한다 = REFUTED"라 결론(Flirds-1st/2nd 전부 AUROC=1.0) [plan `flirds-implementation-plan.md:337`]. 그러나 matrix(full working-backdoor config, `/tmp/flirds_matrix_poison_batch8.log`)는 표준 검출 orientation(corrupt=high ϕ)서 **Flirds-1st AND -2nd = AUROC 0.0 = EVADED**라 보고 — 원 threat matrix 가설 CONFIRM [plan `:343`].
- ruling (검증세션, `memory/phase2-step5-verification.md:18-27`): matrix가 맞다. backdoor detection test가 오해의 소지. backdoor detection test는 `roc_auc_score(labels, - $\phi$ )` 로 per-threat 라벨지식을 써 부호를 뒤집어 1.0을 만든 것 → attacker의 ϕ -extremeness를 검출로 오독. 본질은 Taylor-approximation 실패: $pr[a] \cdot \gamma = 1$ 이라 loss-heur와 Flirds-1st가 같은 δ_0 에 작용하는데, loss-heur=exact secant는 overshoot 잡아 1.0, Flirds=tangent는 속아 0.0(loss-heur Spearman vs Flirds=+0.000). exact in-run util/in-run oracle은 잡고, linearization만 blind. (docs의 " γ -overshoot"는 부정확 — γ 는 상쇄됨.)
- 정리: attacker는 ϕ -extreme(two-sided/magnitude/loss-heur catchable)이지 ϕ -high 아님. 정직한 threat matrix headline = "Flirds는 noisy+free-rider를 잡고, clean-preserving backdoor엔 EVADED; matched detector(FLDetector/FedDQC/loss-heur)가 보완".
- real config 재확인 완료: silo5_poison 3-seed 연속화 run(`runs/phase2_matrix/rundirs/silo5_poison/metrics.json` , 커밋 8d364cc) — (b)oracle-loss-heur AUROC 1.000(잡음), Flirds-1st 0.000(완전 회피 — .log-only run과 공통), Flirds(2차) 0.917±0.118 per-seed [0.75, 1.0, 1.0]. 이전 .log-only run은 {0, 0.25, 1.0}(0.417±0.425) — 두 run 모두 실측이며 어느 쪽도 무효 아님, run간 분산이 큼.
- 여전히 열린 것: 이 framing을 논문 headline으로 확정 = Yonghee 결정 대기.

5.2 claimed-vs-verified 교정 (문서 과장 → 검증값 채택)

검증세션(`memory/phase2-step5-verification.md`)이 잡은 과장. 충돌 시 검증값 채택, 충돌 자체 기록.

#	문서 주장(claimed)	검증값(verified)	근거
1	poison detector "FLDetector-STD-DAGMM-FedDQC 전부 1.0"	STD-DAGMM-FLTrust = 0.75 (single-shot이 mean-pooling서 희석: attacker가 10 round 중 1번만 malicious; real R≈30서 더 나뉨). FLDetector+FedDQC+loss-heur만 robust 1.0	<code>verification.md:29-31</code>
2	"ALL methods Spearman +1.000 vs in-run oracle"	tiny-config서 FedSV +0.900(tiny-config noise). 단 phase1 real 3-seed는 FedSV +1.000 — matrix-orchestrator build smoke와 phase1 real을 혼동한 것	<code>verification.md:32</code> ; <code>phase1 metrics.json</code>
3	"STD-DAGMM AE-CPU ~100s"	runtime ~360s(또는 그 이상; 한 run 526s 관측). ~85~110s는 AE 학습 컴포넌트만	<code>verification.md:32</code>
4	backdoor detection test "evades-Flirds REFUTED" (Flirds AUROC 1.0)	표준 orientation서 Flirds AUROC 0.0 (EVADED) — §5.1	<code>verification.md:18-27</code>

주의: 위 1-3-4는 원래 tiny-config smoke(Ⓐ)/1-seed 기반이었으나, real grid서 측정·영속화됨(runs/phase2_matrix/rundirs/ , 22/25셀) — 특히 #4는 real silo5_poison 3-seed서 Flirds(2차) 0.917±0.118로 완전-EVADED 아님(Flirds-1st는 0.000 유지; 상세 \$5.1). phase1 silo5 N5(Ⓑ)는 3-seed로 단단함.

5.3 알려진 caveat (버그 아님, real-config서 확인 필요)

- **tiny-config 수치 전반**: matrix-orchestrator build 5 code paths는 val=20/R≤10 smoke — 값 coarse, 구조/orientation/gating만 검증. device100 anchor per-round in-run oracle +0.999, GTG 0.93/FedSV 0.82/ShapleyFL 0.86는 R=4 tiny.
- **selection run nuance**(직접 metrics.json 대조): seed0은 random이 우연히 clean set {2,3,4} → tie; "beats random"은 cross-seed. AUROC가 lr로 반전 (lr1e-3 noisy0.75/FR1.0 ↔ lr3e-3 1.0/0.75) — MEMORY는 lr1e-3만 기재. selection은 양 lr 동일. → 02.
- **ComFedSV** tiny-R서 Spearman 낮음(R≤8 completion-starved; cross-device port R=30서 +1.000). real은 R≈30 필요.
- **device100 corrupt-seen** R≈30 필요(짧으면 corrupt가 안 보임).
- **device100 poison ASR**: real config 실측됨(커밋 b9113c4, rundirs/dev_a*_poison/metrics.json) — dev_a0.0_poison ASR=[1.0, 1.0], dev_a0.5_poison ASR=[0.675, 0.825, 0.0] (α=0.5서 cross-device 회색-seed 분산).
- **Ripple eigsh flaky**(CPU spinning stall) → 비교는 RIPPLE=0, 값은 06-06 단일세션.
- **3B retrain val-loss vs in-run oracle +0.900**(1B는 +1.000) = clean-client 1-swap=retrain noise; estimator는 +1.000 유지. 1-seed.
- **FedDQC** per-domain IRA 분산 큼(finance 0.17≈noisy 0.067) → noisy 도메인/seed 변주 필요. 1-seed smoke.
- **N=100 detector(STD-DAGMM-FLTrust)**: device100 real grid 3-seed 확보(14셀, runs/phase2_matrix/rundirs/dev_*/metrics.json ; α=0.5 anchor {noisy,frand,frzero} 3셀만 미실행) — 예: FLTrust FR 셀 측정 전 α(0/0.01/0.1/5.0) 1.000±0.000 / noisy α별 0.602–1.000, STD-DAGMM 셀별 분산 큼(0.508–1.000).

5.4 3-state 미실행 항목 (Ⓒ)

real grid는 실행·영속화됨(상세: 07 \$7.0) — runs/phase2_matrix/rundirs/ 에 22/25 셀 metrics.json 영속화(커밋 8d364cc 20셀 + b9113c4 poison 2셀; 잔여 3셀 = dev_a0.5 anchor {noisy, frand, frzero}).

- **real grid**: silo5 N5 4-threat 3-seed Ⓑ DONE + device100 α-sweep{0,0.01,0.1,0.5,5.0} 3-seed 14셀 DONE(dev_a0.5 anchor {noisy, frand, frzero} 잔여) + 3B 4-threat 1-seed DONE — 전부 rundirs/ 영속화. 7B tier만 Ⓒ.
- **N=10 retrain oracle**(LLM): 2–5일/1-GPU → multi-GPU sharding 필요. Ⓒ 연기.
- **7B in-run oracle**: matrix MODEL_CFG 경로에 있으나 미실행. Ⓒ
- **free-rider delta/advanced-delta(Lin Attack II/III)**: advanced free-rider. Ⓒ

5.5 즉시 다음 단계 — real grid 실행 (cost-tiered stage-gate)

전략 LOCKED 06-09 (Yonghee) = cost-tiered stage-gate:

1. **cheap-first by cost tier**: N5(silo5, 530s) → N100(device100, 11h@1점) → 3B → 7B.
2. **category-together**: 한 (regime,threat,seed) 궤적은 비용 무관 모든 비교 method를 같이 — 공유 로그 위 공정비교(절대 cheap subset 먼저 아님).
3. **in-run oracle = anchor not comparand**: N5엔 530s로 비교군, N100엔 11h라 α=0.5 1점 앵커만(나머지 α는 Flirds proxy-truth).
4. **adaptive**: tier 결과가 예상 밖이면 큰 tier 계획 수정.

실행 전 체크리스트:

- [] **poison threat**은 별도 invocation LR=2e-3 BATCH=8 EPOCHS=5 POISON_FRAC=0.8 (device100은 + ROUNDS=60 MAX_STEPS=10). matrix 기본 lr1e-3/batch16은 ASR=0.
- [] real config(full val, fp32, R 충분)로 \$5.1 poison-vs-Flirds + \$5.2 교정값 재측정 → threat matrix framing 확정(Yonghee).
- [] phase1 lr 결정(2e-5 fine-tune vs 1e-3 비교용) — config 재고(04).
- [x] 3-seed N=100 detector(STD-DAGMM-FLTrust) 확보 — runs/phase2_matrix/rundirs/dev_* 14셀(α∈{0,0.01,0.1,5.0} ×{noisy,frand,frzero}+poison 2셀) 전부에 STD-DAGMM-FLTrust 포함. 단 dev_a0.5 anchor {noisy,frand,frzero} 3셀은 아직 미영속화.
- [x] matrix 결과 파일 영속화 완료 — runs/phase2_matrix/rundirs/<cell>/metrics.json 22/25 셀 영속화(커밋 8d364cc + b9113c4).

git 상태(운영): main이 origin보다 앞섬(미푸시 누적). device100-poison 해결 + per_client=300 커밋 상태는 [CLAUDE.md](#) 참조. Claude는 push 불가 (creds 없음) → Yonghee push.

5.6 한 줄 결론

코드와 phase1(silo5 N5, 3-seed)은 단단하다. 방법은 retrain oracle = in-run oracle=estimator + 1.000으로 검증됐다. real grid는 22/25셀 실행·영속화 완료([runs/phase2_matrix/rundirs/](#), 커밋 8d364cc+b9113c4; 잔여 3셀=dev_a0.5 anchor {noisy, frand, frzero}, 7B tier는 ) — (1) 큰 N 분리력, (2) detector 경쟁, (3) poison-vs-Flirds framing 전부 real config 실측 확보, **headline framing 확정**(Yonghee 결정, \$5.1)만 잔여. 추가로 06-12 Track C/D 표준-세팅 비교 실험 설계 확정([flirds-implementation-plan](#) §3.11): **Track C(C1 CNN fidelity&cost · C2 CNN 일반성능+개입 3종 · C3 cross-seed stability) 구현 완료** =  (커밋 5b0ba71; 구현+단위검증 green, 실측 없음), **Track D(LLM 표준세팅, 전부 API-free)** =  (설계만).