

Flirds 체크포인트 07 — novelty·한계 분석 + 개선 제안

00-06 작성 후 같은 날 오후의 분석 세션. checkpoint 문서 직접 정독 + 8개 병렬 reader(checkpoint·flirds.md·threads·plan·protocol·코드·raw)로 교차 정독 + load-bearing 주장 4건 직접 검증. \$7.0은 00 \$0.5 / 05 \$5.4의 'real grid 미실행'을 SUPERSEDE.

07 · novelty·한계 분석 + 개선 제안

목적: "이 연구의 novelty와 한계는 무엇이고, 어디를 개선할 수 있나"에 대한 종합 판정. **방법:** 00-06 직접 정독 + 8방향 병렬 reader 교차 정독 + 직접 검증 4건(FedIF 부재 grep, runs/ 상태, tier1 로그, baselines 디렉토리). 모든 정량 주장에 경로 근거, 3-state(Ⓐ/Ⓑ/Ⓒ) 구분. 경쟁자 3종(FedIF/FedTSV/Ripple)의 상세 포지셔닝은 06-closest-competitors-fedif-fedtsv-ripple — 이 문서는 그 위에서 novelty 방어력·한계·개선을 판정.

7.0 ✂ SUPERSEDE: real grid가 시작됐다 (00 \$0.5 / 05 \$5.4의 "미실행" 교체)

checkpoint 작성(06-10 00:50) 직후 real grid가 시작됨. 직접 확인(06-10 오후):

- tier1 (silos 4-threat × 3-seed, 1B) 완료 — runs/phase2_matrix/tier1/silos_{noisy, freerider_zero, freerider_random, poison}.log (03:58-04:14 완료). noisy/FR = $1r1e-3$ /batch16, poison = D2b config $1r2e-3$ /batch8, 전부 R=10, ORACLE_B+COALITION on.
- tier2 (device100 α-sweep 12 cells) 진행 중 — tier2/_driver.log (09:27 시작, 4-GPU). △ 일부 cell이 done[CHECK] 플래그 → 확인 필요.
- △ 전부 평문 .log만 — protocol \$6 run-dir(config·git SHA·φ archive-metrics.json) 부재 상태로 paper-bound 수 치 생산 중. tier3 전에 영속화 필수 (§7.3 제안 1).

tier1 핵심 결과 (Ⓑ, real config 3-seed — 직접 로그 대조)

threat	valuation (전 방법)	Flirds-1st	Flirds (2차)	비고
noisy	AUROC 1.0 / Spearman +1.000 전부 동률	1.0	1.0	FLDetector 0.75(off-threat), STD-DAGMM 0.417±0.425, FedDQC 0.917±0.118
freerider_zero	동률 (FedSV Sp +0.967)	1.0	1.0	STD-DAGMM 0.083±0.118 실패 (matched threat인데!), FedDQC 0.75
freerider_random	동률	1.0	1.0	STD-DAGMM 1.0 (random만 잡음)
poison (ASR=1.00)	동률 첫 붕괴	0.000±0.000 완 전화피 (Sp +0.000)	seed별 {0.0, 0.25, 1.0} = 0.417±0.425	(b)·loss-heur·Banzhaf·ShapleyFL AUROC 1.0/Sp +1.000; GTG Sp +0.867; FedSV Sp +0.367 추락; 4 detector ≥0.917

poison seed2 = 2차항이 1차를 이긴 최초의 LLM-scale 데이터포인트 (Flirds 2nd AUROC 1.0/Sp +1.000 vs 1st 0.0/+0.000) — 단 seed 분산이 극심(0/0.25/1.0). 이 분산의 원인 규명이 §7.3 제안 #2 (현 시점 최고 가치 실험).

7.1 Novelty 평가 (방어력 등급순)

강함 — ㉔ 근거, 리뷰어 방어 가능

#	주장	평가
N1	dual-oracle 검증 방법론 : (a)-valloss=(b)=estimator +1.000(1B N=5 fp32 3-seed) + (a)-ROUGE 발산 반례(+0.4@1B/-0.9@3B) + bf16 정밀도 바닥 진단	"같은 게임으로 검증" 통찰+실증 = FL valuation에 독립적으로 내놓을 만한 방법론 기여
N2	(b) oracle exact per-round 분해 : $2^N \rightarrow \sum_r 2^{\{P_r\}}$, $\Delta\phi \approx 3e-16$	Shapley linearity의 귀결이라 인프라성이나, volatility 문헌이 필요성을 독립 뒷받침하는 견고한 검증 장치
N3	비용 구조 : round당 1 HVP(N-독립)+N내적, 35-107s vs ~530s	△ "zero-comm"은 차별점 아님 — 자체 비교표 (flirds:228-231)서 GTG/ShapleyFL/Ripple/FedIF도 comm 0. 진짜 차별 = **서버 연산 구조(1 HVP vs 2^N coalition)**로 서술 교정 필요(flirds:52 내적 불일치)

중간 — 조건부

- **교집합 novelty** (client-level+in-run+closed-form 1st/2nd+zero-extra-comm+LoRA/LLM): "최초 federated in-run"은 Ripple 선점 자인 후 교집합으로 후퇴한 구조(06 §6.1 표 참조). 근거가 서술적 스캔(4-agent+GPT)이라 리뷰어에게 "incremental combination"으로 읽힐 위험. **교집합의 load-bearing 성분 = 2차항** — 서면 전체가 서고, 무너지면 "Shapley 프레이밍+LoRA 엔지니어링"으로 축소.
- **경계 특성화** (backdoor evasion = Taylor tangent vs exact secant 메커니즘; memory/phase2-step5-verification.md): 정직한 기여 framing. tier1의 seed-의존 2차항 결과로 이야기가 풍부해짐.
- **FLTrust $\approx$ normalized Flirds-1st**: 양날 — 포섭 서사인 동시에 1차 검출 신호가 2021년(FLTrust)+2025년(FedIF, 같은 정규화 내적 — [06] §6.3) 선점됐다는 뜻.

약함 — 미입증 (novelty의 사활처)

- **2차항 가치**: 어제까지 LLM-scale 입증 0건(N=5/N=100 모두 1st=2nd=+1.000, 1st가 15× 저렴; CNN 0.96>0.92는 plain-SGD 조건부 — momentum서 역전). **tier1 poison seed2가 첫 분리 신호이나 불안정**. Ripple와의 "2차 종류" 차별([06] §6.5)은 © Yonghee 결정 대기.
- **format-uniformity / per-domain norm hook**: ablation 전부 © — 현재는 "기여"가 아니라 "control 변수 선택".
- **이론(Prop 1/2)**: informal + 파일럿 U-shape 모순 관측, #5 검증 ©.

리뷰어 1순위 공격 지점 (직접 확인)

FedIF(2025)가 03-baselines-and-prior-work에 0회 등장(grep 확인)하고 codes/flirds/baselines/에도 없음. wiki 스스로 "Ripple 외 가장 가까운 federated in-run-on- Δw 경쟁자", "'why isn't 1st-order enough?'의 핵심 baseline"으로 등장(flirds:231,245)한 최근접 published 경쟁자가 대조 문서-비교 suite 양쪽에서 누락. ([06] 포지셔닝 문서가 같은 날 생겨 일부 해소 — 단 **baseline 구현 + [03] 통합은 여전히 부재**, [06] §6.3도 "Flirds-1st ablation $\approx$ FedIF 메커니즘"이라 같음 가능성만 시사.)

7.2 한계 분석

A. 방법 내재

1. **Taylor 절단** — clean-preserving backdoor의 γ -update가 clean val-loss를 내려 최저 ϕ 로 랭킹. tier1서 1st 완전회피(0.000), 2nd seed-의존. 전개-반경 진단/가드 코드 전무.
2. **plain SGD mom=0 강제** — AdamW 표준 실무와 비호환, momentum하 2차항 역효과(0.73<0.81) 기관측, FedHDS(Adam) 벤치와 충돌. 가장 큰 일반성 제약.
3. **fp32 강제** — 신호($\sim 1e-3$) < bf16 정밀도($\sim 8e-3$) 자체가 본질 제약. 7B 비용(no-tensor-core $\times 3.1$), bf16 배포 귀적 valuation 불가, protocol §13 vs task8 모순 미해소.
4. **eager attention 강제 / LoRA-subspace 한정**(실범위="LoRA-subspace Shapley") / **FedAvg 한정**(robust agg·FedProx·secure agg 비호환 — backdoor 방어가 robust agg 쓰는 시스템과 양립 불가) / **개별 Δw 노출**(privacy).

5. 단일 server val-loss 게임 — val 오염/편향 미고려, #16 민감도 연기. (a)-ROUGE 발산은 "val-loss가 안 속음"인 동시에 "배포지표 가치와 다른 게임" 반론 근거.

B. 증거력

1. N=5 near-additive 무변별 — noisy/FR은 real config서도 전 방법 +1.000 동물(tier1 재확인). 유일한 분리 = poison인데 Flirds에 불리한 방향. N=10 (a)-oracle 연기 = 무변별 해소의 유일한 직접 증거 부재.
2. lr 의존 AUROC 반전 — noisy ϕ 부호가 lr 의존($-0.0084 \leftrightarrow +0.0096 \rightarrow 0.75 \leftrightarrow 1.0$). real grid lr 선택이 noisy 결론을 결정하는데 lr 미확정.
3. 1-seed 다수(3B +0.900, N=100 detector) / α -sweep proxy-truth 순환(off-anchor truth=Flirds 자신 $\rightarrow$ 원리적으로 자기 오류 검출 불가) / CI(\$3.3)·timing(\$15.1) 미구현 / seed [0,1,2] vs protocol [42,123,2024].
4. 영속화 부재 현재진행형 — tier1/tier2가 .log-only로 돌고 있음 (\$7.0).

C. 위협모델·framing

1. poison 인위성 — hand-tuned 별도 config(LR2e-3/B8/E5/frac0.8)만 ASR>0, batch 하나로 1.0 $\leftrightarrow$ 0 반전, per_client 40 $\rightarrow$ 300은 공격 성립 위한 역조정. 위협별 trajectory config 상이 = category-together 원칙 훼손.
2. 최약 공격자만 — stealthy arm 불가($\|\Delta\|=40\times$), DBA 제외, free-rider easy 모드만(delta/recycled-aggregate = "genuinely AT RISK" 자인 모드가 task9 이연), adaptive attacker 부재.
3. orientation protocol 취약성 — D2b 사건(ϕ 채점 $\rightarrow$ 정반대 결론). 교정됐으나 규약 명문화 없으면 재발.
4. detector 개조 confound — FLTrust signed-cosine=원형 강화, STD-DAGMM hash+pooling=약화 가능 (0.628-tier1 FR-zero 0.083이 port confound인지 미분리), Ripple=우리 port 위 측정. 원형-ablation 부재.

D. 프로세스

1. 낙관적 distillation 드리프트 반복 — 검증세션 4건 교정(poison detector 1.0 $\rightarrow$ 0.75, FedSV +0.900, 360s, REFUTED $\rightarrow$ EVADED). D2b 오류 결론이 immutable raw에 정정 포인터 없이 잔존.
2. protocol stale(06-04) — 분기 4-11·(b) MC $\rightarrow$ exact 미반영 = "silent deviation 금지" 자기위반. [03]의 ShapleyFL +0.86 state-mixing(㉠ 수치를 ㉡ 맥락에 무라벨 인용).

7.3 개선 제안 (우선순위순)

● 즉시 (real grid 진행 중인 지금)

1. 결과 영속화: tier3 전 phase2_matrix.py에 run-dir 출력(metrics.json+ ϕ archive+config+git SHA), tier1/2는 .log 파싱 소급.
2. poison Flirds-2nd seed 분산({0,0.25,1.0}) 원인 규명: seed2가 왜 잡았나 — per-round ϕ 분해(1차 vs $\frac{1}{2}(\Delta w, H\Delta w)$ 기여). 기실행 궤적 재분석이라 비용 ~0, 2차항 novelty의 사할 — 현 시점 최고 가치 실험.
3. two-sided $|\phi|$ 점수를 matrix 표준 산출물로: " ϕ -extreme not ϕ -high" 발견의 label-free 제품화. 비용 ~0.
4. orientation 사전교정 + lr 양쪽($1e-3, 3e-3$) 보고 규약 명문화: lr-반전은 숨기면 약점, 보고하면 robustness 특성화.

● 단기 (논문 전 필수)

1. FedIF baseline 편입 (신호= $\Delta w / \|\Delta w\| \cdot \nabla \text{val}$ 라 fltrust.py 변형으로 저비용; 코드 공개돼 있음 — [06] §6.3) 또는 [03]에 수학적 관계+min-max/EMA 차이 명문화 — 1순위 공격 방어.
2. 2차항 결정 실험(#13 PGD/direction-aligned poison) 앞당기기: tier1 seed2 신호와 결합하면 "2차항이 언제 필요한가" 양방향 폐쇄(저도 honest fallback 기설계). [06] §6.5의 Ripple "2차 종류 차별"과 묶으면 경쟁자 대비 스토리 완성.
3. N=10 (a)-oracle (multi-GPU sharding 11-22h) — near-additive 무변별 해소의 유일한 직접 증거. 차선 = cross-silo N=10 detection-only(plan 기허용).
4. task9 delta/advanced free-rider: Flirds 진짜 위험 모드 — 뚫리면 경계 특성화, 막으면 robustness, 양쪽 다 논문 가치. backdoor 회피와 동종 맹점(val-loss 내리는 적대 update)의 free-rider 축 존재 여부가 §3.9 framing 완결성 결정.
5. loss-heur 공식 보완 검출기 패키징: "Flirds(tangent)+singleton secant 잔차" 하이브리드(~164s, 같은 frozen

logs) = "경계 발견+해법" 서사 완성 + 비용/역할 분리표.

6. 원형-ablation 3건 + bootstrap CI: ReLU-FLTrust / per-round STD-DAGMM / Ripple 저자코드 1-setting; CI는 ϕ archive만 있으면 소급 적용.
7. STD-DAGMM FR-zero 0.083 진단 (tier1 신규): zero-delta가 matched detector에 안 잡힘 = suite 서사의 구멍. pooling/hash confound 분리.

● 중기 (한계→기여 전환)

1. momentum/Adam-aware Taylor: velocity-tail 원인분석 기존재 → preconditioned delta 해석 확장 = 분기 #2를 한계에서 기여로.
2. Taylor 신뢰도 자기진단: 샘플 round서 1st+2nd 예측 vs `in_run_utility([k])` exact 잔차 → 전개 붕괴 runtime 플래그(loss-heur 경로 재활용). lr 부호반전 사전감지 가능성도 답해짐.
3. per-round 2^K oracle의 MC/stratified 근사 → α -sweep 전 지점 독립 truth = proxy-truth 순환 해소.
4. 이질-포맷 ablation: classification-포맷 client 의도 혼입 → ϕ 왜곡 정량화 = format-uniformity를 "한계 회피"에서 "finding+권고"로.
5. double-backward HVP(jvp-동치 $9.8e-6$ 기록만 존재) → SDPA/flash 활성화 = 7B eager 병목+val_maxlen confound 제거. 필요시 LoRIF Woodbury-ACC-SGD-IE.
6. 저비용 설득 실험: #17 per-client ϕ 정성 attribution(per-layer 로깅 기구현, near-free) + #18 clean-data skyline.

운영 (작지만 지금)

protocol 현행화(분기 4-11·seed 실험 7B 정밀도 모순) / D2b raw에 위키 측 정정 포인터 / [03] ShapleyFL +0.86 state-mixing 교정 / tier2 done[CHECK] cell 확인.

7.4 종합 판단

가장 단단한 자산 = 방법 정당성 증명(dual-oracle 삼중 일치 + exact per-round 분해 + 비용 구조)과 한계를 메커니즘 수준 까지 파는 특성화 문화. 가장 큰 리스크 = novelty 핵심 축인 2차항의 LLM-scale 입증 공백 + 최근접 경쟁자 FedIF의 비교 suite 부재. tier1 poison seed2가 2차항의 첫 실마리를 줬으므로, 지금 최고 가치의 한 수 = seed 분산 원인 규명(제안 #2) — 기실행 데이터 재분석이라 비용이 거의 없고, 결과가 논문 중심 서사를 결정한다.

근거: tier1 수치는 `runs/phase2_matrix/tier1/*.log` 직접 대조(06-10), 교정값은 `memory/phase2-step5-verification.md`, 나머지는 `00-06 + flirds/flirds-implementation-plan/flirds-protocol/threads/raw` 정독.