

Flirds 체크포인트 (2026-06-10)

목적: Phase 0-2 구현(코드 + step5 matrix orchestrator)이 끝난 시점에서, 연구자 본인이 전체 그림을 다시 잡기 위한 재오리엔테이션. 외부 발표용 아님. 방법: 문서 요약이 아니라 실제 코드(codes/) · raw 로그(research-wiki/raw/) · 논문 PDF를 7개 병렬 reader로 직접 읽고 대조 + load-bearing 항목 직접 spot-check. 추측 없음, 모든 정량주장에 파일경로 근거. 규율: ㉠ 코드+smoke green(값 coarse) / ㉡ 실제 실험결과(seed·N·model 명시) / ㉢ 설계 략·미실행 — 3-state 구분. 문서 과장은 검증값 채택 + 충돌 기록.

문서별 1줄 요약

문서	요약
00-overview	전체 그림 한 장 — end-to-end 파이프라인(mermaid), 구성요소 지도(estimator/oracle/9 valuation/4 detector/2×4 매트릭스), 용어집, 3-state 상태표. 제일 먼저 읽을 것.
01-research-value	알고리즘 + 노벨티 — flirds_estimator.py 코드 기준 1차+2차 Taylor-round당 HVP 1회 · forward HVP·true Hessian 정확본 + 선행한계→차별점→노벨티(각 근거).
02-experimental-setup	최종 실험 세팅 — 모델/regime/threat 4종/α-sweep/seed/LoRA-fp32/(b) 비용공식 + 위협 정의의 논문근거(answer_swap·free_rider·backdoor) + #7 selection 실측(metrics.json 직접 대조).
03-baselines-and-prior-work	baseline + 선행연구 (PDF 1:1 대조) — 가장 무거움. 경쟁 baseline 7종 + detector 4종 + 선행 6편, 원문 vs 우리구현 차이+왜. Xu·Bagdasaryan은 PDF 부재→web-extract.
04-plan-vs-implementation-divergences	plan 대비 분기 11건 — GGN→Hessian, momentum→plain SGD, ROUGE→val-loss, detector 재설계, per_client 40→300 등 + 각 raw 근거.
05-open-issues-and-next	미해결 + 다음 — poison-vs-Flirds framing(verification ruling: matrix=EVADED 맞음, headline은 미결) + claimed-vs-verified 교정표 + caveat + real grid 실행계획(cost-tiered).
06-closest-competitors-fedif-fedtsv-ripple	직접 경쟁자 3종 포지셔닝 — FedIF/FedTSV/Ripple을 'LLM+FL+기여도' 교집합 축에 놓은 근접도+장단점. ★ Ripple "2차항 없음" 주장을 코드(ripple.py:191)로 정밀화(within-round vs cross-round 곡률; © Yonghee 결정). 03의 경쟁 3종 심화판.
07-novelty-limitations-analysis	novelty·한계 분석 + 개선 제안 (06-10 오후) — novelty 방어력 등급(강: dual-oracle·per-round 분해·비용구조 / 사활처: 2차항), 한계 4범주 15건, 개선 17건 우선순위. ★ \$7.0이 00·05의 'real grid 미실행'을 SUPERSEDE: tier1 완료+tier2 진행 중(.log-only △), poison서 동를 첫 붕괴 — Flirds-1st 0.000 완전회피, 2nd seed별 {0,0.25,1.0}(seed2=2차가 1차 이긴 최초 LLM 데이터포인트).

추천 읽기 순서

00 → 01 → 02 → 03 → 04 → 05 (→ 06 경쟁자 포지셔닝 → 07 novelty·한계 판정)

빠르게 현황만: 00(상태표 \$0.5) → 05(다음 단계 \$5.5) → 07(\$7.0 real-grid UPDATE — 00·05의 '미실행'을 교체). 방법론 핵심만: 01(알고리즘 \$1.1) → 03(IRDS 대조 \$C.1). "내 주장이 진짜인가" 점검: 05(\$5.2 교정표) → 02(\$2.6 #7 실측). 경쟁자 포지셔닝만: 06(축별 근접도 \$6.1 → Ripple 2차 정밀화 \$6.5).

핵심 한 줄 (전 문서 종합)

- 방법은 검증됨(🟢): (a)-valloss = (b) in-run = estimator **Spearman +1.000** (1B N=5 fp32). free-rider ϕ 정확0. N=5 near-additive서 Flirds가 프론티어 지배(5-15× 싸게 같은 ranking).
- 코드는 단단함(🟡): estimator/oracle/backend/FL/데이터/baseline 11종/detector 4종/matrix orchestrator 전부 구현 + smoke green.
- real grid는 미실행(🟡) → STALE(06-10 오후, 07 \$7.00이 교체): tier1(silo5 4-threat 3-seed) 완료 + tier2(α -sweep) 진행 중. poison서 동를 첫 붕괴(Flirds-1st 0.000 / 2nd seed별 {0,0.25,1.0}). Δ .log-only — run-dir 영속화 필요.
- 교정 적용: poison detector 0.75($\neq 1.0$), FedSV tiny +0.900(real +1.000), STD-DAGMM ~360s, D2b "REFUTED"→matrix "EVADED(Flirds AUROC 0.0)"가 맞음.
- 즉시 다음: cost-tiered real grid (poison은 LR=2e-3 D2b config); \$3.9 headline framing은 Yonghee 결정.

근거 추적: 코드 인용은 path:line, 실측은 codes/runs/.../metrics.json 또는 research-wiki/raw/conversations/flirds/*.md, 논문은 research-wiki/raw/papers/flirds/*.pdf. 검증/교정은 ~/.claude/.../memory/phase2-step5-verification.md.
